

## **1 INTRODUÇÃO**

O desaparecimento de cães de estimação é um problema frequente em centros urbanos, causando considerável impacto emocional e financeiro para os tutores. Segundo estimativas de organizações de proteção animal, milhares de cães desaparecem todos os anos no Brasil, sendo que boa parte deles não é encontrada devido à ausência de mecanismos eficazes de rastreamento e monitoramento. Paralelamente a esse desafio social, os avanços recentes em Inteligência Artificial (IA) e Visão Computacional tornaram viável o desenvolvimento de soluções que utilizem o reconhecimento de imagens para auxiliar ativamente na busca por esses animais. Experimentos recentes já demonstram aplicações promissoras de IA para detecção de animais em vias públicas e o uso de modelos avançados como YOLOv8 em monitoramento urbano tem sido explorado. Assim, justifica-se o desenvolvimento do CÃO RADAR, um sistema inteligente de apoio na busca de cães perdidos, que funcionará como prova de conceito para um futuro serviço integrado a câmeras urbanas. Para o protótipo, será utilizado um celular como câmera, embora o conceito preveja escalabilidade para integração com câmeras de monitoramento urbano. O presente trabalho se concentra na questão de pesquisa: Como um sistema baseado em Visão Computacional pode simular, de forma experimental, a comparação eficaz de imagens de cães perdidos com registros de vídeo capturados em diferentes resoluções, de modo a aferir o grau de assertividade da identificação individual do cão? O desenvolvimento do projeto é pautado pelos objetivos, justificativas e delimitações apresentados nas seções seguintes.

### **1.1 Objetivos**

O projeto visa desenvolver uma solução tecnológica para o desafio social da busca por animais desaparecidos, explorando o potencial da Inteligência Artificial.

#### **1.1.1 Objetivo Geral**

O objetivo geral deste trabalho é desenvolver um sistema de software baseado em Inteligência Artificial que simule, ainda que de modo experimental, a comparação de imagens de cães perdidos fornecidas pelos seus tutores com imagens captadas por câmeras de monitoramento. Esta simulação será limitada

a cães de algumas raças reconhecidas que possuam um padrão determinado, ou de características físicas passíveis de identificação visual, visando aferir o grau de assertividade da identificação individual do cão.

### **1.1.2 Objetivos Específicos**

Para cumprir o objetivo geral e validar a viabilidade da solução, foram definidos os seguintes objetivos específicos:

Implementar um sistema de captura de imagens de cães utilizando diferentes resoluções de câmeras, incluindo câmeras de monitoramento para uso residencial e câmeras de smartphones.

Aplicar algoritmos de Visão Computacional (ex.: YOLOv8) para detecção de cães em imagens, incorporando a anonimização automática de humanos (borramento).

Desenvolver um módulo de comparação entre as imagens enviadas por tutores e os registros armazenados, retornando possíveis correspondências.

Medir o grau de acurácia e assertividade da identificação do animal quando a comparação das imagens ocorrer, de modo a evitar falsos positivos.

Indicar por intermédio de simulações e testes os requisitos mínimos necessários de configuração e padrões de imagens.

## **1.2 Justificativas e escopo do projeto**

### **1.2.1 Justificativas**

A relevância do projeto CÃORADAR se fundamenta em três dimensões principais:

Social: Contribuir para reduzir o sofrimento dos tutores e o abandono de animais, fornecendo uma ferramenta inovadora de apoio na busca.

Acadêmica: Explorar o uso de IA aplicada à visão computacional em um problema de relevância urbana e social, ampliando as discussões sobre ética, segurança e uso de dados em sistemas inteligentes.

Tecnológica: Validar o uso de algoritmos modernos de detecção de objetos e reconhecimento de imagens em um contexto real, utilizando técnicas de Machine Learning e bancos de dados para armazenamento e comparação de registros.

### **1.2.2 Escopo e Delimitações**

O presente trabalho caracteriza-se como um protótipo acadêmico, com natureza de prova de conceito experimental. O desenvolvimento está restrito ao prazo de dois semestres acadêmicos e à utilização de ferramentas gratuitas e de código aberto, como Python, bibliotecas de IA como PyTorch, OpenCV e YOLOv8. O protótipo utilizará um celular como câmera para validar o conceito, sendo que a integração real com as câmeras de monitoramento urbano da cidade de São Caetano do Sul será apenas simulada. Adicionalmente, o foco estará na validação da pipeline de detecção e comparação, e a classificação de atributos será restrita a um conjunto selecionado de poucas raças. O sistema de comparação por similaridade poderá apresentar falsos positivos/negativos , e sua acurácia será limitada pela disponibilidade de datasets e pelo poder computacional da equipe. Restrições éticas e legais quanto à captura e uso de imagens em espaços públicos também serão consideradas.

## **2 REFERENCIAL TEÓRICO**

### **2.1 Padrões de Raça e Identificação Visual de Indivíduos**

A identificação visual de um cão por um sistema de Inteligência Artificial depende fundamentalmente da compreensão dos seus padrões morfológicos. Esta seção aborda os desafios e as estratégias para o reconhecimento canino, partindo dos padrões oficiais que definem uma raça até os problemas práticos da identificação de indivíduos em ambientes urbanos

#### **2.1.1 Conceito de raça e variabilidade morfológica**

O reconhecimento de raças caninas constitui um problema de classificação de alta complexidade, tanto no campo da cinofilia quanto na aplicação de técnicas de Inteligência Artificial (IA). A Fédération Cynologique Internationale (FCI), principal órgão de regulamentação e padronização de raças no mundo, reconhece atualmente 356 raças oficiais (FCI, 2022). Cada raça é formalmente definida por um “padrão” que descreve um conjunto detalhado de características

morfológicas e comportamentais, incluindo proporções corporais, formato do crânio, tipo e densidade da pelagem, coloração, tamanho e movimentação típica. Esses atributos visuais, estabelecidos para preservar a identidade funcional e estética de cada raça, formam o núcleo do problema de identificação automatizada em imagens e vídeos.

Esses padrões têm o objetivo de preservar a morfologia e o temperamento originais de cada raça, permitindo a distinção visual entre elas. As raças são organizadas em dez grupos principais, definidos conforme porte, estrutura corporal e função histórica

(DA SILVA MELO, 2017):

- Grupo 1: Cães Pastores e Boiadeiros (exceto os suíços);
- Grupo 2: Pinscher, Schnauzer, Molossóides e Boiadeiros Suíços;
- Grupo 3: Terriers;
- Grupo 4: Dachshunds;
- Grupo 5: Spitz e tipos Primitivos;
- Grupo 6: Sabujos, Rastreadores e semelhantes;
- Grupo 7: Cães de Aponte;
- Grupo 8: Levantadores, Retrievers e Cães de Água;
- Grupo 9: Cães de Companhia;
- Grupo 10: Galgos (Lébreis).

A diversidade morfológica canina é resultado direto de processos de seleção artificial conduzidos ao longo de séculos, orientados por diferentes funções históricas como caça, guarda, companhia ou pastoreio. Como consequência, os cães domésticos exibem um dos maiores espectros fenotípicos dentro da espécie animal, com variação significativa de porte, pelagem, coloração e estrutura craniana. Essa variabilidade amplia a dificuldade dos algoritmos de reconhecimento visual, pois exige que o sistema aprenda representações suficientemente discriminantes para distinguir raças entre si e, simultaneamente, generalistas o bastante para reconhecer indivíduos dentro de uma mesma categoria.

Fatores ambientais e fisiológicos, como idade, tosa, iluminação, postura e ângulo de captura, introduzem ruído visual que compromete a consistência dos padrões morfológicos. Compreender a origem e a natureza dessa variabilidade é,

portanto, um passo fundamental para o desenvolvimento de soluções de Visão Computacional (VC) aplicadas à identificação canina. No contexto do projeto CÃORADAR, esse entendimento é essencial para calibrar a pipeline de detecção e comparação de imagens, garantindo que o sistema opere de forma robusta diante da diversidade real encontrada em ambientes urbanos.

### **2.1.2 Implicações visuais para sistemas de reconhecimento**

A distinção entre raças não é apenas um exercício de taxonomia cinológica, mas um fator que influencia diretamente o desempenho de sistemas de reconhecimento baseados em IA. As Redes Neurais Convolucionais (CNNs), base de praticamente todos os detectores modernos, aprendem a reconhecer padrões locais de textura, coloração e forma, compondo gradualmente abstrações visuais de alto nível (LECUN; BENGIO; HINTON, 2015). Assim, raças com traços morfológicos marcantes e consistentes — como o focinho achatado e orelhas eretas do Buldogue Francês, ou a pelagem densa e encaracolada do Poodle — apresentam características visuais fortemente discriminantes, que facilitam o aprendizado supervisionado e aumentam a acurácia do modelo.

Raças com alta variabilidade visual interna ou com características sobrepostas a outras tendem a gerar maior dispersão intra-classe, reduzindo a capacidade de separação linear nos espaços de features aprendidos pela rede. Em tais casos, abordagens tradicionais de classificação podem apresentar confusão entre classes semelhantes, como ocorre entre Golden Retriever e Labrador Retriever. Para mitigar esse problema, pesquisas recentes propõem estratégias de classificação hierárquica, em que o modelo diferencia grupos gerais antes de refinar a decisão, ou classificação Top-K, que admite múltiplas hipóteses ordenadas por probabilidade (CUI et al., 2024).

A literatura em visão computacional aplicada à identificação de cães demonstra avanços significativos com o uso de redes profundas. O Stanford Dogs Dataset (KHAO, 2011), composto por 20.580 imagens de 120 raças, e o Oxford-IIIT Pet Dataset (PARKHI; VEDALDI; ZISSERMAN, [s.d.]), com 37 classes, são amplamente utilizados como referência. Trabalhos baseados em transfer learning e redes pré-treinadas em ImageNet, como ResNet e EfficientNet,

alcançam precisão superior a 90% na classificação de raças puras em ambientes controlados. No entanto, como demonstram Cui et al. (2024), o desempenho desses modelos pode cair para menos de 70% em cenários de iluminação adversa, oclusão parcial ou imagens de baixa resolução — condições típicas de monitoramento urbano.

Esses resultados indicam que o sucesso do reconhecimento canino automatizado depende não apenas do modelo de IA, mas também da qualidade do dado de entrada. Aspectos como resolução mínima viável, nitidez, ângulo de visão e ausência de motion blur tornam-se determinantes para a eficácia do sistema. No caso do CÃORADAR, a calibração de resolução e o controle de qualidade dos frames capturados constituem etapas obrigatórias do processo de pré-filtragem, evitando que frames inadequados comprometam o desempenho dos classificadores.

Outro aspecto técnico relevante é o balanceamento entre classes nos conjuntos de dados. Bases caninas frequentemente apresentam desequilíbrio, com raças populares (como Poodle e Golden Retriever) mais representadas que outras (como Schnauzer ou Shiba Inu). Essa desproporção leva o modelo a enviesar previsões para classes dominantes. Técnicas de data augmentation, oversampling sintético e loss functions ponderadas são amplamente utilizadas para mitigar esse problema. No CÃORADAR, optou-se por um conjunto reduzido de raças justamente para evitar tal desequilíbrio e priorizar a análise da pipeline.

Em síntese, a variabilidade visual entre raças, a qualidade do dado e o balanceamento das amostras compõem o tripé de desafios para a detecção e classificação automática de cães. A compreensão desses fatores é essencial para a definição de parâmetros e estratégias de treinamento que maximizem a robustez do sistema proposto.

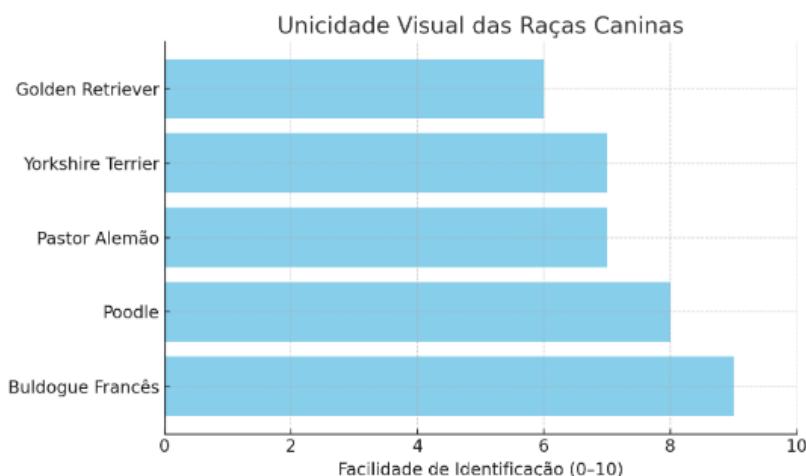
### 2.1.3 Seleção das raças para o protótipo CÃORADAR

Para fins de validação experimental da prova de conceito, o projeto CÃORADAR limita-se a um conjunto de cinco raças caninas com elevado contraste morfológico e ampla disponibilidade de imagens em bases públicas: Buldogue Francês, Poodle, Pastor Alemão, Yorkshire Terrier e Golden Retriever. Essa seleção foi orientada por três critérios principais: (i) diversidade morfológica e visual, garantindo silhuetas e texturas distintas; (ii) disponibilidade de dados públicos para treino e validação; e (iii) relevância prática, considerando raças comuns em áreas urbanas brasileiras.

O Buldogue Francês é caracterizado por porte compacto e orelhas eretas; o Poodle, por sua pelagem densa e encaracolada; o Pastor Alemão, por seu porte atlético e coloração marrom com preto; o Yorkshire Terrier, por pelos longos e sedosos; e o Golden Retriever, por pelagem dourada e aparência robusta. Essa seleção garante diversidade de tamanho, textura e coloração, permitindo testar o sistema em diferentes escalas e contextos de iluminação.

Ao reduzir o número de classes, o projeto controla a complexidade computacional e viabiliza uma análise aprofundada de desempenho, especialmente nas etapas de detecção, recorte e comparação de atributos. Essa limitação é estratégica e não definitiva — em etapas futuras, o sistema poderá ser expandido para abranger mais raças ou até identificação individual por embeddings visuais.

*Figura 1 – Unicidade visual de raças*



*Fonte: Pesquisa sobre raças de cão*

## 2.1.4 Considerações sobre mestiçagem e variação intra-raça

Um dos desafios mais expressivos para a aplicação prática de sistemas de reconhecimento de cães em ambientes reais é a mestiçagem, particularmente relevante em centros urbanos brasileiros. Cães sem padrão racial definido (SRD) resultam de cruzamentos múltiplos, apresentando combinações imprevisíveis de características visuais — como coloração híbrida, proporções intermediárias e variações cranianas. Essa variabilidade extrema inviabiliza a abordagem de classificação fechada por categorias fixas, já que o modelo supervisionado não possui classes que representem adequadamente essa diversidade.

Pesquisas sobre fine-grained classification apontam que a presença de cães mestiços gera alta sobreposição interclasse, dificultando a convergência dos classificadores (ARAVA; YANG; YUAN, [s.d.]). Modelos treinados exclusivamente em raças puras tendem a falhar ao identificar cães mestiços, classificando-os incorretamente como a raça mais próxima visualmente. Para contornar essa limitação, o CÃORADAR adota uma abordagem de extração de atributos em vez de uma classificação direta. Essa estratégia decompõe a tarefa em subtarefas independentes — como estimar porte, cor predominante, tipo de pelagem e formato da cabeça — e, a partir desses atributos, infere raças prováveis.

Essa abordagem é implementada por meio de Modelos de Linguagem Multimodais (VLMs), detalhados na seção 2.3, capazes de combinar informações visuais e textuais. O sistema é instruído, via prompt engineering, a descrever a aparência do animal e retornar atributos estruturados, em vez de uma única classe. Essa solução é mais robusta à variabilidade fenotípica e reflete melhor a diversidade real dos cães urbanos.

Além de lidar melhor com mestiçagem, a extração de atributos permite comparações semânticas flexíveis. Assim, o sistema pode identificar similaridades entre um cão perdido descrito como “pequeno, pelagem clara, orelhas eretas” e outro detectado com características equivalentes, mesmo que a raça exata não seja conhecida.

### **2.1.5 Considerações finais do capítulo**

Compreender os padrões morfológicos e visuais das raças caninas vai além da descrição biológica: trata-se de um componente essencial para o desenho e calibração de modelos de visão computacional voltados à detecção e identificação de cães. O domínio dessas características: forma, textura, coloração e silhueta orienta tanto a seleção das raças utilizadas nos testes quanto a definição dos parâmetros de extração e comparação de atributos.

Ao integrar princípios da cinologia e da inteligência artificial, o CÃORADAR busca equilibrar rigor técnico e aplicabilidade social, contribuindo para a criação de um sistema mais robusto, ético e aderente à realidade urbana brasileira.

## **2.2 Desafios computacionais do projeto**

A implementação do CAORADAR — um Sistema como Serviço (SaaS) que integra Visão Computacional em tempo real com a rede de vigilância urbana Smart Sanca: envolve desafios técnicos interligados nas áreas de aquisição de vídeo, processamento/armazenamento de grandes volumes de dados e classificação robusta de atributos visuais. Esta seção apresenta os problemas centrais, as implicações arquitetônicas e as estratégias de mitigação propostas, fundamentadas em literatura científica e em práticas consolidadas de engenharia de sistemas.

### **2.2.1 Aquisição e qualidade do frame**

O desempenho de toda a *pipeline* depende criticamente da qualidade do dado de entrada. Em cenários urbanos, variáveis como oclusão, *motion blur*, baixa iluminação e variação de escala degradam a informação visual. Ocultações parciais por pedestres ou veículos exigem o emprego de técnicas de *Multi-Object Tracking* (MOT) para recuperar identidades após breves perdas de visibilidade (ZHANG et al., 2021). Similarmente, o *motion blur*, causado pelo movimento do animal ou vibração da câmera, pode ser mitigado com modelos de *deblurring* (ex.: DeblurGAN-v2) aplicados em pré-processamento (KUPYN et al., 2019). Para lidar com a variação de escala e iluminação, que pode tornar a classificação inviável, é imprescindível um Módulo de Análise de Qualidade do Frame (AQF).

Esse módulo deve avaliar métricas objetivas (como nitidez e área do objeto) e descartar *frames* que não atinjam uma Resolução Mínima Viável (RMV), evitando a introdução de ruído no sistema.

### **2.2.2 Ingestão, processamento em streaming e persistência**

A operação contínua (24/7) produz um fluxo massivo de vídeo, impondo requisitos de latência, resiliência e controle de custos. Para gerenciar esse fluxo, recomenda-se uma plataforma de *streaming* distribuído, como Apache Kafka, que desacopla os produtores (câmeras) dos consumidores (módulos de análise) e permite processamento paralelo (APACHE SOFTWARE FOUNDATION, [2025?]). A arquitetura deve priorizar o processamento na borda (*edge*), onde a triagem inicial (IA 1) ocorreria para reduzir latência e tráfego de rede, enviando ao *cloud* apenas eventos relevantes (HU et al., 2023). A persistência desses dados deve ser híbrida: metadados estruturados (localização, *timestamp*) devem residir em um banco relacional com suporte geoespacial (ex.: PostgreSQL + PostGIS), enquanto os objetos binários (imagens) devem ser armazenados em *Object Storage* escalável (ex.: Amazon S3), com políticas de *lifecycle* e versionamento de imagens para otimizar os custos de armazenamento (POSTGIS, [2025?]; AMAZON WEB SERVICES, [2025?]).

### **2.2.3 Classificação de atributos: raça, porte e coloração**

Classificar raça, porte e coloração em imagens capturadas “*in the wild*” é um problema de *fine-grained recognition*, agravado por mestiçagem (SRD), pose variável e baixa resolução. Classificadores treinados exclusivamente em raças puras (KHAO, 2011; PARKHI; VEDALDI; ZISSEMAN, [s.d.]) tendem a falhar nesse cenário. Estratégias robustas envolvem modelos que fornecem saídas *top-K* (as raças mais prováveis) ou *multi-label* (combinação de características) (ARAVA; YANG; YUAN, [s.d.]). Além disso, o treinamento com *augmentations* que simulem sujeira e variações de iluminação aumenta a resiliência. Sugere-se uma arquitetura hierárquica, onde o sistema primeiro estima atributos genéricos (porte, silhueta) e, condicionalmente, aciona um classificador de raça mais refinado apenas quando a RMV é atendida (CUI et al., 2024).

## **2.2.4 Síntese: implicações para o projeto CAORADAR**

A conjunção dos desafios acima demanda um projeto que balanceie precisão, latência e custo. Em termos práticos, recomenda-se implementar o AQF na borda; utilizar processamento distribuído via Kafka para escalabilidade; e adotar uma estratégia de persistência híbrida (PostGIS para metadados; *Object Storage* para imagens). A IA de classificação deve ser projetada para saídas *Top-K* e *multi-label*, e o sistema deve ser avaliado com métricas padronizadas (mAP, MOTA/IDF1, *Top-K*) em conjuntos de vídeo reais, sempre aplicando práticas de privacidade e minimização de dados. Essas escolhas orientam a metodologia experimental deste TCC e servem como critérios para seleção de tecnologias, *datasets* e métricas de avaliação.

## **2.3 Desenvolvimento de software do projeto**

O núcleo funcional do projeto CÃORADAR reside na aplicação de técnicas de Inteligência Artificial (IA) para processar e interpretar dados visuais. O objetivo de detectar cães em ambientes urbanos e, subsequentemente, comparar suas características com um banco de dados de animais desaparecidos, enquadra-se no campo da Visão Computacional (VC). Esta seção detalha os fundamentos teóricos das tecnologias de detecção de objetos e da extração de atributos que sustentam o sistema.

### **2.3.1 Visão Computacional e Detecção de Objetos**

Visão Computacional é uma área da ciência da computação que busca replicar a capacidade humana de "ver" e interpretar imagens e vídeos. Diferente do simples processamento de imagem, a VC envolve a extração de informações e a tomada de decisões baseadas nesses dados (Szeliski, 2010). Uma de suas tarefas fundamentais é a **detecção de objetos**, que consiste não apenas em classificar um objeto (ex.: "isto é um cão"), mas também em localizar sua posição exata na imagem, geralmente através de uma "caixa delimitadora" (*bounding box*).

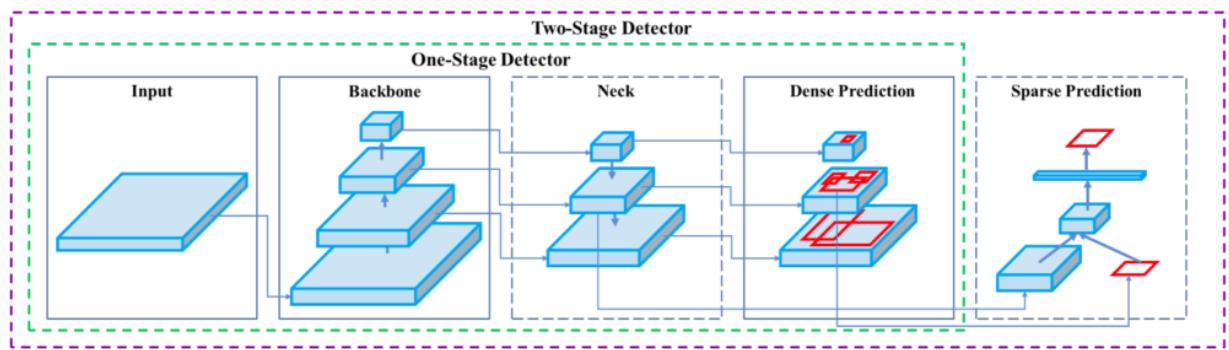
No contexto do CÃORADAR, a detecção de objetos é a primeira etapa crítica da *pipeline* de análise. Ela permite que o sistema filtre automaticamente o fluxo de

vídeo e identifique *frames* que contêm um cão, para posterior análise de raça, porte e cor.

### 2.3.2 Redes Neurais Convolucionais (CNNs) e a Arquitetura YOLO

A revolução recente na precisão da detecção de objetos foi impulsionada pelo *Deep Learning*, especificamente pelas Redes Neurais Convolucionais (CNNs). As CNNs são arquiteturas de rede neural projetadas para processar dados que possuem uma topologia de grade, como imagens. Elas aprendem hierarquias de características (filtros) automaticamente, desde bordas e texturas simples até formas complexas (LECUN; BENGIO; HINTON, 2015).

*Figura 2 – Arquitetura YOLO*



Fonte: [https://visao computacional.com.br/yolo-versoes-3-e-4-arquitetura/](https://visaocomputacional.com.br/yolo-versoes-3-e-4-arquitetura/)

Dentro das arquiteturas de detecção baseadas em CNNs, a família YOLO (*You Only Look Once*) se destaca. Proposta por Redmon et al. (2016), a arquitetura YOLO trata a detecção de objetos como um problema de regressão. Ela analisa a imagem inteira de uma só vez e prediz todas as caixas delimitadoras e probabilidades de classe simultaneamente, o que a torna extremamente rápida e adequada para processamento em tempo real.

O projeto CÃORADAR opta pela utilização de uma implementação moderna desta família, o YOLOv8 (ULTRALYTICS, [2025?]), que representa um estado da arte em equilíbrio entre velocidade de inferência e acurácia de detecção, sendo vital para a triagem eficiente de imagens.

### **2.3.3 Extração de Atributos com Modelos de Linguagem Multimodais (LLMs)**

Após a detecção do cão (IA 1), o desafio seguinte é implementar o "Módulo de comparação" (IA 2). Para fins acadêmicos e em linha com os avanços recentes, este projeto propõe o uso de um Modelo de Linguagem de Grande Escala (LLM) pré-treinado com capacidades multimodais (também conhecidos como *Vision-Language Models* ou VLMs).

Diferente de um modelo de classificação tradicional que apenas retorna uma etiqueta (ex: "Poodle"), os VLMs podem analisar uma imagem e responder a perguntas complexas sobre ela em linguagem natural. Para o CÃORADAR, a imagem do cão (recortada pela detecção do YOLOv8) é fornecida ao LLM juntamente com um *prompt* de engenharia (instrução textual) solicitando a extração dos atributos visuais relevantes.

Por exemplo, um *prompt* estruturado solicitaria ao modelo que retornasse a raça provável, a cor predominante e o porte estimado do animal. A resposta do modelo, idealmente formatada em JSON, constitui os **metadados** que serão persistidos no banco de dados. O "Módulo de comparação", portanto, não realiza uma busca por similaridade de vetores de imagem, mas sim uma **consulta estruturada** que compara os atributos fornecidos pelo tutor no *input* com os atributos extraídos pelo LLM nas capturas automatizadas.

## **3 METODOLOGIA**

### **3.1 Pesquisa de campo: Formulário aberto**

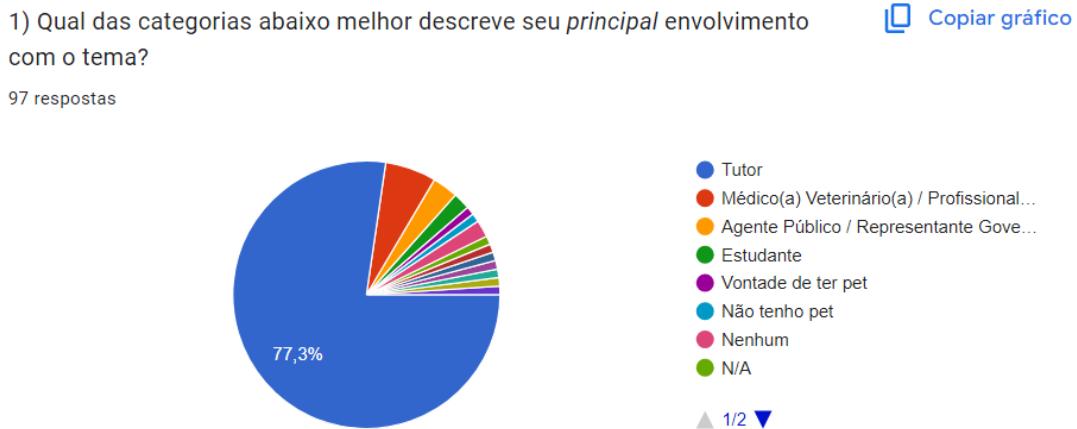
Para validar quantitativamente a percepção do problema, a relevância da solução CÃORADAR e os requisitos de funcionalidade, foi aplicado um formulário online. A pesquisa foi conduzida de forma aberta dos dias 04/11 até 11/11, resultando em um total de 97 respostas: [Questionário - CÃORADAR](#).

#### **3.1.1 Categorias dos usuários**

A maior parte dos participantes (77,3%) se identifica como tutores de cães, mostrando que o público respondente tem experiência direta com o tema. As demais categorias apareceram em porcentagens bem menores, distribuindo-se

entre profissionais da área veterinária, agentes públicos, estudantes, pessoas que desejam ter pet, pessoas sem pet ou sem envolvimento direto.

*Figura 3 – Gráfico categorias dos usuários*

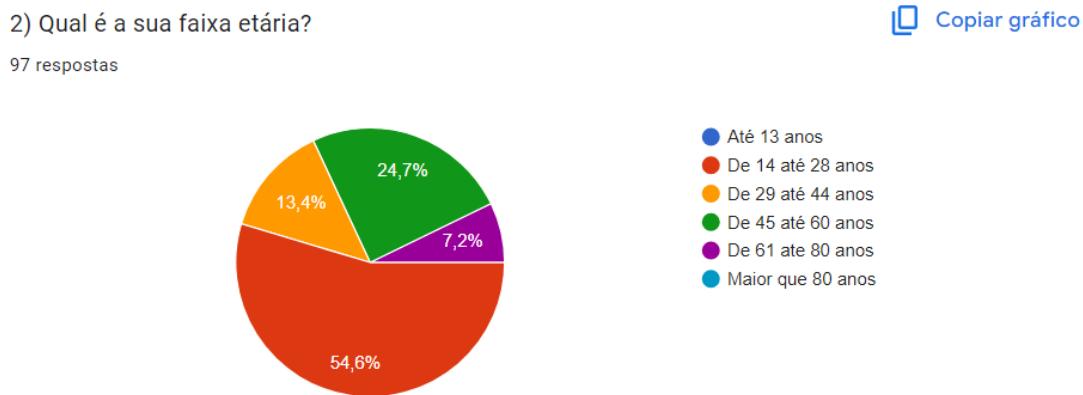


*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

Isso indica que a amostra é majoritariamente composta por tutores, justamente o grupo mais impactado pelo problema estudado.

### 3.1.2 Faixa Etária

*Figura 4 – Gráfico de faixa etária*



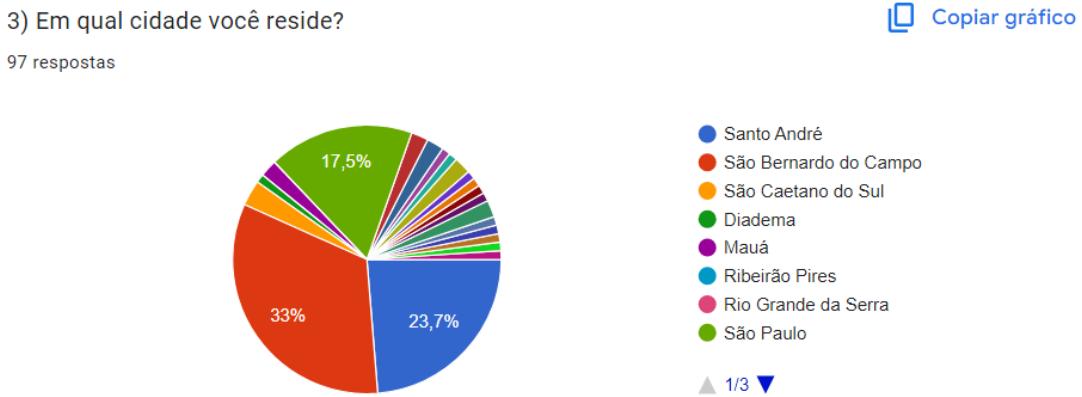
*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

A maior parte dos respondentes está na faixa de 14 a 28 anos, representando 54,6% da amostra. Em seguida, aparecem as faixas 29 a 44 anos (24,7%) e 45 a 60 anos (13,4%). Apenas 7,2% têm entre 61 e 80 anos, enquanto as faixas "até 13 anos" e "acima de 80 anos" não tiveram participação relevante.

Esses dados mostram que o público é predominantemente jovem adulto, com maior engajamento entre pessoas de 14 a 44 anos.

### 3.1.3 Cidades dos Respondentes

*Figura 5 – Gráfico cidades dos entrevistados*



*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

A maioria dos participantes reside no ABC Paulista, com destaque para São Bernardo do Campo, que representa 33% das respostas, seguido por Santo André, com 23,7%. Também há participação relevante de moradores da cidade de São Paulo, que correspondem a 17,5% da amostra. As demais cidades, como São Caetano do Sul, Diadema, Mauá, Ribeirão Pires e Rio Grande da Serra, aparecem com percentuais menores, porém ainda contribuem para a diversidade regional da pesquisa. Esses resultados indicam que o público está concentrado na região metropolitana que seria diretamente impactada e potencialmente beneficiada por um sistema como o CÃORADAR.

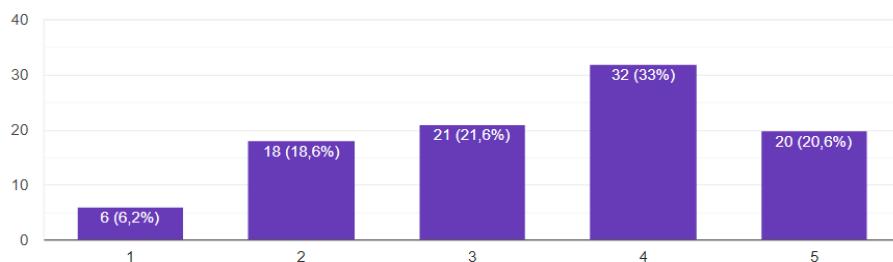
### 3.1.3 Frequência do Problema

*Figura 6 – Gráfico Frequência de ocorrência do problema*

4) Na sua opinião, a perda de animais de estimação é um problema frequente na sua cidade?

 Copiar gráfico

97 respostas



*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

A análise da percepção de frequência do problema revela que a maioria dos respondentes (53,6%) considera a perda de animais de estimação um evento frequente (nota 4, com 33%) ou muito frequente (nota 5, com 20,6%) em sua cidade. Esta percepção majoritária contrasta com os 24,8% que avaliam o problema como pouco frequente (notas 1 e 2) e os 21,6% que se mantêm neutros (nota 3). Estes dados validam empiricamente a justificativa social do projeto, demonstrando que o desafio abordado pelo CÃORADAR é uma preocupação real e significativa para o público pesquisado.

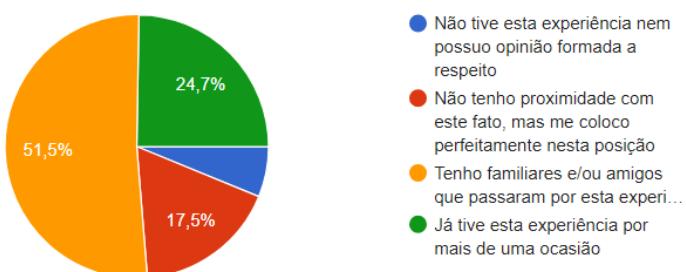
### 3.1.5 Proximidade com a Perda

*Figura 7 – Gráfico experiência da perda*

5) Você conhece alguém ou já passou pela experiência do seu pet se perder fora de casa?

 Copiar

97 respostas



*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

A pesquisa sobre a proximidade dos respondentes com o tema revela que a grande maioria (76,2%) possui uma conexão direta ou próxima com a perda de um animal. Este número é composto por 51,5% que conhecem familiares ou amigos que passaram pela experiência e 24,7% que já vivenciaram pessoalmente o desaparecimento de um pet em mais de uma ocasião. Adicionalmente, 17,5% dos participantes, mesmo sem proximidade com o fato, afirmaram se colocar "perfeitamente nesta posição". Somados, 93,7% dos entrevistados (seja por experiência direta, indireta ou empatia) validam a relevância emocional e social do problema, reforçando a urgência de uma solução como a proposta pelo CÃORADAR.

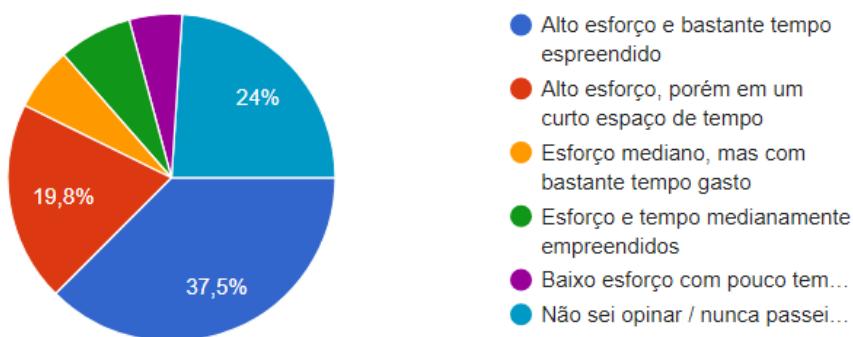
### 3.1.6 Nível de Esforço/Tempo

*Figura 8 – Gráfico Nível de Esforço/Tempo*

- 6) Se já viveu a situação de perda ou se identifica com este cenário, qual foi o nível de esforço e tempo necessário para encontrar o animal perdido?

 Copiar

96 respostas



*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

Questionados sobre o esforço e tempo despendidos na busca por um animal perdido, 37,5% dos respondentes selecionaram a opção "Alto esforço e bastante tempo empreendido", sendo esta a maior fatia. Além disso, 19,8% indicaram "Alto esforço, porém em um curto espaço de tempo", o que totaliza 57,3% dos participantes que percebem o processo como de "alto esforço". Em contrapartida, 24% não opinaram ou nunca passaram pela situação, e as demais categorias de esforço mediano ou baixo representam fatias menores. Estes dados sugerem que os métodos tradicionais de busca são amplamente

percebidos como árduos e ineficientes, reforçando a justificativa tecnológica do CÃORADAR como uma solução necessária para otimizar e reduzir o desgaste desse processo.

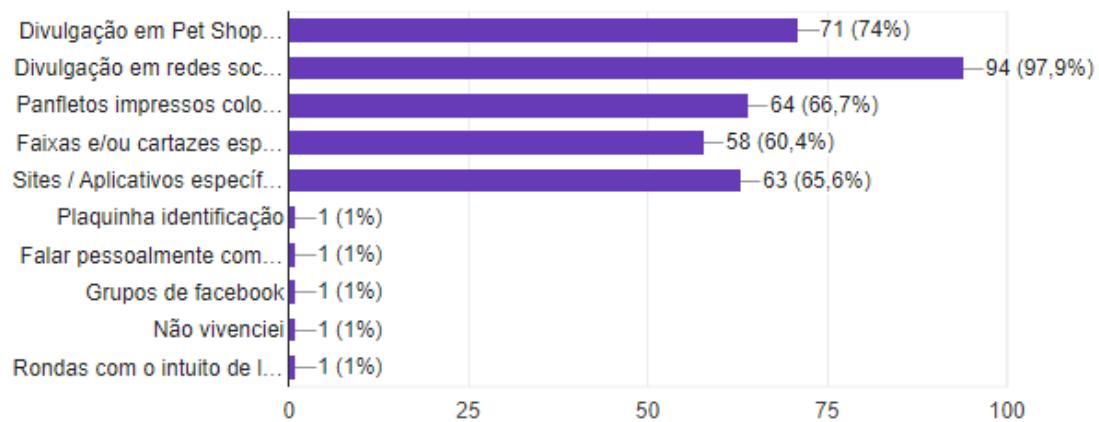
### 3.1.7 Métodos de Busca Válidos

*Figura 9 – Gráfico Métodos de Busca Válidos*

 Copiar

- 7) Selecione todas as opções que você considera válidas para reencontrar um animal perdido:

96 respostas



*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

A investigação sobre os métodos de busca validados (96 respostas) demonstra que o ecossistema de ferramentas atual é reativo e dependente do esforço manual do tutor. A "Divulgação em redes sociais" (97,9%) surge como o método quase universal, indicando que a busca se inicia em canais digitais amplos, mas não especializados em rastreamento. Em complemento, os métodos tradicionais, físicos e de alto esforço manual ainda são amplamente validados, incluindo "Divulgação em Pet Shops" (74%), "Panfletos impressos" (66,7%) e "Faixas/cartazes" (60,4%). Mesmo os "Sites/Aplicativos específicos" (65,6%), embora validados, representam no cenário atual ferramentas passivas (como murais de anúncios). Este cenário revela que não há uma solução tecnológica proativa e automatizada, validando a lacuna de mercado para uma ferramenta como o CÃORADAR, que propõe inverter essa lógica, de uma busca manual para uma busca ativa e inteligente.

### 3.1.8 Relatos de Dificuldades

*Figura 10 – Relatos de Dificuldades*

8) Caso tenha experiência própria ou próxima, descreva brevemente como a busca e o reencontro ocorreram (ou quais foram as maiores dificuldades)

52 respostas

Através do Facebook

Um cliente meu perdeu o pet dele, postou em grupos de Facebook e foi encontrado

Coloquei cartaz em postes de muito certo na época não havia redes sociais

tive vizinho que perdeu, colocamos em redes sociais, em grupos de whatsapp, e foi encontrado por um pet shop

Vasculhei todas as ruas do meu bairro, mas ela foi encontrada por um vizinho que acolheu

*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

A análise dos 52 relatos qualitativos, provenientes da questão discursiva opcional, aprofunda a compreensão das metodologias de busca atuais e suas principais dificuldades. Os respondentes relatam que os maiores desafios são a desorientação espacial ("não saber para qual direção o cachorro [foi]", "dificuldade em prever onde... poderia ter ido") e a ineficiência temporal ("a busca foi longa, pois tínhamos informações antigas"). Os métodos de busca descritos são invariavelmente manuais, reativos e de alto esforço, como "vasculhar todas as ruas", "procurar de carro", e a mobilização de "redes sociais", "grupos de whatsapp" e "cartazes". Os relatos de reencontro bem-sucedido frequentemente dependem da sorte ou da intervenção da comunidade ("vizinho que acolheu", "portaria... ligou", "veterinária... reconheceu"), enquanto vários casos terminam em fracasso ("não obtive sucesso", "nunca mais voltou"). Notavelmente, um relato mencionou o uso de câmeras privadas para "ver em que direção ele tinha ido", validando a premissa central do CÃORADAR. Em suma, os relatos descrevem um processo estressante, manual e de baixa eficiência, reforçando a lacuna que uma solução de monitoramento proativo pode preencher.

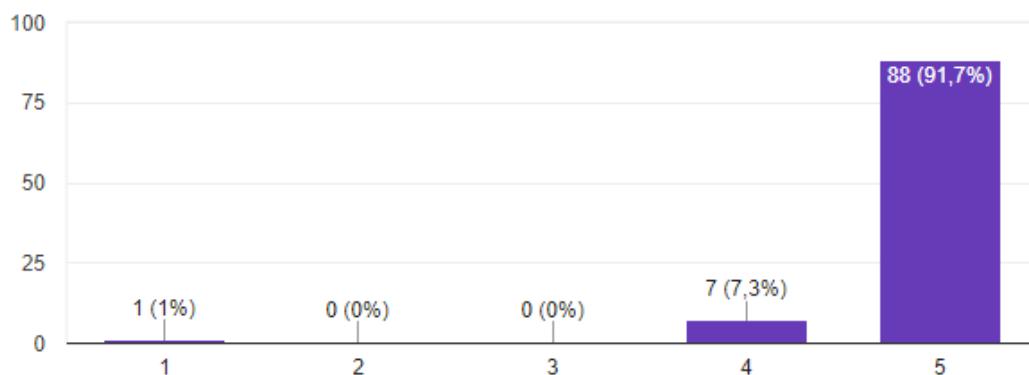
### 3.1.9 Validação da Solução IA

Figura 11 – Gráfico Validação da Solução IA

 Copiar

9) Acha que um sistema/App integrado com as câmeras de vigilância de sua cidade, utilizando IA para reconhecer traços do cão, facilitaria drasticamente a busca?

96 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

Ao avaliar a receptividade da solução central do projeto, a pesquisa questionou se um sistema/App com IA integrado a câmeras de vigilância "facilitaria drasticamente a busca". Os dados demonstram uma validação massiva da proposta do CÃORADAR: 91,7% dos 96 respondentes (88 pessoas) concordaram totalmente (nota 5) que a solução traria um benefício drástico. Somando-se aos 7,3% (7 pessoas) que deram nota 4, um total de 99% do público enxerga um alto valor na solução. Com apenas 1% de discordância (nota 1) e 0% de neutralidade, este resultado confirma de forma contundente a aceitação e a relevância da hipótese tecnológica do trabalho, indicando um alinhamento direto entre a solução proposta e a necessidade percebida pelo público.

### 3.1.10 Qualidade das Fotos

*Figura 12 – Gráfico Qualidade das Fotos*

 Copiar

- 10) Para maior precisão do CAORADAR, o sistema necessita de fotos claras. Você possui fotos recentes do seu cão, que mostrem suas características (cor, marcas, manchas)?

96 respostas



*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

Para validar a viabilidade técnica da entrada de dados no sistema, a pesquisa avaliou se os tutores possuem o material necessário para o CÃORADAR. Os resultados indicam uma forte prontidão do público: a grande maioria dos respondentes, 67,7%, afirmou possuir "várias fotos de boa qualidade" de seus cães. Somando-se aos 12,5% que possuem fotos de "qualidade média", 80,2% do total de entrevistados teria imagens utilizáveis para o sistema. Em contraste, apenas 3,1% indicaram não ter fotos adequadas (16,7% não possuem cão atualmente). Este dado é crucial pois confirma que a premissa de input do projeto é viável, demonstrando que a maioria dos tutores pode fornecer os dados de qualidade que o algoritmo de IA necessita para operar.

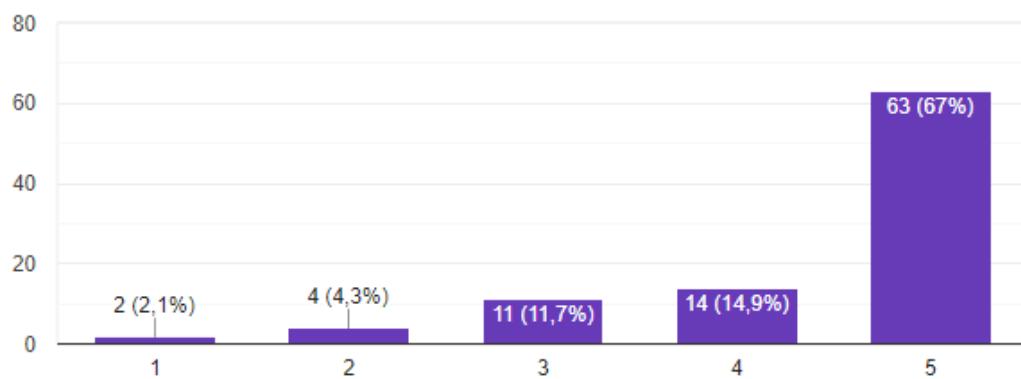
### 3.1.11 Capacidade de Descrição

Figura 13 – Gráfico Capacidade de Descrição

Copiar

- 11) Se o seu cão se perdesse, em uma escala de 1 a 5, quanto detalhadamente você conseguiria descrever suas características físicas (manchas, cicatrizes, cor exata do pelo, etc.) para um sistema de busca?

94 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

A confiança dos tutores em fornecer dados descritivos para o sistema também foi avaliada, complementando a análise sobre a entrada de fotos. Os resultados mostram que 67% dos 94 respondentes (63 pessoas) autoavaliaram com nota máxima (5) sua capacidade de descrever detalhadamente as características físicas de seus cães (manchas, cicatrizes, etc.). Somando-se aos 14,9% (nota 4), 81,9% do público sente-se confiante em prover esta informação. Este dado valida a premissa de que os usuários são uma fonte de *input* de atributos de alta qualidade, o que é fundamental para a precisão dos algoritmos de filtragem e comparação do CÃORADAR.

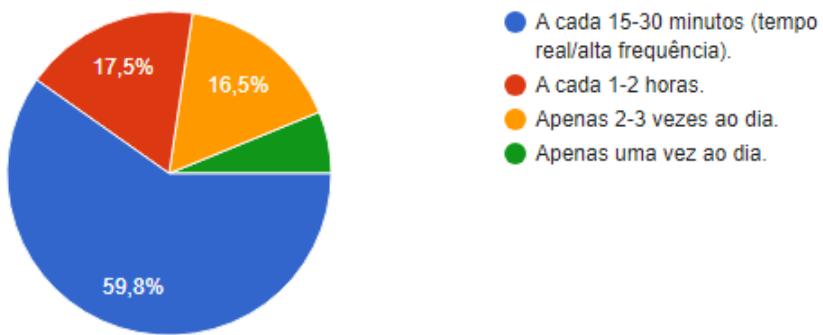
### 3.1.12 Frequência de Atualizações

Figura 14 – Gráfico Frequência de Atualizações

12) Caso você utilizasse um sistema de busca por IA como o CÃORADAR (sistema inteligente com IA que busca auxiliar o tutor na busca de seu cão **perdido** com monitoramento de câmeras), com que frequência você esperaria receber atualizações sobre o monitoramento do seu cão nas vias públicas?

 Copiar

97 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

A definição dos requisitos de usabilidade do sistema foi avaliada pela expectativa de frequência de atualizações. Os resultados indicam uma demanda clara por monitoramento proativo, com 59,8% dos 97 respondentes esperando atualizações em "tempo real/alta frequência" (a cada 15-30 minutos). Esta é a expectativa majoritária, seguida por 17,5% que esperam atualizações a cada 1-2 horas. As frequências mais baixas, como "Apenas 2-3 vezes ao dia" (16,5%) e "Apenas uma vez ao dia" (fatia verde), representam uma minoria. Esta forte preferência por um sistema de alta frequência define um requisito técnico e de desempenho crucial para o CÃORADAR, alinhando a arquitetura do projeto à principal necessidade do usuário em um momento de angústia.

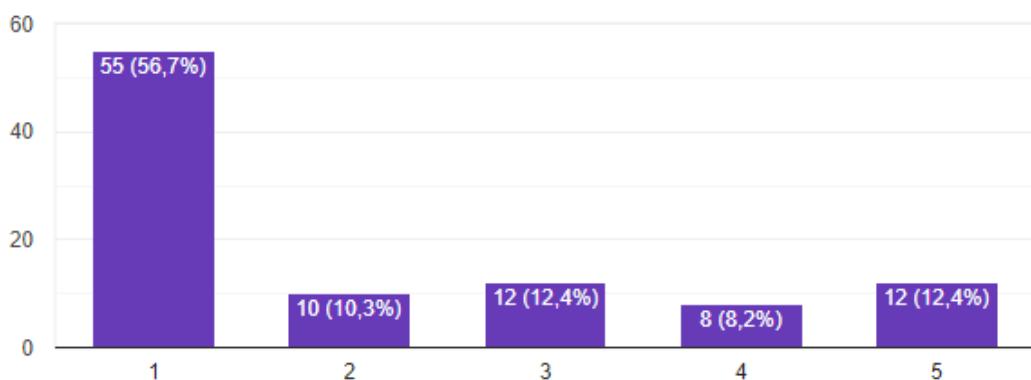
### 3.1.12 Preocupação com Privacidade

*Figura 15 – Gráfico Preocupação com Privacidade*

13) Em uma escala de 1 a 5, quão preocupado(a) você estaria com a privacidade (uso de câmeras públicas para monitorar animais) ao utilizar um serviço como o CAORADAR?

 Copiar

97 respostas



*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

A análise sobre as preocupações éticas de privacidade, um dos pontos de delimitação do projeto, demonstra que a maioria do público não vê o uso de câmeras como um impedimento. A maioria absoluta dos 97 respondentes (56,7%) indicou a nota 1, o nível mais baixo de preocupação. Somando as notas 1 e 2, um total de 67% do público demonstra baixa preocupação com o tema. Em contrapartida, 20,6% (soma das notas 4 e 5) expressaram alta preocupação, enquanto 12,4% se mantiveram neutros (nota 3). Os dados indicam que, embora a preocupação com a privacidade exista e deva ser tratada (como previsto no objetivo de anonimização de humanos), ela não é uma barreira para a maioria dos usuários, que prioriza a eficácia da busca.

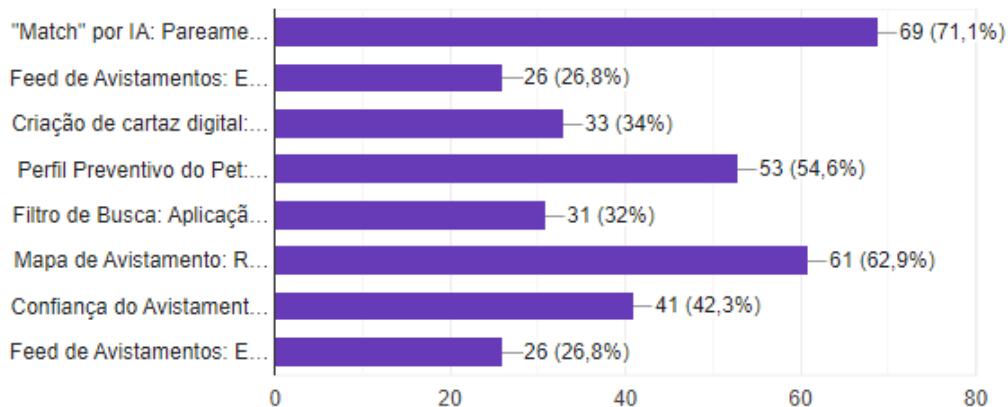
### 3.1.14 Prioridade de Funcionalidades

Figura 16 – Gráfico Prioridade de Funcionalidades

14) Selecione as 3 funcionalidades mais importantes na sua opinião que potencialmente poderíamos ter

 Copiar

97 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

A priorização de funcionalidades, onde os 97 respondentes podiam selecionar as 3 mais importantes, revela um claro alinhamento com a principal proposta de valor do projeto. A funcionalidade "'Match" por IA: Pareamento...', que representa o núcleo tecnológico do CÃORADAR, foi destacada como a mais importante, sendo selecionada por 71,1% dos participantes. Em segundo e terceiro lugar, respectivamente, figuram o "Mapa de Avistamento" (62,9%) e o "Perfil Preventivo do Pet" (54,6%). Esta hierarquia de preferência é fundamental, pois valida que o investimento em Visão Computacional é a maior demanda do usuário, seguida por ferramentas de visualização de dados (mapa) e preparação (perfil preventivo).

### **3.1.15 Sugestões Adicionais**

*Figura 17 – Sugestões Adicionais*

15) Se houver alguma funcionalidade ou recurso adicional que considere fundamental para o sucesso do CÃORADAR e que não foi listado acima, por favor, descreva-o no campo a seguir

20 respostas

Sistema está perfeito

Se vc perder seu cão e alguém acha- lo vc poderia colocar no app seu áudio para o seu cão escuta lo chamando.....o cão reconhece a voz do dono de longe

Se tivesse um chip com numeração para rastreio que pudesse estar no pet talvez os sistema pudesse enviar a localização desta forma ser mais eficaz.

*Fonte: Questionário - Pesquisa para TCC – CÃORADAR*

Na questão discursiva opcional sobre funcionalidades adicionais, que obteve 20 respostas, uma parte dos participantes usou o espaço para elogiar a ideia e validar a proposta existente. Entre as sugestões construtivas, o tema mais recorrente foi a integração com hardware de rastreamento físico, como chips de localização. Outras ideias pontuais mencionadas incluíram a integração com serviços de recolhimento de animais, a emissão de alertas de proximidade para outros usuários do aplicativo e a utilização de recursos de áudio para auxiliar na busca.

### **3.1.16 Conclusões do Formulário**

A pesquisa quantitativa validou de forma robusta os pilares do projeto. Os dados confirmam que: (1) O desaparecimento de animais é percebido como um problema frequente e angustiante (53,6% com notas 4 ou 5). (2) Os métodos atuais são vistos como de "alto esforço" (57,3%) e são reativos (baseados em redes sociais e panfletos). (3) A solução CÃORADAR tem aceitação massiva (99% com notas 4 ou 5). (4) Os requisitos técnicos são viáveis, pois os usuários possuem fotos (80,2%) e confiança na descrição (81,9%). (5) A maior demanda é pelo "Match" por IA (71,1%), e a preocupação com a privacidade é baixa para a maioria (67%).

## **3.2 Pesquisa Qualitativa: Entrevista com Discentes de Medicina Veterinária**

Para complementar os dados quantitativos obtidos com o público-alvo e validar a viabilidade técnica e prática da solução, a pesquisa incluiu uma etapa de coleta de dados qualitativos. O instrumento escolhido foi a entrevista semiestruturada com um grupo focal de especialistas em formação.

O grupo foi composto por quatro discentes do curso de Medicina Veterinária: Ana Beatriz (19 anos, Santo André), Beatriz (19 anos, Ribeirão Preto), Emily (20 anos, Santo André) e Larissa (19 anos, Mauá). A escolha deste público justifica-se por sua visão acadêmica e pré-clínica, aliando o conhecimento técnico sobre as raças e o contato com a realidade da perda de animais em estágios e rotinas de clínicas. Durante a entrevista, foi apresentado às participantes o contexto do projeto CÃORADAR, explicando a premissa de utilizar Inteligência Artificial e câmeras de monitoramento urbano para auxiliar na busca por cães perdidos.

### **3.2.1 Identificadores Visuais Fáceis**

Pergunta: Quais características físicas de um cão são mais fáceis de identificar visualmente?

Ana Beatriz iniciou a resposta, destacando características de alta visibilidade. Ela mencionou que o focinho braquicefálico (achatado, como em Pugs e Bulldogs) é um identificador claro. As demais estudantes (Beatriz, Emily e Larissa) concordaram e complementaram, citando a coloração e o comprimento do pelo (ex: Doberman, Golden) como fatores fáceis. Ana Beatriz acrescentou que orelhas (sempre caídas ou levantadas), manchas específicas e o tamanho/pporte (ex: Salsicha) também são distintivos.

### **3.2.2 Características Padrão em Cães**

Pergunta: Existe alguma característica que seja um "padrão" na maioria dos cães, mesmo de raças diferentes?

As estudantes debateram sobre características universais. Ana Beatriz mencionou que, embora existam exceções, a característica mais comum vista no dia a dia é o focinho preto. As outras estudantes, em conjunto, concordaram,

notando que, embora os coxins (almofadas das patas) variem, o focinho preto é o padrão mais observado na rotina clínica.

### **3.2.3 Dificultadores na Captura de Imagem**

Pergunta: O que mais atrapalha na captura da característica física de um cão por foto?

As estudantes concordaram unanimemente que o ângulo é o principal dificultador. Ana Beatriz explicou que fotos de costas, de lado ou focadas apenas no rabo são insuficientes. Elas concluíram que a qualidade da imagem é importante, mas que a captura do rosto do animal é o fator mais essencial para a identificação.

### **3.2.4 Identificação de Outras Raças**

Pergunta: Além das raças do projeto (Golden, Yorkshire, etc.), quais outras vocês consideram "únicas" ou fáceis de identificar?

As estudantes listaram raças que consideram de fácil identificação. Ana Beatriz e Beatriz citaram Pug e Pinscher como inconfundíveis. Em conjunto, elas também adicionaram Rottweiler e American Bully. Em contrapartida, Ana Beatriz alertou que raças como Shih Tzu seriam o maior desafio, por serem muito parecidas entre si.

### **3.2.5 Viabilidade da Expansão de Raças**

Pergunta: Vocês acham viável expandir o sistema para todas as raças (incluindo vira-latas) ou seria melhor manter o foco em raças específicas para garantir a precisão?

Esta foi uma resposta crucial de Ana Beatriz. Ela argumentou que limitar o sistema a raças específicas excluiria a maioria dos usuários, incluindo ela própria. Ela defendeu que, embora seu cão seja "vira-lata", ele "não existe outro

"igual" devido a características únicas, e que focar em características específicas (manchas, etc.) seria mais eficaz do que focar em raças.

### **3.2.6 Causas Comuns de Fuga**

Pergunta: Na experiência de vocês, qual é o motivo mais comum para um cão fugir?

As estudantes concordaram que a fuga raramente ocorre durante o passeio. Ana Beatriz afirmou que o motivo mais comum é o **descuido residencial**, principalmente o **portão aberto** (ao sair com o carro, receber visitas). As demais complementaram citando o pânico por **barulhos** (como fogos) como segunda causa principal.

### **3.2.7 Facilitadores e Dificultadores da Busca Atual**

Pergunta: Quais são os maiores facilitadores e dificultadores na hora de procurar um cão perdido?

Ana Beatriz, relatando sua experiência pessoal, apontou o maior facilitador como a divulgação rápida e massiva ("o meu a gente achou porque divulgou muito"). Ter uma foto de boa qualidade e saber a região da perda também são cruciais. Os maiores dificultadores citados por ela e pelas demais foram: (1) O Tempo ("daqui dois dias ele já pode estar longe"); (2) Fotos Inadequadas ("muita gente não tem foto... ou tipo, uma foto abraçada"); e (3) O Nervosismo do tutor.

### **3.2.8 Validação de Recursos de Apoio**

Pergunta: O que vocês acham de integrar uma rede social e mensagens de apoio?

Ao discutir o nervosismo, as estudantes validaram a ideia de apoio. Ana Beatriz alertou que alertas em alta frequência podem gerar "muito desespero", mas que uma mensagem de apoio, "mesmo que mínima", ajudaria. Beatriz (Ribeirão Preto) mencionou uma iniciativa de sucesso em sua cidade (um grupo de

Instagram). Todas concordaram que integrar uma funcionalidade de rede social (um "feed" onde o público pudesse postar fotos de "eu vi") seria uma adição de grande valor.

### **3.2.9 Validação da Solução Central (IA)**

Pergunta: Vocês acham que a funcionalidade principal (busca por IA nas câmeras) faz sentido e vocês usariam?

Todas as estudantes validaram a ideia. Ana Beatriz e Emily afirmaram que "faz sentido" começar por cães, pois "a maioria das pessoas tem cão" e o comportamento de gatos é muito diferente. Elas confirmaram que usariam a funcionalidade.

### **3.2.10 Desafios de Infraestrutura e Câmeras**

Pergunta: Quais desafios práticos vocês veem na dependência de câmeras urbanas? Seria melhor integrar com câmeras de condomínios e comércios?

As estudantes ponderaram sobre a infraestrutura. Ana Beatriz sugeriu uma abordagem híbrida para diminuir custos: usar as câmeras públicas em conjunto com a rede social de avistamentos (onde o público envia fotos). Elas sugeriram que, em locais com pouca cobertura pública, a integração com câmeras de comércios e condomínios faria uma grande diferença e deveria ser buscada.

### **3.2.11 Conclusão da Entrevista**

A entrevista com as discentes de medicina veterinária forneceu uma validação qualitativa crucial para o projeto CÃORADAR. Os *insights* técnicos confirmaram que os métodos de busca atuais são reativos, descentralizados (dependentes de redes sociais) e ineficientes, sendo o tempo o fator crítico para o sucesso. A solução proposta foi recebida com entusiasmo, sendo classificada como "fantástica" e necessária. As contribuições mais significativas para o escopo do protótipo foram a validação de que a especificidade da IA (focando em manchas

e traços únicos, e não apenas na raça) é o fator-chave para o sucesso, e a recomendação de não excluir os cães sem raça definida (vira-latas), visto que representam a maioria dos casos e possuem características individuais identificáveis. Por fim, as estudantes validaram a baixa preocupação do público com a privacidade frente ao benefício social e reforçaram o valor de uma funcionalidade de "feed" de avistamentos pela comunidade.

### **3.3 Pesquisa Qualitativa: Entrevista com o Setor Público (Zoonoses)**

Para validar a dimensão do problema e a viabilidade da solução sob a ótica do poder público, a pesquisa foi complementada por uma entrevista com uma autoridade da área. A entrevista foi conduzida por telefone com a gerente do departamento de Zoonoses de Santo André, Sandra.

O objetivo foi mapear os processos oficiais atuais, identificar os gargalos logísticos do setor público no manejo de animais perdidos e avaliar a receptividade e o potencial de integração da solução CÃORADAR.

#### **3.3.1 Procedimentos e Amostra**

A amostra desta etapa qualitativa foi intencional, buscando a gestora responsável pela política pública de manejo animal no município. Foi apresentado à gerente o contexto do projeto CÃORADAR, e as perguntas focaram nos processos de notificação, identificação e reencontro de animais perdidos na cidade.

#### **3.3.2 Análise e Resultados da Entrevista**

A análise da entrevista com a gerente de Zoonoses permitiu validar os gargalos do sistema atual e o valor da inovação proposta. Os *insights* foram agrupados nos seguintes eixos temáticos:

**3.3.2.1 Processos Atuais de Identificação Preventiva e Reativa** A gestora explicou que o município de Santo André possui um sistema de identificação preventiva, o RGA (Registro Geral do Animal), que é atrelado à vacinação. Caso um cão com RGA seja encontrado, a identificação e o reenvio ao dono são diretos.

No entanto, quando um animal sem RGA ou outro tipo de identificação (como microchip) se perde, o processo torna-se reativo e ineficiente. A gerente foi enfática ao afirmar que, nesses casos, "a maior chance é de não reencontrar". O Centro de Zoonoses funciona como um "achados e perdidos", mas depende do tutor ir fisicamente ao local perguntar sobre o animal.

**3.3.2.2 Gargalos Logísticos e Gestão de Dados** Foi confirmado que a taxa de cães perdidos reportada é alta. O departamento recebe frequentes chamados e ligações sobre perdas, mas estes registros são, em sua maioria, manuais (anotações) e, por vezes, lançados em sistemas de forma secundária.

A gestora citou que o poder público é "limitado" na prevenção e que a gestão desses dados não é priorizada por não haver ferramentas eficazes que justifiquem o investimento de recursos. A falta de informações (como a direção da fuga) e a ausência de ferramentas proativas resultam em uma baixa taxa de reencontro.

**3.3.2.3 Validação e Receptividade da Solução CÃORADAR** A ideia do CÃORADAR foi recebida como "ótima" e de "extrema importância". A gerente validou que a solução poderia "facilitar e otimizar muito mais os processos de reencontro".

No entanto, ela posicionou a ferramenta, inicialmente, como um "complemento" essencial às buscas já priorizadas pelos tutores (redes sociais, divulgações informais). Embora a gestora incentive o uso de chips, ela reconhece que o custo é um impedimento para a maioria, o que eleva o valor de uma solução baseada em câmeras.

**3.3.2.4 Viabilidade de Integração e Burocracia** A gerente demonstrou grande interesse na integração da plataforma com o departamento. Ela sugeriu que os reportes de cães avistados ou recolhidos pela Zoonoses pudessem ser inseridos no CÃORADAR, e o sistema, por sua vez, enviaria alertas para tutores com cães de características semelhantes.

Sobre os entraves burocráticos e de privacidade no uso de câmeras públicas, a gestora não demonstrou grande preocupação. Ela afirmou que, estando o

sistema sob controle do poder público e focado no bem-estar social, o fator privacidade teria "pouca importância" e seria superável.

### **3.3.3 Conclusões da Entrevista**

A entrevista com o departamento de Zoonoses validou a hipótese do projeto sob a perspectiva logística e pública. Ficou evidente que (1) existe um vácuo tecnológico na gestão de animais perdidos, com processos manuais e reativos; (2) a taxa de reencontro de animais sem identificação é baixa, o que justifica uma ferramenta de busca ativa; (3) a solução é vista pelo poder público como uma otimização de importante para um processo hoje limitado.

## **REFERÊNCIAS**

- ARAVA, S.; YANG, W.; YUAN, Y. Mixed Breed Dogs Classification. [S.I.: s.n.], [s.d.]. Disponível em: [https://www.academia.edu/33721767/Mixed\\_Breed\\_Dogs\\_Classification](https://www.academia.edu/33721767/Mixed_Breed_Dogs_Classification). Acesso em: 29 out. 2025.
- BOCHKOVSKIY, A.; WANG, C.; LIAO, H. M. YOLOv4: Optimal Speed and Accuracy of Object Detection. arXiv preprint arXiv:2004.10934, 2020. Disponível em: <https://arxiv.org/abs/2004.10934>. Acesso em: 11 nov. 2025.
- CUI, Y. et al. Classification of Dog Breeds Using Convolutional Neural Networks. MDPI, 2024. Disponível em: <https://www.mdpi.com/2306-5354/11/11/1157>. Acesso em: 29 out. 2025.
- DA SILVA MELO, J. Classificação de raças caninas segundo a FCI. 2017.
- DENG, J. et al. ImageNet: A Large-Scale Hierarchical Image Database. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2009, Miami. Proceedings [...]. New York: IEEE, 2009. p. 248-255. Disponível em: [http://www.image-net.org/papers/imagenet\\_cvpr09.pdf](http://www.image-net.org/papers/imagenet_cvpr09.pdf). Acesso em: 11 nov. 2025.

FCI – Fédération Cynologique Internationale. Breeds Nomenclature. [S.I.]: FCI, [s.d.]. Disponível em: <https://www.fci.be/en/Nomenclature/Default.aspx>. Acesso em: 27 out. 2025.

HU, M. et al. Edge-Based Video Analytics: A Survey. [S.I.: s.n.], 2023. (arXiv:2303.14329). Disponível em: <https://arxiv.org/abs/2303.14329>. Acesso em: 29 out. 2025.

KHAO, Aditya. Stanford Dogs Dataset. Stanford University, 2011. Disponível em: <https://vision.stanford.edu/aditya86/StanfordDogs/>. Acesso em: 29 out. 2025.

KUPYN, O. et al. DeblurGAN: Blind Motion Deblurring Using Conditional Adversarial Networks. In: PROCEEDINGS OF THE IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2018. Disponível em: [https://openaccess.thecvf.com/content\\_cvpr\\_2018/CameraReady/1944.pdf](https://openaccess.thecvf.com/content_cvpr_2018/CameraReady/1944.pdf). Acesso em: 29 out. 2025.

KUPYN, O. et al. DeblurGAN-v2: Deblurring (Orders-of-Magnitude) Faster and Better. In: INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), 2019. Disponível em: [https://openaccess.thecvf.com/content\\_ICCV\\_2019/papers/Kupyn\\_DeblurGANv2\\_Deblurring\\_Orders-of-Magnitude\\_Faster\\_and\\_Better\\_ICCV\\_2019\\_paper.pdf](https://openaccess.thecvf.com/content_ICCV_2019/papers/Kupyn_DeblurGANv2_Deblurring_Orders-of-Magnitude_Faster_and_Better_ICCV_2019_paper.pdf). Acesso em: 29 out. 2025.

LAMPERT, C. H.; NICKISCH, H.; HARMELING, S. Learning to Detect Unseen Object Classes by Between-Class Attribute Transfer. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2009, Miami. Proceedings [...]. New York: IEEE, 2009. p. 965-972. Disponível em: <http://bar-le-d.com/wp-content/uploads/2016/09/AttributeTransfer.pdf>. Acesso em: 11 nov. 2025.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. Nature, v. 521, n. 7553, p. 436-444, 2015.

LIN, T.; ROYCHOWDHURY, A.; MAJI, S. Bilinear CNN Models for Fine-Grained Visual Recognition. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), 2015, Santiago. Proceedings [...]. New York: IEEE, 2015. p.

1449-1457. Disponível em: <https://arxiv.org/abs/1504.07889>. Acesso em: 11 nov. 2025.

LOBO, A. C. Origem do Cão. Formação TMA, 2019. Disponível em: <https://formacaotma.net/wp-content/uploads/2019/05/origem-do-c%C3%A3o.pdf>. Acesso em: 27 out. 2025.

PARKHI, O. M.; VEDALDI, A.; ZISSERMAN, A. Oxford-IIIT Pet Dataset. University of Oxford, [s.d.]. Disponível em: <https://www.robots.ox.ac.uk/~vgg/data/pets/>. Acesso em: 29 out. 2025.

PRODUCTION & DIVISION. Definição do termo raça. 2001.

RADFORD, A. et al. Learning Transferable Visual Models From Natural Language Supervision. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 2021, [S.I.]. Proceedings [...]. [S.I.]: PMLR, 2021. p. 8748-8763. Disponível em: <https://arxiv.org/abs/2103.00020>. Acesso em: 11 nov. 2025.

REDMON, J. et al. You Only Look Once: Unified, Real-Time Object Detection. In: PROCEEDINGS OF THE IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2016.

SZELISKI, R. Computer Vision: Algorithms and Applications. Springer, 2010.

ULTRALYTICS. ultralytics/ultralytics: YOLOv8. [S.I.]: GitHub, [2025?]. Disponível em: <https://github.com/ultralytics/ultralytics>. Acesso em: 29 out. 2025.

ZHAO, F. et al. A survey of fine-grained visual-categorization. arXiv preprint arXiv:1907.03069, 2019. Disponível em: <https://arxiv.org/abs/1907.03069>. Acesso em: 11 nov. 2025.

ZHANG, Y. et al. Multi-Object Tracking by Associating Every Detection Box. [S.I.: s.n.], 2021. (arXiv:2110.06864). Disponível em: <https://arxiv.org/abs/2110.06864>. Acesso em: 29 out. 2025.