

**Universidade Municipal de São Caetano do Sul
Escola de Tecnologias da USCS
Curso Superior de Graduação em Ciências da Computação**

**Douglas Ferreira Primo
Gabriel Shoga
Giovanni Chiarello
Pedro de Abreu Palma
Vinicius Vilela**

**CÃO RADAR: sistema de identificação e localização de cães
perdidos por meio de Visão Computacional e Inteligência Artificial
Generativa Multimodal**

**São Caetano do Sul
2026**



**Universidade Municipal de São Caetano do Sul
Escola de Tecnologias da USCS
Curso Superior de Graduação em Ciências da Computação**

**CÃO RADAR: sistema de identificação e localização de cães
perdidos por meio de Visão Computacional e Inteligência Artificial
Generativa Multimodal**

Douglas Ferreira Primo	RA: 8092305
Gabriel Shoga	RA: 8128818
Giovanni Chiarello	RA: 8138412
Pedro de Abreu Palma	RA: 8138077
Vinicius Vilela	RA: 8135388

**São Caetano do Sul
2026**

Universidade Municipal de São Caetano do Sul
Escola de Tecnologias da USCS
Curso Superior de Graduação em Ciências da Computação

Douglas Ferreira Primo
Gabriel Shoga
Giovanni Chiarello
Pedro de Abreu Palma
Vinicius Vilela

CÃO RADAR: sistema de identificação e localização de cães perdidos
por meio de Visão Computacional e Inteligência Artificial Generativa
Multimodal

Trabalho de conclusão de curso apresentado à
Universidade Municipal de São Caetano do Sul, como
requisito parcial para a obtenção do Título de
Bacharel em Ciência da Computação.

Orientador: Prof. Me. Fabrício Ricardo Perrella

São Caetano do Sul
2026

FICHA CATALOGRÁFICA

CÃO RADAR: sistema de identificação e localização de cães perdidos por meio de Visão Computacional e Inteligência Artificial Generativa Multimodal.

Douglas Ferreira Primo

Gabriel Shoga

Giovanni Chiarello

Pedro de Abreu Palma

Vinicius Vilela

São Caetano do Sul – SP, 2026.

108 f. : il. ; 30 cm.

Orientador: Prof. Me. Fabricio Ricardo Perrella

TCC (Graduação) - Universidade Municipal de São
Caetano do Sul

Escola de Tecnologias da USCS

Curso Superior de Graduação em Ciência da Computação, 2026.

1. Visão Computacional. 2. Inteligência Artificial Generativa. 3. YOLOv8.
4. Reidentificação de Cães. 5. Microsserviços I. Fabrício Ricardo Perrella. II.
Universidade Municipal de São Caetano do Sul. III. Ciência da Computação. IV.
CÃO RADAR: sistema de identificação e localização de cães perdidos por meio
de Visão Computacional e Inteligência Artificial Generativa Multimodal.

REITOR DA UNIVERSIDADE MUNICIPAL DE SÃO CAETANO DO SUL

Prof. Dr. Leandro Campi Prearo

PRÓ-REITOR DE GRADUAÇÃO

Prof. Me. Silton Marcelli Romboli

GESTORA DOS CURSOS DE COMPUTAÇÃO

Prof. Me. Fabrício Ricardo Perrella

Universidade Municipal de São Caetano do Sul

CÃO RADAR: sistema de identificação e localização de cães perdidos por meio de Visão Computacional e Inteligência Artificial Generativa Multimodal

Trabalho de conclusão de curso apresentado à Universidade Municipal de São Caetano do Sul, como requisito para a obtenção do Título de Bacharel em Ciência da Computação, composta pela banca examinadora:

Prof. Me. Fabrício Ricardo Perrella
Orientador

Professor 1
Universidade Municipal de São Caetano do Sul (USCS)

Professor 2
Universidade Municipal de São Caetano do Sul (USCS)

São Caetano do Sul – SP, _____.

Dedicamos este trabalho aos nossos familiares e amigos, pelo apoio incondicional durante toda a jornada acadêmica, e a todos os tutores que enfrentaram a dolorosa experiência do desaparecimento de seus animais de estimação, fonte de inspiração e propósito para o desenvolvimento do projeto Cão Radar.

Agradecimentos

Agradecemos, primeiramente, ao nosso orientador, Prof. Me. Fabrício Perrella, pela orientação competente, pela paciência ao longo das inúmeras reuniões de acompanhamento, pelos conselhos técnicos sempre pertinentes e pela confiança depositada em nosso projeto, da concepção até a entrega final desta monografia.

Agradecemos à Universidade Municipal de São Caetano do Sul (USCS), à Escola de Tecnologias e a todo o corpo docente do Curso Superior de Graduação em Ciência da Computação pela formação sólida e pelas oportunidades oferecidas ao longo destes anos, que possibilitaram nosso crescimento pessoal, acadêmico e profissional.

Dirigimos um agradecimento especial às discentes do curso de Medicina Veterinária que generosamente aceitaram participar da pesquisa qualitativa deste trabalho: Ana Beatriz, Beatriz, Emily e Larissa. Suas contribuições foram fundamentais para a validação técnica e prática da proposta, em particular no que tange à seleção das características fenotípicas mais relevantes para a identificação visual dos animais.

Estendemos nossa gratidão à Sra. Sandra, gerente do departamento de Zoonoses de Santo André, pela disponibilidade em conceder entrevista sobre os processos públicos de manejo de animais perdidos e pela receptividade à proposta do Cão Radar, cujos insights orientaram diretamente o escopo institucional e operacional do projeto.

Agradecemos, ainda, aos 97 respondentes anônimos da pesquisa quantitativa, que dedicaram seu tempo ao preenchimento do formulário e cujas respostas sustentaram empiricamente a relevância social do problema abordado.

Por fim, agradecemos aos nossos familiares e amigos pelo apoio constante, pela compreensão nos momentos de ausência e pelo incentivo nos momentos de maior dificuldade ao longo do desenvolvimento deste trabalho.

*"Until one has loved an animal, a part
of one's soul remains unawakened."
(Anatole France)*

RESUMO

O desaparecimento de cães de estimação em centros urbanos brasileiros constitui um problema social recorrente, agravado pela inexistência de mecanismos tecnológicos eficazes de rastreamento e identificação automatizada. O presente trabalho apresenta o Cão Radar, um protótipo acadêmico de sistema de identificação e reidentificação de cães extraviados, fundamentado na combinação entre Visão Computacional clássica e Inteligência Artificial Generativa Multimodal. O sistema foi concebido sob uma arquitetura de microsserviços, integrando uma interface web em Angular/TypeScript, um back-end transacional em Java/Spring Boot e um microsserviço cognitivo em Python, que combina o detector espacial YOLOv8 e o modelo generativo Google Gemini 2.5 Flash para extração de atributos fenotípicos e cálculo de similaridade entre relatos de perda e avistamentos captados por câmeras de monitoramento. A metodologia articulou pesquisa quantitativa, com 97 respondentes, pesquisa qualitativa com discentes de Medicina Veterinária e entrevista com o setor público (Zoonoses de Santo André), além do desenvolvimento e da validação experimental do pipeline cognitivo. Os resultados obtidos evidenciam taxa de aproximadamente 90% de acurácia na classificação fenotípica de raça, taxa superior a 90% na detecção espacial de cães em vídeo e aproveitamento superior a 75% no motor de reidentificação por similaridade, atestando a viabilidade técnica e operacional da abordagem sob restrições reais de orçamento e tempo. O trabalho contribui com uma metodologia replicável de validação cognitiva e demonstra empiricamente o ganho de desempenho proporcionado pela substituição de modelos artesanais por modelos generativos multimodais em tarefas de reconhecimento fino aplicadas a contextos não controlados.

Palavras-chaves: visão computacional. inteligência artificial generativa. YOLOv8. reidentificação de cães. microsserviços.

ABSTRACT

The disappearance of pet dogs in Brazilian urban centers represents a recurring social problem, worsened by the absence of effective technological mechanisms for automated tracking and identification. This work presents *Cão Radar*, an academic prototype of a system for identifying and reidentifying lost dogs, grounded in the combination of classical Computer Vision and Multimodal Generative Artificial Intelligence. The system was designed under a microservices architecture, integrating an Angular/TypeScript web interface, a Java/Spring Boot transactional back-end, and a Python cognitive microservice that combines the YOLOv8 spatial detector with the Google Gemini 2.5 Flash generative model for phenotypic attribute extraction and similarity scoring between loss reports and sightings captured by monitoring cameras. The methodology combined quantitative research with 97 respondents, qualitative research with Veterinary Medicine students, an interview with the public sector (Zoonoses of Santo André), and the development and experimental validation of the cognitive pipeline. The results show approximately 90% accuracy in phenotypic breed classification, a rate above 90% in spatial dog detection in video, and a performance above 75% in the similarity-based reidentification engine, attesting to the technical and operational viability of the approach under real budget and time constraints. The work contributes a replicable methodology of cognitive validation and empirically demonstrates the performance gain provided by replacing handcrafted models with multimodal generative models in fine-grained recognition tasks applied to uncontrolled contexts.

Keywords: computer vision. generative artificial intelligence. YOLOv8. dog reidentification. microservices.

LISTA DE FIGURAS

Figura 1 - Logo do “Cão Radar”	20
Figura 2 - Arquitetura YOLO.....	37
Figura 3 - Gráfico Categorias dos usuários	41
Figura 4 - Gráfico Faixa etária.....	41
Figura 5 - Gráfico Cidades dos entrevistados	42
Figura 6 - Gráfico Frequência de ocorrência do problema	43
Figura 7 - Gráfico Experiência da perda.....	43
Figura 8 - Gráfico Nível de esforço/tempo.....	44
Figura 9 - Gráfico Métodos de busca válidos	45
Figura 10 - Relatos de dificuldades	46
Figura 11 - Gráfico Validação da solução IA	47
Figura 12 - Gráfico Qualidade das fotos.....	48
Figura 13 - Gráfico Capacidade de descrição	49
Figura 14 - Gráfico Frequência de atualizações.....	50
Figura 15 - Gráfico Preocupação com privacidade	51
Figura 16 - Gráfico Prioridade de funcionalidades	52
Figura 17 - Sugestões adicionais	53
Figura 18 - Diagrama de Atividades UML do “Cão Radar”	60
Figura 19 - Diagrama de componentes e integração de microserviços	64
Figura 20 - Diagrama de máquina de estados	65
Figura 21 - Fluxo de Monitoramento	67
Figura 22 - Fluxo do Usuário	69
Figura 23 - Fluxo IA Match	71
Figura 24 - Desenho do banco de dados	72
Figura 25 - Comparativo de acurácia entre o modelo treinado artesanalmente e a IA Generativa	80
Figura 26 - Taxa de identificação de Cães no vídeo pelo YOLO.....	82
Figura 27 - Distribuição de acerto do motor de match (aproveitamento superior a 75%)	84
Figura 28 - Monitor de performance de back-end: pico de RAM - cenário de stress.	89
Figura 29 - Curva de latência em cenário de cold start.....	90

LISTA DE QUADROS

Quadro 1 - Cenários de testes automatizados do back-end.....	87
Quadro 2 - Cenários e resultados dos testes de carga e estresse	88
Quadro 3 - Síntese dos testes funcionais do motor de match	91
Quadro 4 - Pontos técnicos observados no cenário 2 (Cacau)	93

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
API	Application Programming Interface
AQF	Análise de Qualidade do Frame
BLOB	Binary Large Object
CDN	Content Delivery Network
CNN	Convolutional Neural Network
CPU	Central Processing Unit
CSS	Cascading Style Sheets
CVPR	Conference on Computer Vision and Pattern Recognition
FCI	Fédération Cynologique Internationale
GPU	Graphics Processing Unit
HTTP	Hypertext Transfer Protocol
IA	Inteligência Artificial
IDOR	Insecure Direct Object Reference
I/O	Input/Output
JSON	JavaScript Object Notation
JSONB	JavaScript Object Notation Binary
LGPD	Lei Geral de Proteção de Dados Pessoais
LLM	Large Language Model
LTS	Long Term Support
MOT	Multi-Object Tracking
PoC	Proof of Concept
RA	Registro Acadêmico
RAM	Random Access Memory
REST	Representational State Transfer
RF	Requisito Funcional
RGA	Registro Geral do Animal
RMV	Resolução Mínima Viável
RNF	Requisito Não Funcional
SaaS	Software as a Service
SGBD	Sistema Gerenciador de Banco de Dados

SPA	Single Page Application
SRD	Sem Raça Definida
TCC	Trabalho de Conclusão de Curso
UML	Unified Modeling Language
URL	Uniform Resource Locator
USCS	Universidade Municipal de São Caetano do Sul
UUID	Universally Unique Identifier
VC	Visão Computacional
VLM	Vision-Language Model
XSS	Cross-Site Scripting
YOLO	You Only Look Once

SUMÁRIO

1	INTRODUÇÃO	19
1.1	Objetivos	20
1.1.1	Objetivo geral	21
1.1.2	Objetivos específicos.....	21
1.2	Justificativa e escopo do projeto.....	22
1.2.1	Justificativas	22
1.2.2	Escopo e delimitações.....	23
2	REFERENCIAL TEÓRICO.....	25
2.1	Padrões de raça e identificação visual de indivíduos.....	25
2.1.1	Conceito de raça e variabilidade morfológica	25
2.1.2	Implicações visuais para sistemas de reconhecimento	27
2.1.3	Seleção das raças para o protótipo “Cão Radar”	29
2.1.4	Considerações sobre mestiçagem e variação intrarraça.....	30
2.1.5	Considerações finais da seção.....	32
2.2	Desafios computacionais do projeto.....	32
2.2.1	Aquisição e qualidade do frame	33
2.2.2	Ingestão, processamento e persistência	34
2.2.3	Classificação de atributos: raça, porte e coloração	34
2.2.4	Síntese: implicações para o projeto "Cão Radar"	35
2.3	Desenvolvimento de software do projeto	35
2.3.1	Visão computacional e detecção de objetos	36
2.3.2	Redes neurais convolucionais (CNNs) e a arquitetura YOLO	36
2.3.3	Extração de atributos com Modelos de Linguagem Multimodais (VLMs)	38
3	METODOLOGIA	40
3.1	Pesquisa de campo: formulário aberto	40
3.1.1	Categorias dos usuários.....	40
3.1.2	Faixa etária.....	41
3.1.3	Cidades dos respondentes.....	42
3.1.4	Frequência do Problema	42
3.1.5	Proximidade com a perda.....	43
3.1.6	Nível de esforço/tempo.....	44
3.1.7	Métodos de busca válidos	44
3.1.8	Relatos de dificuldades	45

3.1.9	Validação da solução IA	46
3.1.10	Qualidade das fotos	47
3.1.11	Capacidade de descrição	48
3.1.12	Frequência de atualizações	49
3.1.13	Preocupação com privacidade	50
3.1.14	Prioridade de funcionalidades	51
3.1.15	Sugestões adicionais	52
3.1.16	Conclusões do formulário	53
3.2	Pesquisa qualitativa: entrevista - discentes de medicina veterinária....	53
3.2.1	Identificadores visuais fáceis	54
3.2.2	Características padrão em cães	54
3.2.3	Dificultadores na captura de imagem	54
3.2.4	Identificação de outras raças	55
3.2.5	Viabilidade da expansão de raças	55
3.2.6	Causas comuns de fuga	55
3.2.7	Facilitadores e dificultadores da busca atual	56
3.2.8	Validação de recursos de apoio	56
3.2.9	Validação da solução central (IA)	56
3.2.10	Desafios de infraestrutura e câmeras	56
3.2.11	Conclusão da entrevista	57
3.3	Pesquisa qualitativa: entrevista - setor público (zoonoses)	57
3.3.1	Procedimentos e amostra	57
3.3.2	Análise e resultados da entrevista	58
3.3.2.1	Processos atuais de identificação preventiva e reativa	58
3.3.2.2	Gargalos Logísticos e Gestão de Dados	58
3.3.2.3	Validação e receptividade da solução CÃORADAR	59
3.3.2.4	Viabilidade de integração e burocracia	59
3.3.3	Conclusões da entrevista	59
4	DESENVOLVIMENTO	60
4.1	Requisitos do sistema	60
4.1.1	Estórias de usuário	61
4.1.2	Requisitos Funcionais (RF)	61
4.1.3	Requisitos Não Funcionais (RNF)	62
4.3	Desenho da arquitetura do software	63

4.3.3	Camada de IA e visão computacional (Microserviço Isolado)	64
4.3.3.1	Fluxo de Monitoramento (detecção por vídeo)	66
4.3.3.2	Fluxo do Usuário (cadastro de cão perdido).....	68
4.3.3.3	Fluxo de Match (motor de similaridade)	69
4.4	Desenho do projeto de banco de dados	71
4.4.1	Decisões de modelagem e segurança	72
4.4.2	Dicionário e relacionamento de entidades.....	73
4.5	Implementação	74
4.6	Justificativa do modelo cognitivo e abordagens descartadas.....	75
5	TESTES	77
5.1	Cenários e plano de testes	78
5.2	Testes de classificação de raças	79
5.3	Testes de identificação e detecção em vídeo	81
5.4	Testes de reidentificação (match).....	83
5.5	Testes funcionais e de integração	85
5.6	Análise integrada da equipe.....	86
5.6.1	Testes de resiliência, carga e estresse da infraestrutura	86
5.6.2	Testes funcionais do motor de match.....	90
5.6.3	Testes práticos do pipeline de visão computacional	92
5.6.3.1	Cenário 1: Desafios de captura e mudança de domínio	92
5.6.3.2	Cenário 2: Validação de match retroativo e resiliência visual.....	93
5.6.3.3	Cenário 3: Discriminação intrarraça e seleção dinâmica de frames	94
5.6.3.4	Síntese das considerações finais dos testes práticos	95
5.6.4	Síntese integrada	95
6	CONSIDERAÇÕES FINAIS	97
6.1	Síntese do trabalho desenvolvido	97
6.2	Cumprimento dos objetivos	98
6.3	Principais resultados alcançados.....	99
6.4	Contribuições do trabalho.....	99
6.5	Decisões estratégicas e aprendizados técnicos	100
6.6	Limitações reconhecidas.....	101
6.7	Trabalhos futuros	102
6.8	Reflexão final	104
	REFERÊNCIAS.....	105

1 INTRODUÇÃO

O desaparecimento de cães de estimação constitui um problema social recorrente e de elevada gravidade em centros urbanos brasileiros, acarretando impacto emocional, psicológico e financeiro considerável para os tutores e suas famílias. Segundo estimativas de organizações de proteção animal, milhares de cães desaparecem anualmente no território nacional, sendo que parcela significativa desses animais não é reencontrada em razão da ausência de mecanismos tecnológicos eficazes de rastreamento, monitoramento e identificação automatizada. A problemática agrava-se quando se considera que os métodos tradicionais de busca, tais como panfletos impressos, publicações em redes sociais e consultas presenciais a centros de controle de zoonoses, são intrinsecamente reativos, manuais e dependentes do esforço individual do tutor, resultando em baixas taxas de reencontro e em um processo marcado pelo desgaste emocional.

Paralelamente a esse desafio de natureza social, os avanços recentes e exponenciais no campo da Inteligência Artificial (IA) e da Visão Computacional tornaram viável e economicamente acessível o desenvolvimento de soluções tecnológicas que empreguem o reconhecimento automático de imagens para auxiliar ativamente na localização e identificação de animais desaparecidos. Experimentos recentes já demonstram aplicações promissoras de IA para a detecção de animais em vias públicas por meio de câmeras de monitoramento urbano, e a utilização de modelos avançados de detecção de objetos, como a família de arquiteturas YOLO (You Only Look Once), particularmente em sua versão YOLOv8, tem sido amplamente explorada no contexto de vigilância urbana e monitoramento ambiental em tempo real. Ademais, o surgimento dos Grandes Modelos de Linguagem Multimodais (VLMs, Vision-Language Models), capazes de analisar imagens e retornar descrições estruturadas em linguagem natural, abriu um paradigma inteiramente novo para a extração automatizada de características fenotípicas de animais a partir de fotografias e frames de vídeo.

Nesse contexto de convergência entre uma demanda social não atendida e uma oferta tecnológica emergente, justifica-se o desenvolvimento do "Cão Radar", um sistema inteligente de apoio na busca de cães perdidos, concebido como prova de conceito para um futuro serviço integrado a câmeras de monitoramento urbano. Para o presente protótipo acadêmico, utiliza-se um dispositivo celular como câmera

simuladora, embora o conceito preveja escalabilidade futura para integração com infraestruturas de vigilância urbana existentes, como a rede Smart Sanca da cidade de São Caetano do Sul.

O presente Trabalho de Conclusão de Curso (TCC) concentra-se, portanto, na seguinte questão de pesquisa: Como um sistema baseado em Visão Computacional e Inteligência Artificial Generativa pode simular, de forma experimental, a comparação eficaz de imagens de cães perdidos com registros de vídeo capturados em diferentes resoluções, de modo a aferir o grau de assertividade da identificação individual do cão? O desenvolvimento do projeto é pautado pelos objetivos, justificativas e delimitações apresentados nas seções seguintes, e a metodologia empregada combina pesquisa quantitativa (formulário com 97 respondentes), pesquisa qualitativa (entrevistas com especialistas em Medicina Veterinária e representantes do poder público) e desenvolvimento técnico de engenharia de software. A Figura 1 apresenta o logo do projeto “Cão Radar”.

Figura 1 - Logo do “Cão Radar”



Fonte: Autoria própria (2025)

1.1 Objetivos

O projeto "Cão Radar" visa desenvolver uma solução tecnológica inovadora para o desafio social da busca por animais de estimação desaparecidos em ambientes urbanos, explorando o potencial da Inteligência Artificial (IA) aplicada à Visão Computacional. A definição dos objetivos orientou-se pela necessidade de equilibrar

o rigor acadêmico exigido por um Trabalho de Conclusão de Curso com a aplicabilidade prática de uma solução que, embora em caráter de prova de conceito, demonstre viabilidade técnica para escalamento futuro.

1.1.1 Objetivo geral

O objetivo geral deste trabalho é desenvolver um sistema de software baseado em Inteligência Artificial que simule, ainda que de modo experimental e em ambiente controlado, a comparação automatizada de imagens de cães perdidos fornecidas pelos seus tutores com imagens captadas por câmeras de monitoramento simuladas. Essa simulação será direcionada, em um primeiro momento, a cães de algumas raças reconhecidas que possuam um padrão fenotípico determinado, ou de características físicas passíveis de identificação visual, tais como porte, coloração predominante, tipo de pelagem, formato das orelhas e marcações corporais específicas, visando aferir o grau de assertividade da identificação individual do cão por meio de um motor de similaridade baseado em Inteligência Artificial Generativa Multimodal.

1.1.2 Objetivos específicos

Para cumprir o objetivo geral supracitado e validar a viabilidade técnica e social da solução proposta, foram definidos os seguintes objetivos específicos, cada qual representando uma etapa incremental e verificável do processo de desenvolvimento:

a) **Implementação do Sistema de Captura:** Desenvolver e configurar um sistema de captura de imagens de cães utilizando diferentes resoluções de câmeras, incluindo câmeras de monitoramento para uso residencial e câmeras de smartphones, de modo a avaliar o impacto da qualidade do dado de entrada na acurácia do reconhecimento.

b) **Aplicação de Algoritmos de Detecção:** Aplicar algoritmos de Visão Computacional, especificamente o modelo YOLOv8 (You Only Look Once, versão 8), para a detecção automática de cães em imagens e frames de vídeo, incorporando mecanismos de recorte automático (crop) da região de interesse e filtragem de qualidade do frame capturado.

c) **Desenvolvimento do Módulo de Comparação:** Desenvolver um módulo inteligente de comparação entre as imagens e atributos descritivos enviados por

tutores e os registros armazenados no banco de dados do sistema, utilizando Modelos de Linguagem Multimodais (VLMs) para extração de características e cálculo de score de similaridade, retornando possíveis correspondências ordenadas por grau de confiança.

d) **Mensuração da Acurácia:** Medir o grau de acurácia e assertividade da identificação do animal quando a comparação das imagens ocorrer, de modo a minimizar falsos positivos e falsos negativos, estabelecendo métricas quantitativas para avaliação do desempenho do sistema.

e) **Definição de Requisitos Mínimos:** Indicar, por intermédio de simulações e testes controlados, os requisitos mínimos necessários de configuração de hardware, resolução de captura e padrões de qualidade de imagens para o funcionamento adequado do sistema.

1.2 Justificativa e escopo do projeto

1.2.1 Justificativas

A relevância do projeto "Cão Radar" fundamenta-se em três dimensões complementares e mutuamente reforçantes, que convergem para justificar a pertinência acadêmica e social do presente trabalho:

Na dimensão social, o projeto busca contribuir concretamente para a redução do sofrimento emocional e psicológico dos tutores e suas famílias diante do desaparecimento de um animal de estimação, bem como para a diminuição das taxas de abandono animal, fornecendo uma ferramenta tecnológica inovadora e proativa de apoio na busca. Conforme evidenciado pela pesquisa de campo conduzida neste trabalho, 93,7% dos respondentes possuem conexão direta ou empática com a problemática, e 57,3% percebem os métodos atuais de busca como de "alto esforço" e baixa eficácia, reforçando a urgência de uma solução automatizada.

Na dimensão acadêmica, o trabalho explora de forma interdisciplinar o uso de Inteligência Artificial aplicada à Visão Computacional em um problema de relevância urbana e social ainda pouco explorado na literatura nacional, ampliando as discussões acadêmicas sobre ética algorítmica, privacidade em espaços públicos, segurança de dados pessoais e uso responsável de sistemas inteligentes de monitoramento. A integração de técnicas de detecção de objetos (YOLOv8) com modelos generativos

multimodais (Google Gemini) representa uma contribuição original ao estado da arte, particularmente no que tange à extração de características fenotípicas de animais em condições de captura não controladas.

Na dimensão tecnológica, o projeto valida a aplicação prática de algoritmos modernos de detecção de objetos, reconhecimento de imagens e processamento de linguagem natural multimodal em um contexto real de uso, utilizando uma arquitetura de microsserviços que combina ecossistemas heterogêneos (Java/Spring Boot, Python/YOLOv8, Angular/TypeScript) em uma plataforma coesa, escalável e reproduzível. A disponibilização integral do código-fonte em repositório público (GitHub) reforça o compromisso com a ciência aberta e a reprodutibilidade dos resultados.

1.2.2 Escopo e delimitações

O presente trabalho caracteriza-se como um protótipo acadêmico de natureza experimental, configurando-se como uma prova de conceito (PoC, Proof of Concept) com finalidade de validação técnica e científica. O desenvolvimento está circunscrito ao prazo de dois semestres acadêmicos (aproximadamente oito meses) e à utilização prioritária de ferramentas gratuitas, de código aberto e de ampla adoção na comunidade científica e de engenharia de software, tais como Python, PyTorch, OpenCV, YOLOv8, Java, Spring Boot, Angular, PostgreSQL e Docker.

O protótipo utiliza um dispositivo celular como câmera simuladora para validar o conceito operacional, sendo que a integração real e definitiva com as câmeras de monitoramento urbano da rede Smart Sanca da cidade de São Caetano do Sul será apenas simulada no escopo deste TCC. Adicionalmente, o foco principal do trabalho está na validação da pipeline completa de detecção, extração de atributos e comparação por similaridade, e a classificação de atributos pelo modelo generativo contempla um espectro amplo de características fenotípicas (raça, porte, cor, pelagem, anomalias), embora a validação experimental quantitativa concentre-se inicialmente em um conjunto selecionado de cinco raças com alto contraste morfológico.

Reconhece-se que o sistema de comparação por similaridade, por sua própria natureza probabilística e dependente da qualidade dos dados de entrada, poderá apresentar falsos positivos e falsos negativos. A acurácia obtida será limitada pela

disponibilidade de datasets representativos, pelo poder computacional acessível à equipe e pelas condições variáveis de iluminação, resolução e ângulo de captura inerentes ao monitoramento urbano real. Restrições éticas e legais quanto à captura, armazenamento e uso de imagens em espaços públicos, particularmente no que concerne à privacidade de pessoas eventualmente capturadas nos frames, foram consideradas no design do sistema por meio de mecanismos de anonimização automática de humanos.

2 REFERENCIAL TEÓRICO

2.1 Padrões de raça e identificação visual de indivíduos

A identificação visual de um cão por um sistema de Inteligência Artificial depende fundamentalmente da compreensão aprofundada dos seus padrões morfológicos, isto é, das características físicas observáveis que distinguem visualmente um animal de outro. Esta seção aborda os desafios teóricos e as estratégias práticas para o reconhecimento canino automatizado, partindo dos padrões oficiais que definem formalmente uma raça até os problemas práticos e computacionais da identificação de indivíduos específicos em ambientes urbanos não controlados, onde variáveis como iluminação, oclusão, ângulo de captura e resolução da câmera introduzem desafios adicionais de considerável complexidade.

2.1.1 Conceito de raça e variabilidade morfológica

O reconhecimento de raças caninas constitui um problema de classificação de alta complexidade, tanto no campo da cinofilia, a ciência dedicada ao estudo, seleção e criação de cães, quanto na aplicação de técnicas de Inteligência Artificial (IA) para reconhecimento automatizado. A Fédération Cynologique Internationale (FCI), principal órgão internacional de regulamentação e padronização de raças caninas no mundo, reconhece atualmente 356 raças oficiais (FCI, 2022). Cada raça é formalmente definida por um "padrão", um documento técnico detalhado que descreve um conjunto rigoroso de características morfológicas e comportamentais, incluindo proporções corporais, formato e dimensões do crânio, tipo e densidade da pelagem, padrões de coloração aceitos, tamanho e peso esperados, e movimentação típica. Esses atributos visuais, estabelecidos historicamente para preservar a identidade funcional e estética de cada raça, formam o núcleo conceitual do problema de identificação automatizada em imagens e vídeos que o presente trabalho se propõe a endereçar.

Os padrões de raça têm o objetivo fundamental de preservar a morfologia e o temperamento originais de cada linhagem, permitindo a distinção visual inequívoca entre diferentes raças. As raças reconhecidas pela FCI são organizadas em dez grupos principais, definidos conforme porte, estrutura corporal e função histórica

original (Da Silva Melo, 2017): Grupo 1, Cães Pastores e Boiadeiros (exceto os suíços); Grupo 2, Pinscher, Schnauzer, Molossóides e Boiadeiros Suíços; Grupo 3, Terriers; Grupo 4, Dachshunds; Grupo 5, Spitz e tipos Primitivos; Grupo 6, Sabujos, Rastreadores e semelhantes; Grupo 7, Cães de Aponte; Grupo 8, Levantadores, Retrievers e Cães de Água; Grupo 9, Cães de Companhia; e Grupo 10, Galgos (Lébreis). Essa classificação hierárquica reflete não apenas a diversidade biológica canina, mas também oferece uma estrutura taxonomia potencialmente útil para sistemas de classificação computacional que operem em múltiplas escalas de abstração.

A diversidade morfológica canina é resultado direto de processos de seleção artificial conduzidos ao longo de milênios de coevolução entre humanos e cães, orientados por diferentes funções históricas como caça, guarda, companhia, pastoreio e trabalho. Como consequência direta desses processos seletivos, os cães domésticos (*Canis lupus familiaris*) exibem um dos maiores espectros fenotípicos dentro de uma mesma espécie no reino animal, com variação extraordinária de porte (de Chihuahuas com menos de 2 kg a Mastiffs que ultrapassam 90 kg), tipo e textura de pelagem (curta, longa, encaracolada, dupla, ausente), coloração (monocromática, bicolor, tricolor, merle, brindle), e estrutura craniana (dolicocefala, mesocéfala, braquicefala). Essa variabilidade fenotípica amplifica consideravelmente a dificuldade dos algoritmos de reconhecimento visual, pois exige que o sistema computacional aprenda representações suficientemente discriminantes para distinguir raças entre si e, simultaneamente, generalistas o bastante para reconhecer indivíduos dentro de uma mesma categoria, mesmo diante de variações intrarraça significativas.

Fatores ambientais, fisiológicos e contextuais, como idade do animal, estado de tosa, condições de iluminação, postura corporal, estado emocional e ângulo de captura da imagem, introduzem ruído visual adicional que compromete a consistência dos padrões morfológicos esperados. Um Poodle recém-tosado, por exemplo, apresenta uma silhueta radicalmente diferente de um Poodle com pelagem crescida, embora trate-se do mesmo animal. Compreender a origem e a natureza dessa variabilidade multifatorial é, portanto, um passo epistemológico fundamental para o desenvolvimento de soluções de Visão Computacional (VC) robustas e aplicáveis ao contexto real de identificação canina em ambientes urbanos. No contexto específico do projeto "Cão Radar", esse entendimento teórico é essencial para calibrar adequadamente a pipeline de detecção e comparação de imagens, garantindo que o

sistema opere de forma confiável diante da diversidade fenotípica encontrada nas ruas das cidades brasileiras.

2.1.2 Implicações visuais para sistemas de reconhecimento

A distinção entre raças caninas não é apenas um exercício teórico de taxonomia cinológica, mas constitui um fator determinante que influencia diretamente o desempenho prático de sistemas de reconhecimento automatizado baseados em Inteligência Artificial. As Redes Neurais Convolucionais (Convolutional Neural Networks, CNNs), que formam a base arquitetural de praticamente todos os detectores de objetos modernos, aprendem a reconhecer padrões locais de textura, coloração e forma geométrica nos dados de treinamento, compondo gradualmente abstrações visuais de alto nível por meio de suas camadas convolucionais empilhadas (Lecun; Bengio; Hinton, 2015). Assim, raças com traços morfológicos marcantes, consistentes e altamente distintos, como o focinho achatado (braquicéfalo) e as orelhas eretas e proeminentes do Buldogue Francês, ou a pelagem densa, encaracolada e volumosa do Poodle, apresentam características visuais fortemente discriminantes, que facilitam o processo de aprendizado supervisionado e elevam a acurácia do modelo classificador.

Em contraposição, raças com alta variabilidade visual interna (variância intraclasse elevada) ou com características fenotípicas significativamente sobrepostas a outras raças (baixa distância interclasse) tendem a gerar maior dispersão no espaço de representações aprendido pela rede neural, reduzindo a capacidade de separação linear nos espaços de features e comprometendo a precisão da classificação. Em tais cenários, abordagens tradicionais de classificação por categorias mutuamente exclusivas podem apresentar confusão sistemática entre classes visualmente semelhantes, como ocorre frequentemente entre Golden Retriever e Labrador Retriever, ou entre Shih Tzu e Lhasa Apso. Para mitigar esse problema de fronteiras de decisão ambíguas, pesquisas recentes na área de reconhecimento fino de granularidade (fine-grained recognition) propõem estratégias avançadas como a classificação hierárquica, em que o modelo diferencia primeiro grupos gerais (por porte, tipo de pelagem) antes de refinar a decisão em classes específicas, ou a classificação Top-K, que admite múltiplas hipóteses ordenadas por probabilidade em vez de uma resposta categórica única (Cui *et al.*, 2024).

A literatura científica em Visão Computacional aplicada à identificação e classificação de cães demonstra avanços significativos e progressivos com o uso de redes neurais profundas e técnicas de transferência de aprendizado. O Stanford Dogs Dataset (Khao, 2011), composto por 20.580 imagens distribuídas em 120 classes de raças, e o Oxford-IIIT Pet Dataset (Parkhi; Vedaldi; Zisserman, [s.d.]), com 37 classes abrangendo cães e gatos, são amplamente utilizados como benchmarks de referência pela comunidade acadêmica. Trabalhos baseados em transfer learning, técnica que reutiliza redes pré-treinadas em grandes bases genéricas como ImageNet (Deng *et al.*, 2009) e as especializa para o domínio específico de interesse, utilizando arquiteturas como ResNet, EfficientNet e Vision Transformers, alcançam precisão superior a 90% na classificação de raças puras em ambientes fotográficos controlados. No entanto, como demonstram de forma contundente Cui *et al.* (2024), o desempenho desses mesmos modelos pode degradar drasticamente, caindo para menos de 70% de acurácia, em cenários realistas de iluminação adversa, oclusão parcial por objetos urbanos (veículos, pedestres, mobiliário urbano) ou imagens de baixa resolução, condições que são precisamente típicas e predominantes no contexto de monitoramento urbano por câmeras de segurança que o "Cão Radar" se propõe a processar.

Esses resultados empíricos da literatura indicam inequivocamente que o sucesso do reconhecimento canino automatizado em condições reais depende não apenas da sofisticação e acurácia intrínseca do modelo de IA empregado, mas também, e talvez de forma ainda mais crítica, da qualidade do dado de entrada submetido ao modelo. Aspectos técnicos como resolução mínima viável do frame, nitidez da imagem, ângulo de visão (preferencialmente frontal ou lateral), ausência de motion blur (borramento por movimento) e adequação das condições de iluminação tornam-se determinantes incontornáveis para a eficácia operacional do sistema. No caso específico do "Cão Radar", a calibração rigorosa dos parâmetros de resolução e o controle sistemático de qualidade dos frames capturados, implementado por meio de um agente de IA dedicado à filtragem (Agente IA Filtro), constituem etapas obrigatórias e críticas do processo de pré-filtragem, cuja função é evitar que frames inadequados sejam submetidos aos estágios subsequentes da pipeline e comprometam o desempenho global dos classificadores.

Outro aspecto técnico de relevância para o design do sistema é o balanceamento entre classes nos conjuntos de dados de treinamento. Bases de dados

caninas frequentemente apresentam desequilíbrio significativo na distribuição de amostras, com raças populares (como Poodle, Golden Retriever e Labrador) consideravelmente mais representadas do que raças menos comuns (como Schnauzer, Shiba Inu ou Basenji). Essa desproporção numérica induz o modelo a enviesar sistematicamente suas previsões para as classes dominantes, comprometendo a equidade e a confiabilidade das previsões para classes minoritárias. Técnicas de data augmentation (ampliação artificial dos dados por transformações geométricas e fotométricas), oversampling sintético (como SMOTE) e loss functions ponderadas (que penalizam mais fortemente erros em classes sub-representadas) são amplamente utilizadas na literatura para mitigar esse problema de viés por desbalanceamento. No "Cão Radar", a equipe optou estrategicamente por um conjunto reduzido e cuidadosamente balanceado de raças para validação justamente para evitar tal desequilíbrio e priorizar uma análise aprofundada e rigorosa da pipeline completa, em detrimento de uma cobertura superficial de muitas classes.

Em síntese, a variabilidade visual entre raças, a qualidade do dado de entrada e o balanceamento das amostras de treinamento compõem o tripé fundamental de desafios para a detecção e a classificação automática de cães em ambientes não controlados. A compreensão teórica aprofundada desses fatores, conforme apresentada nesta seção, é essencial para a definição informada de parâmetros, estratégias de treinamento, critérios de filtragem e mecanismos de decisão que maximizem a robustez, a confiabilidade e a utilidade prática do sistema proposto.

2.1.3 Seleção das raças para o protótipo "Cão Radar"

Para fins de validação experimental rigorosa da prova de conceito, o projeto "Cão Radar" delimita-se, em sua fase inicial de desenvolvimento e testes, a um conjunto criteriosamente selecionado de cinco raças caninas que apresentam elevado contraste morfológico entre si e ampla disponibilidade de imagens em bases de dados públicas: Buldogue Francês, Poodle, Pastor Alemão, Yorkshire Terrier e Golden Retriever. A seleção dessas raças específicas foi orientada por três critérios metodológicos principais: (i) diversidade morfológica e visual, garantindo que as raças selecionadas apresentem silhuetas, texturas de pelagem e proporções corporais suficientemente distintas para testar a capacidade discriminativa do sistema; (ii) disponibilidade abundante de dados públicos rotulados para treino, validação e

benchmarking nos datasets acadêmicos de referência; e (iii) relevância prática e social, considerando raças comuns e populares em áreas urbanas brasileiras e, portanto, com maior probabilidade de serem objetos de buscas reais.

O Buldogue Francês é caracterizado por seu porte compacto, focinho braquicéfalo (achatado) e orelhas eretas do tipo "morcego", que lhe conferem uma silhueta inconfundível. O Poodle é reconhecido por sua pelagem densa, encaracolada e hipoalergênica, que varia significativamente conforme o estado de tosa. O Pastor Alemão distingue-se pelo porte atlético e robusto, coloração bicolor característica (marrom com preto), orelhas eretas e dorso inclinado. O Yorkshire Terrier apresenta pelos longos, sedosos e finos, com coloração tan e steel blue, e porte miniatura. O Golden Retriever é identificado por sua pelagem dourada e ondulada, aparência robusta e expressão amigável. Essa seleção garante diversidade representativa de tamanho (miniatura, médio, grande), textura de pelagem (curta, longa, encaracolada), coloração (monocromática, bicolor) e estrutura craniana (braquicéfala, mesocéfala, dolicocefala), permitindo testar o sistema em diferentes escalas morfológicas e contextos variados de iluminação.

Ao reduzir deliberadamente o número de classes a serem classificadas, o projeto controla a complexidade computacional do problema, facilita a análise estatística dos resultados e viabiliza uma investigação aprofundada do desempenho do sistema em cada etapa da pipeline, especialmente nas etapas críticas de detecção (YOLOv8), filtragem de qualidade (Agente IA Filtro), seleção da melhor imagem (Agente IA Compara), extração de atributos (Agente IA Classificação) e comparação por similaridade (Agente IA Comparador/Match). Essa limitação é estratégica e metodologicamente justificada, não definitiva. Em etapas futuras de desenvolvimento, o sistema poderá ser expandido para abranger um espectro mais amplo de raças ou mesmo para a identificação individual de animais por meio de embeddings visuais densos, sem necessidade de reclassificação por raça.

2.1.4 Considerações sobre mestiçagem e variação intrarraça

Um dos desafios mais expressivos e tecnicamente complexos para a aplicação prática de sistemas de reconhecimento de cães em ambientes urbanos reais é a mestiçagem, fenômeno particularmente relevante e predominante em centros urbanos brasileiros. Cães sem padrão racial definido (SRD), comumente denominados "vira-

latas", resultam de cruzamentos múltiplos e sucessivos entre diferentes raças e linhagens, apresentando combinações imprevisíveis e únicas de características visuais, como coloração híbrida, proporções corporais intermediárias, variações cranianas atípicas e padrões de pelagem não padronizados. Essa variabilidade fenotípica extrema inviabiliza fundamentalmente a abordagem clássica de classificação fechada por categorias fixas e mutuamente exclusivas, já que um modelo supervisionado treinado exclusivamente em raças puras não possui classes adequadas para representar essa diversidade combinatória virtualmente infinita.

Pesquisas sobre fine-grained classification na literatura especializada apontam que a presença de mestiços nos dados de teste gera alta sobreposição interclasse e ambiguidade nas fronteiras de decisão, dificultando severamente a convergência dos classificadores tradicionais (Arava; Yang; Yuan, [s.d.]). Modelos treinados exclusivamente em raças puras tendem sistematicamente a falhar ao identificar cães mestiços, classificando-os incorretamente como a raça mais visualmente próxima em seu espaço de representações, independentemente de quão divergente o animal real seja. Para contornar essa limitação fundamental, o "Cão Radar" adota uma abordagem arquitetural inovadora de extração de atributos fenotípicos individuais em vez de uma classificação direta em categorias fixas. Essa estratégia decompõe a tarefa monolítica de "classificar a raça" em subtarefas independentes e mais tratáveis, como estimar porte (pequeno, médio, grande), cor predominante, tipo de pelagem (curta, longa, encaracolada), formato das orelhas (eretas, caídas), formato do focinho e presença de marcações corporais específicas, e, a partir desses atributos estruturados, infere raças prováveis como um atributo secundário, não como a variável primária de decisão.

Essa abordagem de extração de atributos é implementada tecnicamente por meio de Modelos de Linguagem Multimodais (Vision-Language Models, VLMs), detalhados na seção 2.3, que são capazes de combinar informações visuais provenientes da imagem do animal com instruções textuais fornecidas por prompt engineering. O sistema é instruído, via prompts cuidadosamente elaborados, a descrever detalhadamente a aparência do animal e retornar um pacote estruturado de atributos em formato JSON, em vez de uma única classe categórica. Essa solução é substancialmente mais robusta à variabilidade fenotípica inerente à população canina urbana brasileira, onde os cães SRD representam a maioria dos animais, e reflete com muito maior fidelidade a diversidade real encontrada nas ruas.

Além de lidar de forma mais eficaz com a mestiçagem, a estratégia de extração de atributos individuais permite comparações semânticas flexíveis e graduais no motor de match. Assim, o sistema pode identificar similaridades significativas entre um cão perdido descrito pelo tutor como "pequeno, pelagem clara, orelhas eretas, mancha escura no olho esquerdo" e outro animal detectado pelo monitoramento com características equivalentes, mesmo que a raça exata de nenhum dos dois seja conhecida com certeza. Essa flexibilidade semântica é precisamente o que torna o "Cão Radar" aplicável à realidade brasileira, onde a maioria dos cães que se perdem não pertence a raças puras catalogadas.

2.1.5 Considerações finais da seção

Compreender em profundidade os padrões morfológicos e visuais das raças caninas vai muito além da mera descrição biológica ou taxonômica: trata-se de um componente epistemológico essencial para o desenho, calibração e validação de modelos de Visão Computacional voltados à detecção e identificação de cães em ambientes urbanos. O domínio aprofundado dessas características, forma corporal, textura e tipo de pelagem, padrões de coloração e silhueta geral, orienta tanto a seleção criteriosa das raças utilizadas nos testes experimentais quanto a definição dos parâmetros de extração, filtragem e comparação de atributos que governam o funcionamento do motor de similaridade.

Ao integrar de forma sinérgica os princípios fundamentais da cinologia com as técnicas de ponta da Inteligência Artificial e da Visão Computacional, o "Cão Radar" busca equilibrar rigor técnico-científico e aplicabilidade social concreta, contribuindo para a criação de um sistema mais robusto, ético e aderente à complexa realidade urbana brasileira, onde a diversidade canina, em toda sua riqueza fenotípica, constitui simultaneamente o maior desafio e a maior motivação para este trabalho.

2.2 Desafios computacionais do projeto

A implementação do "Cão Radar", um Sistema como Serviço (SaaS) que integra Visão Computacional com análise de vídeo proveniente de câmeras urbanas, envolve desafios técnicos interligados e mutuamente dependentes nas áreas de aquisição de vídeo, processamento e armazenamento de grandes volumes de dados

multimídia e classificação robusta de atributos visuais em condições adversas. Esta seção apresenta os problemas computacionais centrais, as implicações arquitetônicas decorrentes e as estratégias de mitigação propostas, fundamentadas em literatura científica atualizada e em práticas consolidadas de engenharia de sistemas distribuídos.

2.2.1 Aquisição e qualidade do frame

O desempenho de toda a pipeline de processamento do "Cão Radar" depende criticamente, e de forma determinística, da qualidade do dado de entrada, ou seja, dos frames de vídeo capturados pelas câmeras de monitoramento. Em cenários urbanos reais, múltiplas variáveis ambientais e técnicas degradam a informação visual contida nos frames: oclusão parcial ou total por pedestres, veículos e mobiliário urbano; motion blur (borramento por movimento), causado pelo deslocamento rápido do animal ou vibração da câmera; baixa iluminação em horários noturnos ou em condições meteorológicas adversas (chuva, neblina); e variação de escala decorrente da distância variável entre o animal e a câmera. Cada uma dessas variáveis, isoladamente ou em combinação, pode comprometer fatalmente a capacidade de o sistema detectar e classificar corretamente o animal.

A literatura especializada propõe diversas técnicas para mitigação parcial dessas degradações. Ocultações parciais por objetos urbanos exigem o emprego de técnicas de Multi-Object Tracking (MOT) para manter a identidade de rastreamento do animal mesmo após breves perdas de visibilidade (Zhang *et al.*, 2021). O motion blur pode ser parcialmente corrigido com modelos de deblurring neural, como o DeblurGAN-v2, aplicados como etapa de pré-processamento antes da submissão ao detector (Kupyn *et al.*, 2019). Para lidar de forma sistemática com a variação de escala e as condições de iluminação adversas, que podem tornar a classificação inviável, o "Cão Radar" implementa um Módulo de Análise de Qualidade do Frame (AQF), materializado no sistema como o Agente IA de Filtro. Esse módulo avalia métricas objetivas de qualidade (como nitidez, resolução efetiva, área relativa do objeto no frame e distribuição tonal) e descarta automaticamente frames que não atinjam a Resolução Mínima Viável (RMV), evitando a introdução de dados ruidosos nos estágios subsequentes da pipeline.

2.2.2 Ingestão, processamento e persistência

A operação contínua de um sistema de monitoramento por câmeras de vídeo (24 horas por dia, 7 dias por semana) produz um fluxo massivo e ininterrupto de dados multimídia, impondo requisitos estridentes de latência de processamento, resiliência a falhas e controle rigoroso de custos operacionais e de armazenamento. A arquitetura do sistema deve priorizar o processamento na borda (edge computing), realizando a triagem inicial e a detecção de cães o mais próximo possível da fonte de dados para reduzir latência e tráfego de rede, enviando ao ambiente de nuvem (cloud) apenas os eventos relevantes, isto é, apenas os frames nos quais um cão foi efetivamente detectado (Hu *et al.*, 2023).

A persistência dos dados extraídos deve adotar uma estratégia híbrida: metadados estruturados (localização geoespacial via coordenadas de latitude e longitude, timestamp de detecção, atributos fenotípicos em formato JSON, identificadores de câmera e scores de similaridade) devem residir em um Sistema Gerenciador de Banco de Dados Relacional (SGBD) com suporte nativo a dados semiestruturados e geoespaciais (PostgreSQL com tipo JSONB); enquanto os objetos binários pesados (imagens de alta resolução, tanto os frames completos quanto os recortes isolados dos animais) devem ser armazenados em serviços de Cloudinary, plataforma de armazenamento e distribuição de mídias em nuvem, implementando políticas de lifecycle para otimização dos custos de armazenamento a longo prazo.

2.2.3 Classificação de atributos: raça, porte e coloração

Classificar raça, porte e coloração em imagens capturadas in the wild, isto é, em condições não controladas de iluminação, ângulo e resolução, é um problema de reconhecimento fino de granularidade (fine-grained recognition), significativamente agravado pela presença majoritária de cães mestiços (SRD), pela variabilidade de pose e ângulo de captura e pela frequente baixa resolução dos frames de câmeras de monitoramento urbano. Classificadores tradicionais treinados exclusivamente em raças puras em condições de estúdio (Khao, 2011; Parkhi; Vedaldi; Zisserman, [s.d.]) tendem a falhar sistematicamente nesse cenário realista, produzindo classificações incorretas e de baixa confiança.

Estratégias mais robustas para esse domínio envolvem modelos que forneçam saídas Top-K (as K raças mais prováveis, ordenadas por confiança) ou multi-label (combinação simultânea de múltiplas características independentes) (Arava; Yang; Yuan, [s.d.]). Além disso, o treinamento com data augmentations que simulem condições adversas reais (sujeira na lente, variações de iluminação, recortes parciais, diferentes ângulos de visão) aumenta a resiliência do modelo a essas condições. Sugere-se, e o "Cão Radar" implementa, uma arquitetura hierárquica de classificação, na qual o sistema primeiro estime atributos genéricos de alto nível (porte, tipo de pelagem, coloração predominante, silhueta geral) e, condicionalmente, acione um classificador mais refinado de raça específica apenas quando a Resolução Mínima Viável for atendida e a confiança nos atributos de primeiro nível for suficientemente alta (Cui *et al.*, 2024).

2.2.4 Síntese: implicações para o projeto "Cão Radar"

A conjunção dos desafios computacionais apresentados nas subseções anteriores demanda um projeto de engenharia de software que balanceie cuidadosamente precisão de detecção e classificação, latência de processamento e custo operacional. Em termos práticos, as decisões arquiteturais adotadas no "Cão Radar" incluem: implementação do módulo de Análise de Qualidade do Frame (AQF) como primeiro estágio da pipeline de IA; adoção de uma estratégia de persistência híbrida (PostgreSQL com JSONB para metadados estruturados e semiestruturados; Cloudinary para armazenamento de imagens e vídeos em nuvem); e design do motor de IA de classificação para saídas Top-K e multi-label, priorizando a extração de atributos fenotípicos individuais sobre a classificação direta em categorias de raça. Essas escolhas orientam a metodologia experimental deste TCC e servem como critérios fundamentais para a seleção de tecnologias, a construção de datasets de teste e a definição de métricas de avaliação do sistema.

2.3 Desenvolvimento de software do projeto

O núcleo funcional do projeto "Cão Radar" reside na aplicação sinérgica de técnicas de Inteligência Artificial (IA) para processar e interpretar dados visuais provenientes de câmeras de monitoramento urbano. O objetivo de detectar

automaticamente cães em ambientes urbanos e, subsequentemente, comparar suas características fenotípicas extraídas com um banco de dados de animais desaparecidos enquadra-se no campo da Visão Computacional (VC). Esta seção detalha os fundamentos teóricos das duas tecnologias-chave que sustentam o sistema: a detecção de objetos baseada em redes neurais convolucionais profundas e a extração de atributos por meio de Modelos de Linguagem Multimodais.

2.3.1 Visão computacional e detecção de objetos

Visão Computacional é uma subárea da ciência da computação e da Inteligência Artificial que busca replicar, modelar e, em última instância, superar a capacidade humana de "ver" e interpretar informações visuais contidas em imagens digitais e sequências de vídeo. Diferentemente do simples processamento digital de imagens, que se limita a transformações geométricas, ajustes de contraste e operações de filtragem, a Visão Computacional envolve a extração semântica de informações de alto nível e a tomada de decisões automatizadas baseadas na compreensão contextual dos dados visuais (Szeliski, 2010). Uma de suas tarefas mais fundamentais e amplamente estudadas é a detecção de objetos, que consiste não apenas em classificar um objeto presente na cena (ex.: "isto é um cão"), mas também em localizar com precisão sua posição exata dentro da imagem, geralmente por meio de uma "caixa delimitadora" (bounding box) definida por coordenadas retangulares.

No contexto específico do "Cão Radar", a detecção de objetos constitui a primeira etapa crítica e indispensável da pipeline de análise. É esta etapa que permite ao sistema filtrar automaticamente o fluxo volumoso de frames de vídeo e identificar seletivamente apenas os frames que contêm um cão, isolando-o visualmente do cenário urbano de fundo (pedestres, veículos, árvores, construções) para posterior análise aprofundada de raça, porte, coloração e características fenotípicas específicas.


2.3.2 Redes neurais convolucionais (CNNs) e a arquitetura YOLO

A revolução na precisão e na velocidade da detecção de objetos nas últimas décadas foi impulsionada fundamentalmente pelo Deep Learning, e mais especificamente pelas Redes Neurais Convolucionais (Convolutional Neural

Networks, CNNs). As CNNs são arquiteturas especializadas de redes neurais artificiais projetadas para processar dados que possuem uma topologia de grade regular, como imagens bidimensionais. Sua característica distintiva é a capacidade de aprender automaticamente hierarquias progressivas de características visuais, desde filtros de baixo nível, que detectam bordas, cantos e texturas simples nas primeiras camadas, até representações abstratas complexas de formas, objetos e cenas inteiras nas camadas mais profundas da rede (Lecun; Bengio; Hinton, 2015).

Dentro do vasto ecossistema de arquiteturas de detecção de objetos baseadas em CNNs, a família de modelos YOLO (You Only Look Once) destaca-se como uma das mais influentes e amplamente adotadas, particularmente em aplicações que demandam processamento em tempo real. Proposta originalmente por Redmon *et al.* (2016), a arquitetura YOLO (Figura 2) reformulou radicalmente o paradigma de detecção ao tratar o problema como uma tarefa unificada de regressão, em vez de abordá-lo como um pipeline serial de múltiplos estágios (como ocorria nas abordagens anteriores baseadas em R-CNN). A rede YOLO analisa a imagem inteira de uma única passagem (single forward pass) e prediz simultaneamente todas as caixas delimitadoras e suas respectivas probabilidades de classe em uma única inferência, o que a torna extremamente rápida, frequentemente atingindo dezenas de frames por segundo em hardware modesto, e, portanto, adequada para cenários de processamento em tempo real ou quase-real.

Figura 2 - Arquitetura YOLO



Fonte: <https://visaocomputacional.com.br/yolo-versoes-3-e-4-arquitetura/>

O projeto "Cão Radar" opta pela utilização de uma das implementações mais modernas e otimizadas desta família de modelos: o YOLOv8, desenvolvido e mantido pela Ultralytics (Ultralytics, [2025?]). O YOLOv8 representa o estado da arte

contemporâneo em equilíbrio entre velocidade de inferência e acurácia de detecção, incorporando avanços arquiteturais como backbone CSPDarknet otimizado, cabeças de detecção anchor-free e técnicas de treinamento avançadas. No contexto do "Cão Radar", o YOLOv8 é empregado como o primeiro estágio da pipeline de IA (denominado "IA 1" ou "Estágio de Detecção Espacial"), sendo responsável exclusivamente por identificar a presença e a localização de cães nos frames de vídeo e realizar o recorte automático (crop) da região de interesse, delegando a tarefa mais complexa de classificação e extração de atributos ao segundo estágio da pipeline.

2.3.3 Extração de atributos com Modelos de Linguagem Multimodais (VLMs)

Após a detecção e o recorte do cão pelo YOLOv8 (IA 1), o desafio subsequente e qualitativamente mais complexo é implementar o "Módulo de Comparação" (IA 2), responsável por extrair características fenotípicas estruturadas do animal detectado e compará-las com os registros de cães perdidos cadastrados pelos tutores. Para fins acadêmicos e em consonância com os avanços mais recentes e disruptivos da área, este projeto propõe e implementa o uso de Modelos de Linguagem de Grande Escala (*Large Language Models*, LLMs) pré-treinados com capacidades multimodais, também conhecidos na literatura como Vision-Language Models (VLMs).

A diferença fundamental entre um VLM e um modelo de classificação tradicional de imagens reside na natureza e na riqueza de sua saída: enquanto um classificador convencional apenas retorna uma etiqueta categórica (ex.: "Poodle") ou um vetor de probabilidades sobre classes fixas, os VLMs são capazes de analisar uma imagem em conjunto com instruções textuais complexas e responder a perguntas abertas e detalhadas sobre ela em linguagem natural. Para o "Cão Radar", a imagem do cão, previamente recortada e isolada do cenário urbano pela detecção do YOLOv8, é fornecida ao modelo VLM juntamente com um prompt de engenharia cuidadosamente elaborado (instrução textual estruturada) que solicita a extração sistemática dos atributos visuais relevantes para a identificação.

O prompt estruturado solicita ao modelo que retorne, em formato JSON rigorosamente tipado, um conjunto abrangente de atributos fenotípicos, incluindo: raça provável (ou raças mais prováveis, no caso de mestiços), cor predominante, padrão de coloração, tipo e comprimento de pelagem, porte estimado, formato das orelhas, formato do focinho, e quaisquer marcações corporais visíveis (manchas, cicatrizes,

coleira, acessórios). A resposta do modelo, formatada em JSON, constitui os metadados estruturados que serão persistidos no banco de dados PostgreSQL na coluna de tipo JSONB. O "Módulo de Comparação", portanto, não realiza uma busca por similaridade de vetores de imagem (image embeddings), mas sim uma consulta estruturada e semanticamente rica que compara os atributos descritivos fornecidos pelo tutor no formulário de relato de perda com os atributos extraídos automaticamente pelo VLM a partir das capturas de monitoramento.

3 METODOLOGIA

3.1 Pesquisa de campo: formulário aberto

Para validar quantitativamente a percepção do problema, a relevância da solução CÃORADAR e os requisitos de funcionalidade, foi aplicado um formulário online. A pesquisa foi conduzida de forma aberta dos dias 04/11 até 11/11, resultando em um total de 97 respostas: Questionário - CÃORADAR.

O instrumento foi estruturado com perguntas fechadas (escalas Likert de cinco pontos e questões de múltipla escolha) e duas questões discursivas opcionais destinadas à coleta de relatos qualitativos complementares. A amostragem caracteriza-se como não probabilística por conveniência, com divulgação por canais digitais abertos e sem critérios de elegibilidade restritivos além da maioria do respondente. A análise dos dados quantitativos baseou-se em estatística descritiva, com cálculo de frequências absolutas e relativas para cada questão fechada; os dados das questões discursivas foram submetidos à análise temática, com identificação de categorias recorrentes nos relatos de busca e nas sugestões adicionais. Como critério de validação amostral, adotou-se a presença majoritária de público diretamente afetado pelo problema (tutores e profissionais de áreas afins), condição satisfeita conforme análise apresentada na Seção 3.1.1.

3.1.1 Categorias dos usuários


A maior parte dos participantes (77,3%) se identifica como tutores de cães, mostrando que o público respondente tem experiência direta com o tema. As demais categorias apareceram em porcentagens bem menores, distribuindo-se entre profissionais da área veterinária, agentes públicos, estudantes, pessoas que desejam ter pet, pessoas sem pet ou sem envolvimento direto (Figura 3).

Figura 3 - Gráfico Categorias dos usuários

1) Qual das categorias abaixo melhor descreve seu *principal* envolvimento com o tema?

 Copiar gráfico

97 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

Isso indica que a amostra é majoritariamente composta por tutores, justamente o grupo mais impactado pelo problema estudado.

3.1.2 Faixa etária


A maior parte dos respondentes está na faixa de 14 a 28 anos, representando 54,6% da amostra. Em seguida, aparecem as faixas 29 a 44 anos (24,7%) e 45 a 60 anos (13,4%). Apenas 7,2% têm entre 61 e 80 anos, enquanto as faixas “até 13 anos” e “acima de 80 anos” não tiveram participação relevante. Esses dados mostram que o público é predominantemente jovem adulto, com maior engajamento entre pessoas de 14 a 44 anos (Figura 4).

Figura 4 - Gráfico Faixa etária

2) Qual é a sua faixa etária?

 Copiar gráfico

97 respostas




Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.3 Cidades dos respondentes

A maioria dos participantes reside no ABC Paulista, com destaque para São Bernardo do Campo, que representa 33% das respostas, seguido por Santo André, com 23,7%. Também há participação relevante de moradores da cidade de São Paulo, que correspondem a 17,5% da amostra. As demais cidades, como São Caetano do Sul, Diadema, Mauá, Ribeirão Pires e Rio Grande da Serra, aparecem com percentuais menores, porém ainda contribuem para a diversidade regional da pesquisa. Esses resultados indicam que o público está concentrado na região metropolitana que seria diretamente impactada e potencialmente beneficiada por um sistema como o CÃORADAR (Figura 5).

Figura 5 - Gráfico Cidades dos entrevistados



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.4 Frequência do Problema


A análise da percepção de frequência do problema revela que a maioria dos respondentes (53,6%) considera a perda de animais de estimação um evento frequente (nota 4, com 33%) ou muito frequente (nota 5, com 20,6%) em sua cidade. Essa percepção majoritária contrasta com os 24,8% que avaliam o problema como pouco frequente (notas 1 e 2) e os 21,6% que se mantêm neutros (nota 3). Estes dados validam empiricamente a justificativa social do projeto, demonstrando que o desafio abordado pelo CÃORADAR é uma preocupação real e significativa para o público pesquisado (Figura 6).

Figura 6 - Gráfico Frequência de ocorrência do problema

4) Na sua opinião, a perda de animais de estimação é um problema frequente na sua cidade?

[Copiar gráfico](#)

97 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.5 Proximidade com a perda

A pesquisa sobre a proximidade dos respondentes com o tema revela que a grande maioria (76,2%) possui uma conexão direta ou próxima com a perda de um animal. Esse número é composto por 51,5% que conhecem familiares ou amigos que passaram pela experiência e 24,7% que já vivenciaram pessoalmente o desaparecimento de um pet em mais de uma ocasião. Adicionalmente, 17,5% dos participantes, mesmo sem proximidade com o fato, afirmaram se colocar "perfeitamente nesta posição". Somados, 93,7% dos entrevistados (seja por experiência direta, indireta ou empatia) validam a relevância emocional e social do problema, reforçando a urgência de uma solução como a proposta pelo CÃORADAR (Figura 7).

Figura 7 - Gráfico Experiência da perda

5) Você conhece alguém ou já passou pela experiência do seu pet se perder fora de casa?

[Copiar](#)

97 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.6 Nível de esforço/tempo


Questionados sobre o esforço e tempo despendidos na busca por um animal perdido, 37,5% dos respondentes selecionaram a opção "Alto esforço e bastante tempo empreendido", sendo esta a maior fatia. Além disso, 19,8% indicaram "Alto esforço, porém em um curto espaço de tempo", o que totaliza 57,3% dos participantes que percebem o processo como de "alto esforço". Em contrapartida, 24% não opinaram ou nunca passaram pela situação, e as demais categorias de esforço mediano ou baixo representam fatias menores. Estes dados sugerem que os métodos tradicionais de busca são amplamente percebidos como árduos e ineficientes, reforçando a justificativa tecnológica do CÃORADAR como uma solução necessária para otimizar e reduzir o desgaste desse processo (Figura 8).

Figura 8 - Gráfico Nível de esforço/tempo

6) Se já viveu a situação de perda ou se identifica com este cenário, qual foi o nível de esforço e tempo necessário para encontrar o animal perdido?

 Copiar

96 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.7 Métodos de busca válidos

A investigação sobre os métodos de busca validados (96 respostas) demonstra que o ecossistema de ferramentas atual é reativo e dependente do esforço manual do tutor. A "Divulgação em redes sociais" (97,9%) surge como o método quase universal, indicando que a busca se inicia em canais digitais amplos, mas não especializados

em rastreamento. Em complemento, os métodos tradicionais, físicos e de alto esforço manual ainda são amplamente validados, incluindo "Divulgação em Pet Shops" (74%), "Panfletos impressos" (66,7%) e "Faixas/cartazes" (60,4%). Mesmo os "Sites/Applicativos específicos" (65,6%), embora validados, representam no cenário atual ferramentas passivas (como murais de anúncios). Esse cenário revela que não há uma solução tecnológica proativa e automatizada, validando a lacuna de mercado para uma ferramenta como o CÃORADAR, que propõe inverter essa lógica, de uma busca manual para uma busca ativa e inteligente (Figura 9).

Figura 9 - Gráfico Métodos de busca válidos



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.8 Relatos de dificuldades

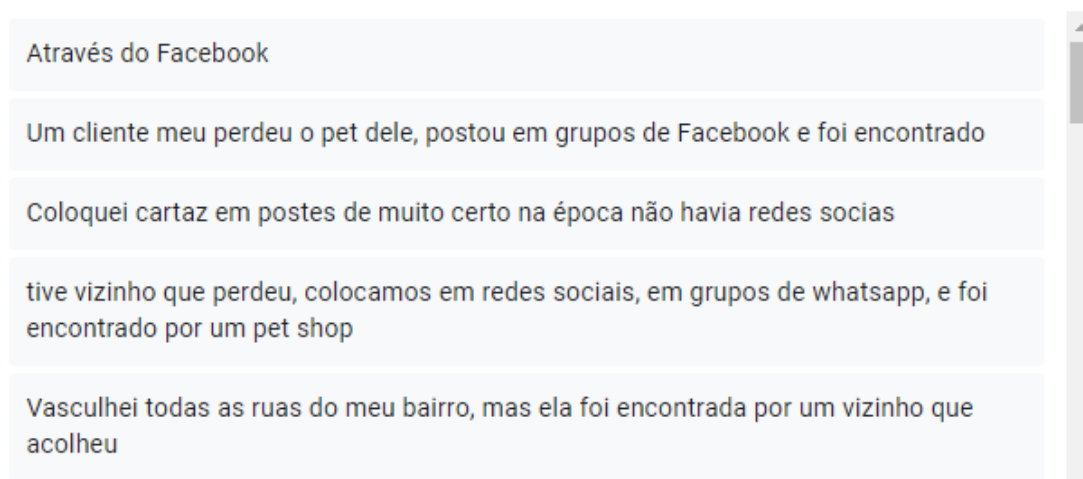
A análise dos 52 relatos qualitativos, provenientes da questão discursiva opcional, aprofunda a compreensão das metodologias de busca atuais e suas principais dificuldades. Os respondentes relatam que os maiores desafios são a desorientação espacial ("não saber para qual direção o cachorro [foi]", "dificuldade em prever onde... poderia ter ido") e a ineficiência temporal ("a busca foi longa, pois tínhamos informações antigas"). Os métodos de busca descritos são invariavelmente manuais, reativos e de alto esforço, como "vasculhar todas as ruas", "procurar de

carro", e a mobilização de "redes sociais", "grupos de whatsapp" e "cartazes". Os relatos de reencontro bem-sucedido frequentemente dependem da sorte ou da intervenção da comunidade ("vizinho que acolheu", "portaria... ligou", "veterinária... reconheceu"), enquanto vários casos terminam em fracasso ("não obtive sucesso", "nunca mais voltou"). Notavelmente, um relato mencionou o uso de câmeras privadas para "ver em que direção ele tinha ido" validando a premissa central do CÃORADAR. Em suma, os relatos descrevem um processo estressante, manual e de baixa eficiência, reforçando a lacuna que uma solução de monitoramento proativo pode preencher (Figura 10).

Figura 10 - Relatos de dificuldades

8) Caso tenha experiência própria ou próxima, descreva brevemente como a busca e o reencontro ocorreram (ou quais foram as maiores dificuldades)

52 respostas



A screenshot of a survey interface showing five responses to a question about pet reunions. The responses are listed in a scrollable container with a vertical scrollbar on the right. Each response is in a light blue box with rounded corners.

- Através do Facebook
- Um cliente meu perdeu o pet dele, postou em grupos de Facebook e foi encontrado
- Coloquei cartaz em postes de muito certo na época não havia redes sociais
- tive vizinho que perdeu, colocamos em redes sociais, em grupos de whatsapp, e foi encontrado por um pet shop
- Vasculhei todas as ruas do meu bairro, mas ela foi encontrada por um vizinho que acolheu

Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.9 Validação da solução IA

Ao avaliar a receptividade da solução central do projeto, a pesquisa questionou se um sistema/App com IA integrado a câmeras de vigilância "facilitaria drasticamente a busca". Os dados demonstram uma validação massiva da proposta do CÃORADAR: 91,7% dos 96 respondentes (88 pessoas) concordaram totalmente (nota 5) que a solução traria um benefício drástico. Somando-se aos 7,3% (7 pessoas) que deram nota 4, um total de 99% do público enxerga um alto valor na solução. Com apenas 1% de discordância (nota 1) e 0% de neutralidade, este resultado confirma de forma


contundente a aceitação e a relevância da hipótese tecnológica do trabalho, indicando um alinhamento direto entre a solução proposta e a necessidade percebida pelo público (Figura 11).

Figura 11 - Gráfico Validação da solução IA

9) Acha que um sistema/App integrado com as câmeras de vigilância de sua cidade, utilizando IA para reconhecer traços do cão, facilitaria drasticamente a busca?

 Copiar

96 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.10 Qualidade das fotos

Para validar a viabilidade técnica da entrada de dados no sistema, a pesquisa avaliou se os tutores possuem o material necessário para o CÃORADAR. Os resultados indicam uma forte prontidão do público: a grande maioria dos respondentes, 67,7%, afirmou possuir "várias fotos de boa qualidade" de seus cães. Somando-se aos 12,5% que possuem fotos de "qualidade média", 80,2% do total de entrevistados teria imagens utilizáveis para o sistema. Em contraste, apenas 3,1% indicaram não ter fotos adequadas (16,7% não possuem cão atualmente). Este dado é crucial, pois confirma que a premissa de input do projeto é viável, demonstrando que a maioria dos tutores pode fornecer os dados de qualidade que o algoritmo de IA necessita para operar (Figura 12).

Figura 12 - Gráfico Qualidade das fotos



10) Para maior precisão do CAORADAR, o sistema necessita de fotos claras. Você possui fotos recentes do seu cão, que mostrem suas características (cor, marcas, manchas)?

96 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.11 Capacidade de descrição


A confiança dos tutores em fornecer dados descritivos para o sistema também foi avaliada, complementando a análise sobre a entrada de fotos. Os resultados mostram que 67% dos 94 respondentes (63 pessoas) autoavaliaram com nota máxima (5) sua capacidade de descrever detalhadamente as características físicas de seus cães (manchas, cicatrizes, etc.). Somando-se aos 14,9% (nota 4), 81,9% do público sente-se confiante em prover esta informação. Este dado valida a premissa de que os usuários são uma fonte de input de atributos de alta qualidade, o que é fundamental para a precisão dos algoritmos de filtragem e comparação do CÃORADAR (Figura 13).

Figura 13 - Gráfico Capacidade de descrição



11) Se o seu cão se perdesse, em uma escala de 1 a 5, quão detalhadamente você conseguiria descrever suas características físicas (manchas, cicatrizes, cor exata do pelo, etc.) para um sistema de busca?

94 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.12 Frequência de atualizações


A definição dos requisitos de usabilidade do sistema foi avaliada pela expectativa de frequência de atualizações. Os resultados indicam uma demanda clara por monitoramento proativo, com 59,8% dos 97 respondentes esperando atualizações em "tempo real/alta frequência" (a cada 15-30 minutos). Esta é a expectativa majoritária, seguida por 17,5% que esperam atualizações a cada 1-2 horas. As frequências mais baixas, como "Apenas 2-3 vezes ao dia" (16,5%) e "Apenas uma vez ao dia" (fatia verde), representam uma minoria. Esta forte preferência por um sistema de alta frequência define um requisito técnico e de desempenho crucial para o CÃORADAR, alinhando a arquitetura do projeto à principal necessidade do usuário em um momento de angústia (Figura 14).

Figura 14 - Gráfico Frequência de atualizações

12) Caso você utilizasse um sistema de busca por IA como o CÃORADAR (sistema inteligente com IA que busca auxiliar o tutor na busca de seu cão **perdido** com monitoramento de câmeras), com que frequência você esperaria receber atualizações sobre o monitoramento do seu cão nas vias públicas?

 Copiar

97 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.13 Preocupação com privacidade


A análise sobre as preocupações éticas de privacidade, um dos pontos de delimitação do projeto, demonstra que a maioria do público não vê o uso de câmeras como um impeditivo. A maioria absoluta dos 97 respondentes (56,7%) indicou a nota 1, o nível mais baixo de preocupação. Somando as notas 1 e 2, um total de 67% do público demonstra baixa preocupação com o tema. Em contrapartida, 20,6% (soma das notas 4 e 5) expressaram alta preocupação, enquanto 12,4% se mantiveram neutros (nota 3). Os dados indicam que, embora a preocupação com a privacidade exista e deva ser tratada (como previsto no objetivo de anonimização de humanos), ela não é uma barreira para a maioria dos usuários, que prioriza a eficácia da busca (Figura 15).

Figura 15 - Gráfico Preocupação com privacidade

13) Em uma escala de 1 a 5, quão preocupado(a) você estaria com a privacidade (uso de câmeras públicas para monitorar animais) ao utilizar um serviço como o CAORADAR?

 Copiar

97 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.14 Prioridade de funcionalidades


A priorização de funcionalidades, onde os 97 respondentes podiam selecionar as 3 mais importantes, revela um claro alinhamento com a principal proposta de valor do projeto. A funcionalidade "Match" por IA: Pareamento...', que representa o núcleo tecnológico do CÃORADAR, foi destacada como a mais importante, sendo selecionada por 71,1% dos participantes. Em segundo e terceiro lugar, respectivamente, figuram o "Mapa de Avistamento" (62,9%) e o "Perfil Preventivo do Pet" (54,6%). Esta hierarquia de preferência é fundamental, pois valida que o investimento em Visão Computacional é a maior demanda do usuário, seguida por ferramentas de visualização de dados (mapa) e preparação (perfil preventivo) (Figura 16).

Figura 16 - Gráfico Prioridade de funcionalidades

14) Selecione as 3 funcionalidades mais importantes na sua opinião que potencialmente poderíamos ter

 Copiar

97 respostas



Fonte: Questionário - Pesquisa para TCC – CÃORADAR

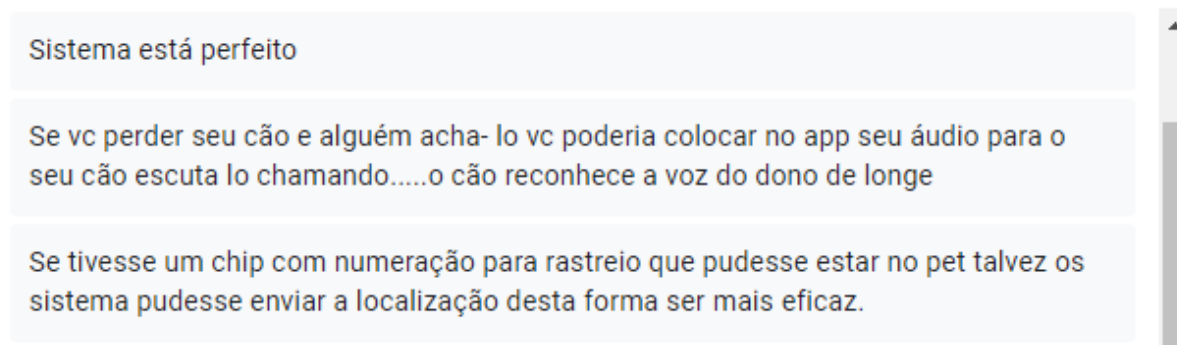
3.1.15 Sugestões adicionais

Na questão discursiva opcional sobre funcionalidades adicionais, que obteve 20 respostas, uma parte dos participantes usou o espaço para elogiar a ideia e validar a proposta existente. Entre as sugestões construtivas, o tema mais recorrente foi a integração com hardware de rastreamento físico, como chips de localização. Outras ideias pontuais mencionadas incluíram a integração com serviços de recolhimento de animais, a emissão de alertas de proximidade para outros usuários do aplicativo e a utilização de recursos de áudio para auxiliar na busca (Figura 17).

Figura 17 - Sugestões adicionais

15) Se houver alguma funcionalidade ou recurso adicional que considere fundamental para o sucesso do CÃORADAR e que não foi listado acima, por favor, descreva-o no campo a seguir

20 respostas



Sistema está perfeito

Se vc perder seu cão e alguém acha- lo vc poderia colocar no app seu áudio para o seu cão escuta lo chamando.....o cão reconhece a voz do dono de longe

Se tivesse um chip com numeração para rastreio que pudesse estar no pet talvez os sistema pudesse enviar a localização desta forma ser mais eficaz.

Fonte: Questionário - Pesquisa para TCC – CÃORADAR

3.1.16 Conclusões do formulário

A pesquisa quantitativa validou de forma robusta os pilares do projeto. Os dados confirmam que: (1) O desaparecimento de animais é percebido como um problema frequente e angustiante (53,6% com notas 4 ou 5); (2) Os métodos atuais são vistos como de "alto esforço" (57,3%) e são reativos (baseados em redes sociais e panfletos); (3) A solução CÃORADAR tem aceitação massiva (99% com notas 4 ou 5); (4) Os requisitos técnicos são viáveis, pois os usuários possuem fotos (80,2%) e confiança na descrição (81,9%); (5) A maior demanda é pelo "Match" por IA (71,1%), e a preocupação com a privacidade é baixa para a maioria (67%).

3.2 Pesquisa qualitativa: entrevista - discentes de medicina veterinária

Para complementar os dados quantitativos obtidos com o público-alvo e validar a viabilidade técnica e prática da solução, a pesquisa incluiu uma etapa de coleta de dados qualitativos. O instrumento escolhido foi a entrevista semiestruturada com um grupo focal de especialistas em formação.

O grupo foi composto por quatro discentes do curso de Medicina Veterinária: Ana Beatriz (19 anos, Santo André), Beatriz (19 anos, Ribeirão Preto), Emily (20 anos, Santo André) e Larissa (19 anos, Mauá). A escolha deste público justifica-se por sua

visão acadêmica e pré-clínica, aliando o conhecimento técnico sobre as raças e o contato com a realidade da perda de animais em estágios e rotinas de clínicas. Durante a entrevista, foi apresentado às participantes o contexto do projeto CÃORADAR, explicando a premissa de utilizar Inteligência Artificial e câmeras de monitoramento urbano para auxiliar na busca por cães perdidos.

3.2.1 Identificadores visuais fáceis

Pergunta: Quais características físicas de um cão são mais fáceis de identificar visualmente?

Ana Beatriz iniciou a resposta, destacando características de alta visibilidade. Ela mencionou que o focinho braquicefálico (achatado, como em Pugs e Bulldogs) é um identificador claro. As demais estudantes (Beatriz, Emily e Larissa) concordaram e complementaram, citando a coloração e o comprimento do pelo (ex: Doberman, Golden) como fatores fáceis. Ana Beatriz acrescentou que orelhas (sempre caídas ou levantadas), manchas específicas e o tamanho/porte (ex: Salsicha) também são distintivos.

3.2.2 Características padrão em cães

Pergunta: Existe alguma característica que seja um "padrão" na maioria dos cães, mesmo de raças diferentes?

As estudantes debateram sobre características universais. Ana Beatriz mencionou que, embora existam exceções, a característica mais comum vista no dia a dia é o focinho preto. As outras estudantes, em conjunto, concordaram, notando que, embora os coxins (almofadas das patas) variem, o focinho preto é o padrão mais observado na rotina clínica.

3.2.3 Dificultadores na captura de imagem

Pergunta: O que mais atrapalha na captura da característica física de um cão por foto?

As estudantes concordaram unanimemente que o ângulo é o principal dificultador. Ana Beatriz explicou que fotos de costas, de lado ou focadas apenas no

rabo são insuficientes. Elas concluíram que a qualidade da imagem é importante, mas que a captura do rosto do animal é o fator mais essencial para a identificação.

3.2.4 Identificação de outras raças

Pergunta: Além das raças do projeto (Golden, Yorkshire, etc.), quais outras vocês consideram "únicas" ou fáceis de identificar?

As estudantes listaram raças que consideram de fácil identificação. Ana Beatriz e Beatriz citaram Pug e Pinscher como inconfundíveis. Em conjunto, elas também adicionaram Rottweiler e American Bully. Em contrapartida, Ana Beatriz alertou que raças como Shih Tzu seriam o maior desafio, por serem muito parecidas entre si.

3.2.5 Viabilidade da expansão de raças

Pergunta: Vocês acham viável expandir o sistema para todas as raças (incluindo vira-latas) ou seria melhor manter o foco em raças específicas para garantir a precisão?

Esta foi uma resposta crucial de Ana Beatriz. Ela argumentou que limitar o sistema a raças específicas excluiria a maioria dos usuários, incluindo ela própria. Ela defendeu que, embora seu cão seja "vira-lata", "não existe outro igual" devido a características únicas, e que focar em características específicas (manchas, etc.) seria mais eficaz do que focar em raças.

3.2.6 Causas comuns de fuga

Pergunta: Na experiência de vocês, qual é o motivo mais comum para um cão fugir?

As estudantes concordaram que a fuga raramente ocorre durante o passeio. Ana Beatriz afirmou que o motivo mais comum é o descuido residencial, principalmente o portão aberto (ao sair com o carro, receber visitas). As demais complementaram citando o pânico por barulhos (como fogos) como segunda causa principal.

3.2.7 Facilitadores e dificultadores da busca atual

Pergunta: Quais são os maiores facilitadores e dificultadores na hora de procurar um cão perdido?

Ana Beatriz, relatando sua experiência pessoal, apontou o maior facilitador como a divulgação rápida e massiva ("o meu a gente achou porque divulgou muito"). Ter uma foto de boa qualidade e saber a região da perda também são cruciais. Os maiores dificultadores citados por ela e pelas demais foram: (1) O Tempo ("daqui dois dias ele já pode estar longe"); (2) Fotos Inadequadas ("muita gente não tem foto... ou tipo, uma foto abraçada"); e (3) O Nervosismo do tutor.

3.2.8 Validação de recursos de apoio

Pergunta: O que vocês acham de integrar uma rede social e mensagens de apoio?

Ao discutir o nervosismo, as estudantes validaram a ideia de apoio. Ana Beatriz mencionou que alertas em alta frequência podem gerar "muito desespero", mas que uma mensagem de apoio, "mesmo que mínima", ajudaria. Beatriz (Ribeirão Preto) mencionou uma iniciativa de sucesso em sua cidade (um grupo de Instagram). Todas concordaram que integrar uma funcionalidade de rede social (um "feed" onde o público pudesse postar fotos de "eu vi") seria uma adição de grande valor.

3.2.9 Validação da solução central (IA)

Pergunta: Vocês acham que a funcionalidade principal (busca por IA nas câmeras) faz sentido e vocês usariam?

Todas as estudantes validaram a ideia. Ana Beatriz e Emily afirmaram que "faz sentido" começar por cães, pois "a maioria das pessoas tem cão" e o comportamento de gatos é muito diferente. Elas confirmaram que usariam a funcionalidade.

3.2.10 Desafios de infraestrutura e câmeras

Pergunta: Quais desafios práticos vocês veem na dependência de câmeras urbanas? Seria melhor integrar com câmeras de condomínios e comércio?

As estudantes ponderaram sobre a infraestrutura. Ana Beatriz sugeriu uma abordagem híbrida para diminuir custos: usar as câmeras públicas em conjunto com a rede social de avistamentos (onde o público envia fotos). Elas sugeriram que, em locais com pouca cobertura pública, a integração com câmeras de comércios e condomínios faria uma grande diferença e deveria ser buscada.

3.2.11 Conclusão da entrevista

A entrevista com as discentes de medicina veterinária forneceu uma validação qualitativa crucial para o projeto CÃORADAR. Os insights técnicos confirmaram que os métodos de busca atuais são reativos, descentralizados (dependentes de redes sociais) e ineficientes, sendo o tempo o fator crítico para o sucesso. A solução proposta foi recebida com entusiasmo, sendo classificada como "fantástica" e necessária. As contribuições mais significativas para o escopo do protótipo foram a validação de que a especificidade da IA (focando em manchas e traços únicos, e não apenas na raça) é o fator-chave para o sucesso, e a recomendação de não excluir os cães sem raça definida (vira-latas), visto que representam a maioria dos casos e possuem características individuais identificáveis. Por fim, as estudantes validaram a baixa preocupação do público com a privacidade frente ao benefício social e reforçaram o valor de uma funcionalidade de "feed" de avistamentos pela comunidade.

3.3 Pesquisa qualitativa: entrevista - setor público (zoonoses)

Para validar a dimensão do problema e a viabilidade da solução sob a ótica do poder público, a pesquisa foi complementada por uma entrevista com uma autoridade da área. A entrevista foi conduzida por telefone com a gerente do departamento de Zoonoses de Santo André, Sandra. O objetivo foi mapear os processos oficiais atuais, identificar os gargalos logísticos do setor público no manejo de animais perdidos e avaliar a receptividade e o potencial de integração da solução CÃORADAR.

3.3.1 Procedimentos e amostra

A amostra desta etapa qualitativa foi intencional, buscando a gestora responsável pela política pública de manejo animal no município. Foi apresentado à

gerente o contexto do projeto CÃORADAR, e as perguntas focaram nos processos de notificação, identificação e reencontro de animais perdidos na cidade.

3.3.2 Análise e resultados da entrevista

A análise da entrevista com a gerente de Zoonoses permitiu validar os gargalos do sistema atual e o valor da inovação proposta. Os insights foram agrupados nos seguintes eixos temáticos:

3.3.2.1 Processos atuais de identificação preventiva e reativa

A gestora explicou que o município de Santo André possui um sistema de identificação preventiva, o Registro Geral do Animal (RGA), que é atrelado à vacinação. Caso um cão com RGA seja encontrado, a identificação e o reenvio ao dono são diretos. No entanto, quando um animal sem RGA ou outro tipo de identificação (como microchip) se perde, o processo torna-se reativo e ineficiente. A gerente foi enfática ao afirmar que, nesses casos, "a maior chance é de não reencontrar". O Centro de Zoonoses funciona como um "achados e perdidos", mas depende de o tutor ir fisicamente ao local perguntar sobre o animal.

3.3.2.2 Gargalos Logísticos e Gestão de Dados

Foi confirmado que a taxa de cães perdidos reportada é alta. O departamento recebe frequentes chamados e ligações sobre perdas, mas esses registros são, em sua maioria, manuais (anotações) e, por vezes, lançados em sistemas de forma secundária. A gestora citou que o poder público é "limitado" na prevenção e que a gestão desses dados não é priorizada por não haver ferramentas eficazes que justifiquem o investimento de recursos. A falta de informações (como a direção da fuga) e a ausência de ferramentas proativas resultam em uma baixa taxa de reencontro.

3.3.2.3 Validação e receptividade da solução CÃORADAR

A ideia do CÃORADAR foi recebida como "ótima" e de "extrema importância". A gerente validou que a solução poderia "facilitar e otimizar muito mais os processos de reencontro". No entanto, ela posicionou a ferramenta, inicialmente, como um "complemento" essencial às buscas já priorizadas pelos tutores (redes sociais, divulgações informais). Embora a gestora incentive o uso de chips, ela reconhece que o custo é um impeditivo para a maioria, o que eleva o valor de uma solução baseada em câmeras.

3.3.2.4 Viabilidade de integração e burocracia

A gerente demonstrou grande interesse na integração da plataforma com o departamento. Ela sugeriu que os reportes de cães avistados ou recolhidos pela Zoonoses pudessem ser inseridos no CÃORADAR, e o sistema, por sua vez, enviaria alertas para tutores com cães de características semelhantes.

Sobre os entraves burocráticos e de privacidade no uso de câmeras públicas, a gestora não demonstrou grande preocupação. Ela afirmou que, estando o sistema sob controle do poder público e focado no bem-estar social, o fator privacidade teria "pouca importância" e seria superável.


3.3.3 Conclusões da entrevista

A entrevista com o departamento de Zoonoses validou a hipótese do projeto sob a perspectiva logística e pública. Ficou evidente que (1) existe um vácuo tecnológico na gestão de animais perdidos, com processos manuais e reativos; (2) a taxa de reencontro de animais sem identificação é baixa, o que justifica uma ferramenta de busca ativa; (3) a solução é vista pelo poder público como uma otimização de importante para um processo hoje limitado.

4 DESENVOLVIMENTO

Este capítulo detalha a engenharia de software aplicada na concepção, modelagem e construção da plataforma "Cão Radar". O processo de desenvolvimento fundamentou-se na integração de um ecossistema web tradicional, composto por uma camada de apresentação client-side construída em Angular/TypeScript e uma camada transacional server-side desenvolvida em Java/Spring Boot, com o processamento avançado de Inteligência Artificial e Visão Computacional, implementado em um microserviço isolado em Python (Figura 18). Essa integração sinérgica visa solucionar, de forma automatizada e proativa, o problema social do desaparecimento de animais de estimação em ambientes urbanos, conforme justificado e validado nos capítulos precedentes. A seguir, são descritos detalhadamente os requisitos do sistema, o cronograma de projeto, a arquitetura de microserviços, a modelagem de dados, a implementação lógica, incluindo a descrição dissertativa completa dos três fluxos operacionais de IA, e a justificativa técnica das abordagens descartadas durante o ciclo de desenvolvimento.

Figura 18 - Diagrama de Atividades UML do “Cão Radar”



Fonte: Autoria própria (2026).

4.1 Requisitos do sistema

A Engenharia de Requisitos consistiu no levantamento sistemático, na análise criteriosa e na documentação formal das necessidades dos stakeholders, tutores de cães desaparecidos, membros da comunidade urbana dispostos a colaborar na busca e administradores responsáveis pela operação técnica do sistema. Para garantir a rastreabilidade bidirecional e a completude do escopo funcional, os requisitos foram mapeados por meio de Estórias de Usuário (User Stories), seguindo a metodologia

ágil, e classificados em duas categorias complementares: Requisitos Funcionais (RF), que descrevem as funcionalidades observáveis pelo usuário, e Requisitos Não Funcionais (RNF), que estabelecem as restrições tecnológicas, arquiteturais e de qualidade do sistema.

4.1.1 Estórias de usuário

As Estórias de Usuário foram elaboradas seguindo o padrão ágil consagrado (Como [perfil], eu quero [ação], para que [benefício]), focando no valor de negócio entregue a cada perfil de ator que interage com a plataforma:

a) US-01: Como tutor, eu quero cadastrar o desaparecimento do meu cão, inserindo características físicas, fotos e o local da fuga, para que o sistema possa rastreá-lo ativamente nas ruas.

b) US-02: Como administrador, eu quero realizar o upload de arquivos de vídeo simulando câmeras de segurança urbanas, para que a IA processe essas mídias em busca de cães.

c) US-03: Como membro da comunidade, eu quero poder reportar o avistamento de um cão perdido, para auxiliar os tutores da minha região.

d) US-04: Como tutor, eu quero receber notificações imediatas no aplicativo, para que eu possa resgatar meu animal assim que ele for detectado.

e) US-05: Como sistema de Inteligência Artificial, eu preciso extrair atributos físicos isolados das imagens capturadas, para que eu possa calcular a probabilidade de match com a base de dados.

4.1.2 Requisitos Funcionais (RF)

Os Requisitos Funcionais descrevem as ações, comportamentos e serviços diretos que o "Cão Radar" deve obrigatoriamente prover aos seus usuários e aos seus módulos internos autônomos:

a) RF-01 (Gestão de Identidade e Autenticação): O sistema deve possuir um módulo de controle de acesso que permita o cadastro, login e gerenciamento de perfis, distinguindo as permissões entre usuários comuns (tutores) e administradores do sistema.

b) RF-02 (Cadastro de Relatos de Perda): A aplicação deve disponibilizar formulários em múltiplas etapas que permitam ao tutor registrar um cão perdido. O formulário deve exigir preenchimento de dados georreferenciados (latitude e longitude da fuga), características fenotípicas (raça, porte e cor) e o upload de imagens nítidas do animal.

c) RF-03 (Módulo de Ingestão de Mídia): O sistema deve fornecer uma interface administrativa capaz de suportar o upload de arquivos de vídeo pesados, exibindo o progresso percentual da transferência em tempo real.

d) RF-04 (Detecção Espacial Autônoma): O motor de Visão Computacional do sistema deve processar os vídeos submetidos, identificar a classe "cão" em meio ao cenário urbano e realizar o recorte automático (crop) do animal detectado, gerando snapshots.

e) RF-05 (Extração de Metadados via IA): O sistema deve submeter as imagens recortadas a um modelo de linguagem multimodal (LLM) capaz de inferir e estruturar características físicas do cão detectado na rua.

f) RF-06 (Motor de Similaridade e Match): O sistema deve executar rotinas de comparação cruzando os atributos extraídos das ruas com os relatos de perda cadastrados. O sistema deve calcular um score de similaridade e gerar uma justificativa textual para a aproximação.

g) RF-07 (Mensageria e Alertas): Ao confirmar uma detecção com alto score de similaridade, a aplicação deve disparar automaticamente uma notificação no aplicativo, informando ao tutor o local e a imagem do achado.

h) RF-08 (Geolocalização Interativa): A interface web deve apresentar mapas dinâmicos e de calor, permitindo aos usuários visualizarem espacialmente os pontos de perda e os avistamentos confirmados.

4.1.3 Requisitos Não Funcionais (RNF)

Os Requisitos Não Funcionais estabelecem as restrições tecnológicas, padrões de qualidade, segurança e escolhas arquiteturais que regem o funcionamento do sistema nos bastidores:

a) RNF-01 (Arquitetura Client-Side Responsiva): O front-end deve ser construído como uma Single Page Application (SPA) utilizando o framework Angular (versão 17+), adotando a arquitetura de Standalone Components e programação

reativa (RxJS) para otimizar o consumo de *Application Programming Interface* (Interface de Programação de Aplicações – APIs) e garantir fluidez na navegação.

b) RNF-02 (Processamento Transacional Multitarefa): O back-end principal deve ser desenvolvido em linguagem Java (LTS), sob o ecossistema Spring Boot, garantindo processamento multithread eficiente e alta disponibilidade para lidar com requisições HTTP concorrentes.

c) RNF-03 (Desacoplamento Cognitivo): Para evitar o bloqueio de I/O no servidor principal, o processamento de Inteligência Artificial e Visão Computacional deve operar em um microsserviço isolado desenvolvido em Python. A comunicação entre a IA e o back-end deve ocorrer de forma assíncrona, orientada a webhooks.

d) RNF-04 (Persistência Híbrida e Geoespacial): O SGBD deve ser o PostgreSQL. A modelagem deve suportar o formato nativo JSONB para indexação de dados não estruturados gerados pela IA e deve possuir capacidade de processar cálculos matemáticos complexos (Fórmula de Haversine) internamente.

e) RNF-05 (Armazenamento Descentralizado de Mídias): Objetos pesados, como frames recortados e fotos de alta resolução, não devem ser gravados como BLOBs no banco de dados, exigindo a integração com serviços de Clouinary e Content Delivery Network (CDN) baseados em nuvem.

f) RNF-06 (Segurança e Criptografia): A aplicação deve blindar as rotas da API RESTful através do módulo Spring Security. O armazenamento local (LocalStorage) no navegador não deve reter tokens sensíveis sem ofuscação, prevenindo ataques do tipo Cross-Site Scripting (XSS).


g) RNF-07 (Otimização de Tráfego de Rede): O front-end deve implementar Lazy Loading no roteamento e utilizar APIs nativas do navegador (Blob API) para gerar visualizações prévias (previews) de vídeos em memória, minimizando o tráfego de rede desnecessário antes da submissão final dos formulários.

4.3 Desenho da arquitetura do software

Para suportar a assimetria computacional do projeto, que exige respostas de baixíssima latência para a navegação web dos usuários, mas demanda alto poder de processamento de tensores para a inferência de redes neurais, a adoção de uma arquitetura monolítica tradicional foi sumariamente descartada. O sistema "Cão Radar" foi concebido sob o paradigma arquitetural de Microsserviços (Microservices

Architecture) (Figura 19). Esta topologia promove o desacoplamento integral entre a interface de apresentação, a orquestração de regras de negócio e o motor cognitivo de Inteligência Artificial, permitindo escalabilidade elástica e tolerância a falhas isolada para cada domínio.

Figura 19 - Diagrama de componentes e integração de microsserviços




Fonte: Autoria própria (2026).

4.3.3 Camada de IA e visão computacional (Microsserviço Isolado)

Totalmente isolado do ecossistema Java, o motor cognitivo do projeto foi alocado em um microsserviço desenvolvido em Python. Essa decisão justifica-se pelo domínio quase absoluto da linguagem sobre as bibliotecas de aprendizado de máquina (*Machine Learning*). O comportamento operacional deste módulo é ditado por uma máquina de estados rigorosa, conforme ilustrado na Figura 20.

Figura 20 - Diagrama de máquina de estados



Fonte: Autoria própria (2026).

Esse processador atua de forma dual. No estágio de Detecção Espacial, utiliza o modelo YOLOv8 (You Only Look Once) para analisar os frames de vídeo recebidos em intervalos de 5% em 5% dos frames totais. Ao detectar um cão, a biblioteca executa um recorte geométrico (crop) da região de interesse, descartando o ruído visual do cenário urbano. No estágio de Inferência Multimodal (VLM), o framework Agno orquestra agentes de Inteligência Artificial baseados nos Grandes Modelos de Linguagem Multimodais da família Google Gemini (2.5 Flash/Pro). Esse agente analisa a imagem recortada, extrai características fenotípicas (pelagem, porte, raça estimada) em formato JSON e cruza essas matrizes com o banco de cães perdidos, calculando matematicamente o score de similaridade.

A integração entre o Java e o Python ocorre de forma orientada a eventos (event-driven). Para não bloquear o tráfego web, a comunicação retroativa da IA para o back-end é realizada através de um Webhook, disparando requisições HTTP POST apenas quando um animal é processado e identificado com sucesso.

4.3.3.1 Fluxo de Monitoramento (detecção por vídeo)

O Fluxo de Monitoramento descreve o processamento completo de um vídeo submetido ao sistema, desde a entrada da gravação até a persistência dos dados extraídos pela IA. Esse fluxo é o coração operacional do microsserviço de Visão Computacional e opera conforme a sequência lógica rigorosamente encadeada, a seguir.

O processo inicia-se com a recepção de uma gravação de vídeo (Input). O modelo YOLOv8 realiza a detecção, analisando o vídeo em intervalos regulares de 5% em 5% do total de frames, aguardando a identificação de um cão. Caso nenhum cão seja detectado em um frame, o sistema avança para o próximo intervalo de análise sem registrar ocorrência. Ao detectar um cão, o sistema executa a captura de duas imagens complementares, a tela completa (full) com o cão visível no cenário urbano e o recorte isolado do animal, atribuindo um ID temporário de rastreamento ao cão detectado e encaminhando o material capturado para o Agente IA de Filtro.

O Agente IA de Filtro recebe a imagem recortada do cão detectado e analisa criteriosamente se a imagem apresenta qualidade e visibilidade suficientes para a extração confiável de características fenotípicas. Essa análise contempla fatores como nitidez da imagem, ângulo de captura, proporção do animal no frame, ausência de oclusão significativa e condições de iluminação. Caso a imagem não possua a qualidade mínima necessária para uma análise confiável, ela é sumariamente descartada e o sistema retorna ao ciclo de detecção para processar o próximo intervalo de frames. Caso a imagem seja aprovada pelo filtro de qualidade, o sistema verifica se o cão identificado pelo ID temporário já possui registros de imagens capturadas em frames anteriores do mesmo vídeo.

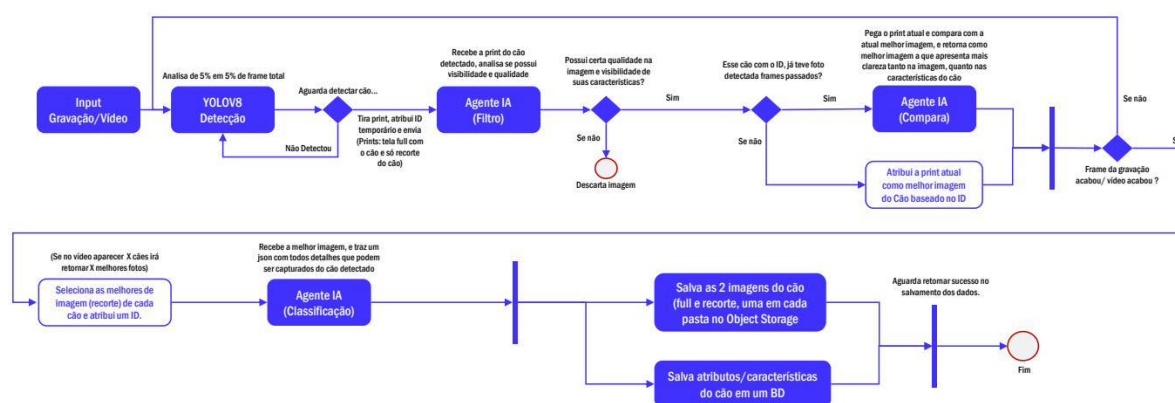
Se o cão com o referido ID temporário ainda não possui registros prévios de imagens (primeira detecção daquele animal específico no vídeo), a imagem atual é automaticamente atribuída como a melhor imagem disponível para aquele ID. Se, por outro lado, o sistema já possui uma ou mais imagens registradas para aquele ID de frames anteriores, o Agente IA de Comparação é acionado. Esse agente compara a imagem atual com a melhor imagem previamente armazenada para aquele cão e seleciona, entre as duas, aquela que oferece maior clareza tanto da imagem em si (resolução, nitidez, iluminação) quanto das características fenotípicas identificáveis do animal (visibilidade do focinho, orelhas, pelagem, marcações corporais). Esse ciclo de

detecção, filtragem, comparação e seleção da melhor imagem repete-se iterativamente até que todos os frames do vídeo sejam integralmente processados.

Ao término do processamento do vídeo (quando todos os intervalos de frames foram analisados), o sistema consolida os resultados: seleciona as melhores imagens (recorte) de cada cão distinto detectado ao longo do vídeo e atribui um ID definitivo a cada animal identificado. Se o vídeo processado contém X cães distintos, o sistema produz exatamente X conjuntos de imagens otimizadas, um para cada animal.

Na etapa final de classificação e persistência, o Agente IA de Classificação recebe cada melhor imagem selecionada e, por meio do modelo generativo multimodal Google Gemini, gera um JSON estruturado contendo todos os detalhes fenotípicos capturáveis do cão, incluindo raça estimada, porte, cor predominante, tipo de pelagem, formato das orelhas, presença de marcações e quaisquer anomalias visuais. As duas imagens de cada cão (tela completa e recorte isolado) são então persistidas no Cloudinary, cada uma em sua respectiva pasta organizacional, enquanto os atributos e características extraídos são salvos no banco de dados PostgreSQL. O Fluxo de Monitoramento (Figura 21) encerra-se somente após a confirmação de sucesso no salvamento de todos os dados.

Figura 21 - Fluxo de Monitoramento



Fluxo de Monitoramento

Fonte: Autoria própria (2026).

4.3.3.2 Fluxo do Usuário (cadastro de cão perdido)


O Fluxo do Usuário descreve o processo de cadastro de um relato de perda realizado por um tutor na plataforma web do "Cão Radar". Esse fluxo representa a porta de entrada dos dados fornecidos pelo lado humano do sistema e é projetado para ser intuitivo, guiado e resiliente a erros de preenchimento.

O tutor submete uma imagem do cão desaparecido e preenche os atributos descritivos do animal por meio de campos selecionáveis (dropdown list) com valores padronizados, como porte (pequeno, médio, grande), cor predominante, raça (quando conhecida) e localização georreferenciada do desaparecimento, além de um campo de texto livre para detalhes adicionais sobre o cão perdido (marcações, coleira, comportamento). A padronização dos campos de entrada por meio de dropdown lists é uma decisão de design deliberada, que visa garantir a consistência e a comparabilidade dos dados inseridos pelos usuários com os atributos extraídos automaticamente pela IA a partir das detecções de monitoramento.

O sistema verifica se todos os campos obrigatórios foram selecionados e preenchidos corretamente, aplicando validações tanto no front-end (validação reativa via formulários Angular) quanto no back-end (validação de integridade no Spring Boot).

Caso os dados sejam inválidos, incompletos ou inconsistentes, o sistema retorna uma mensagem de erro clara e solicita ao usuário que corrija e refaça o envio. Caso os dados estejam corretos e completos, a imagem do cão é salva no Cloudinary e os atributos e características descritivas são persistidos no banco de dados PostgreSQL na tabela `tb_relatos_perda`. Um ID único (UUID) é atribuído ao registro do cão perdido. O Fluxo do Usuário (Figura 22) encerra-se após a confirmação de sucesso no salvamento de todos os dados, e o sistema automaticamente aciona o Fluxo de Match para verificar se existem detecções de monitoramento que correspondam ao novo relato.

Figura 22 - Fluxo do Usuário



Fluxo do Usuário

Fonte: Autoria própria (2026).

4.3.3.3 Fluxo de Match (motor de similaridade)

O Fluxo de Match constitui o algoritmo central e mais sofisticado de comparação do sistema "Cão Radar", representando o núcleo da proposta de valor da plataforma. Esse fluxo é acionado automaticamente por dois gatilhos distintos e complementares: a detecção de um novo cão pelo monitoramento de vídeo (fluxo de monitoramento) ou a inserção de um novo relato de cão perdido por um usuário (fluxo do usuário). Para orquestrar essa lógica bidirecional de forma elegante e escalável, o sistema utiliza um parâmetro arquitetural denominado "visão", que determina a perspectiva a partir da qual a comparação será realizada.

Quando um cão novo é detectado pelo monitoramento de vídeo, o parâmetro "visão" é automaticamente definido como "detectado", e o sistema realiza uma comparação de um cão detectado contra muitos cães perdidos cadastrados no banco de dados, buscando identificar se o animal avistado corresponde a algum relato de perda existente. Inversamente, quando um cão novo é inserido por um usuário por meio do formulário de relato de perda, o parâmetro "visão" é definido como "perdido", e o sistema realiza a comparação inversa: um cão perdido contra muitos cães detectados pelo monitoramento, verificando se o animal recém-reportado como perdido já foi avistado anteriormente pelas câmeras.

O fluxo inicia-se com a recuperação completa de todos os dados do cão cujo registro acabou de ser inserido no sistema (o cão da "visão" corrente, seja ele

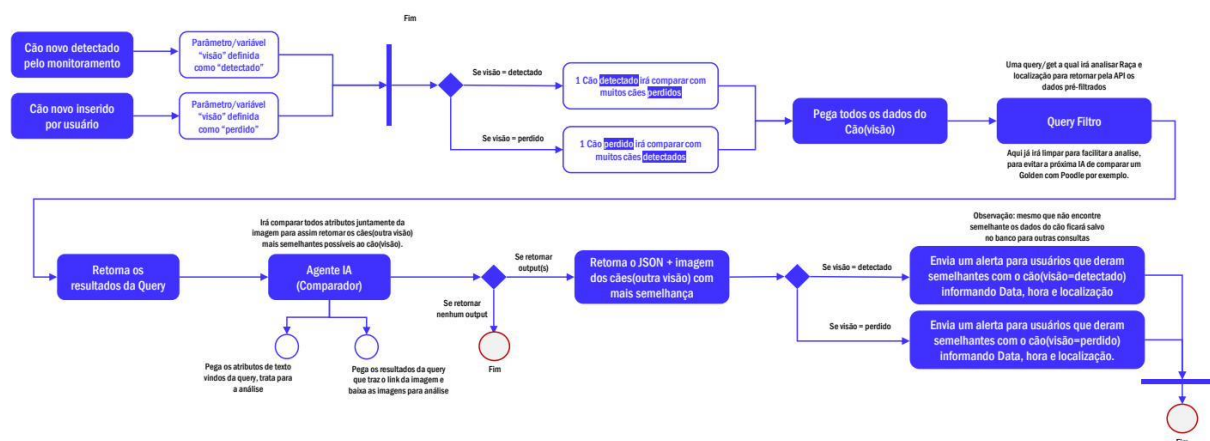
detectado ou perdido). Em seguida, é executada uma Query de Filtro, uma requisição GET parametrizada que analisa os atributos de raça e localização geoespacial (latitude e longitude) para retornar pela API apenas os registros pré-filtrados da "outra visão" que possuam correspondência mínima nesses critérios primários. Essa etapa de pré-filtragem é fundamental para otimizar o desempenho do sistema e evitar que o Agente IA Comparador seja sobrecarregado com comparações desnecessárias e computacionalmente custosas, impedindo, por exemplo, que o sistema desperdice recursos comparando um Golden Retriever com um Poodle, ou um cão perdido em São Paulo com uma detecção ocorrida em Ribeirão Preto.

Os resultados da Query de Filtro retornam dois conjuntos de dados complementares: os atributos textuais dos cães candidatos da "outra visão" (raça, porte, cor, pelagem, marcações), que são tratados e normalizados para a análise comparativa, e os links das imagens armazenadas no Cloudinary, que são baixados para permitir a comparação visual multimodal. O Agente IA Comparador, orquestrado pelo framework Agno e alimentado pelo modelo Google Gemini, recebe simultaneamente todos os atributos textuais e as imagens dos candidatos filtrados e executa uma análise comparativa abrangente e multimodal, cruzando atributos textuais (raça, porte, cor, pelagem) com análise visual direta das imagens, para retornar os cães da "outra visão" que apresentam maior semelhança com o cão da "visão" original, acompanhados de um score de similaridade numérico e uma justificativa textual gerada pela IA explicando os motivos da correspondência.

Se o Agente Comparador retornar resultados (outputs com score de similaridade acima do threshold configurado), o sistema verifica o parâmetro "visão" para determinar a ação de notificação apropriada. Caso a visão seja "detectado" (um novo cão foi avistado pelo monitoramento), o sistema envia automaticamente um alerta para os tutores cujos cães perdidos cadastrados apresentaram semelhança significativa com o cão detectado, informando data, hora e localização geográfica do avistamento. Caso a visão seja "perdido" (um novo relato de perda foi cadastrado), o sistema envia um alerta informando ao tutor sobre detecções anteriores de animais semelhantes ao seu cão, com as respectivas informações de data, hora e localização. Se nenhum resultado de semelhança suficiente for encontrado pelo Agente Comparador, o Fluxo de Match (Figura 23) é encerrado sem envio de notificações. Contudo, é fundamental observar que, mesmo na ausência de matches imediatos, todos os dados do cão permanecem integralmente salvos no banco de dados,

disponíveis para consultas futuras por novos matches que possam ser acionados posteriormente por novas detecções ou novos relatos.

Figura 23 - Fluxo IA Match




Fluxo IA Match

Fonte: Autoria própria (2026).

4.4 Desenho do projeto de banco de dados

A complexidade informacional do "Cão Radar" exige um repositório capaz de conciliar a rigidez dos dados relacionais clássicos (como credenciais de acesso e registros de câmeras) com a flexibilidade inerente aos dados não estruturados gerados dinamicamente pelos modelos de Inteligência Artificial (como os pacotes JSON de características fenotípicas extraídas pelo Gemini). Para suprir essa demanda dual de persistência, elegeu-se o SGBD relacional PostgreSQL 17, hospedado em arquitetura em nuvem (Database-as-a-Service) na plataforma Neon.tech, que oferece instâncias serverless com escalabilidade automática e backups contínuos. A Figura 24 apresenta o desenho do banco de dados.

Figura 24 - Desenho do banco de dados



Fonte: Autoria própria (2026).

4.4.1 Decisões de modelagem e segurança

Para mitigar vulnerabilidades comuns em sistemas web abertos, como ataques de enumeração direta de objetos (IDOR, Insecure Direct Object Reference), todas as chaves primárias (PKs) da modelagem utilizam o padrão UUID (Universally Unique Identifier) versão 4. Diferentemente de inteiros autoincrementais sequenciais, o UUID mascara o volume real da base de dados e torna a adivinhação de identificadores nas URLs de API matematicamente improvável (probabilidade de colisão de aproximadamente 1 em 2^{122}). Sob a ótica de engenharia de dados, o PostgreSQL foi escolhido especificamente por seu suporte nativo e otimizado ao tipo de dado JSONB (JSON Binary), que permite armazenar, indexar e consultar diretamente a totalidade do pacote flexível de características fenotípicas retornado pelo modelo Gemini, sem a necessidade de criar tabelas esparsas ou desnormalizadas.

Ademais, arquivos massivos (fotografias de alta resolução e frames de vídeo) não são persistidos diretamente no banco de dados como binários (BLOBs), o que sobrecarregaria o SGBD e degradaria dramaticamente o desempenho das queries. O

sistema utiliza a API do Cloudinary para atuar como Storage de imagens e rede de distribuição de conteúdo (CDN), armazenando no PostgreSQL apenas a string encurtada com a URL de referência (`url_img_short`), mantendo o banco de dados leve, rápido e focado em sua função primária de gerenciamento de dados estruturados e semiestruturados.

4.4.2 Dicionário e relacionamento de entidades

A arquitetura lógica do modelo relacional orbita em torno de cinco entidades fundamentais e seus relacionamentos:

a) `tb_users`: Entidade mestre de autenticação, armazenando o nome completo, CPF (chave única), e-mail (chave única), o hash criptográfico da senha (nunca a senha em texto plano) e o nível de acesso da conta (`role`: TUTOR ou ADMIN).

b) `tb_relatos_perda`: Registro oficial do cão desaparecido. Relaciona-se com o usuário por meio de chave estrangeira (`tutor_id`) em cardinalidade 1:N (um tutor pode ter múltiplos relatos) e armazena os metadados da perda, como nome do cão, descrição textual, endereço, coordenadas geoespaciais (latitude e longitude) da fuga, data de desaparecimento, status do caso, porte informado pelo tutor, cor predominante e raça.

c) `tb_cameras`: Cadastro físico dos hardwares de monitoramento espalhados pela cidade, identificados por um código externo único (`codigo_externo`), com registro de endereço, coordenadas geoespaciais e status de ativação (`ativa`).

d) `tb_avistamentos_ia`: Entidade populada exclusivamente pelos webhooks do microsserviço Python. Registra cada ocorrência detectada nas câmeras, incluindo a câmera de origem (`camera_origem_id`), data/hora da detecção, URL da imagem no Cloudinary e, crucialmente, a coluna `features` de tipo JSONB contendo o pacote completo de atributos fenotípicos estruturados pelo modelo de IA.

e) `tb_matches`: Tabela associativa que viabiliza o coração funcional do sistema. Ela vincula a chave estrangeira do relato de perda (`relato_id`) à detecção autônoma da máquina (`avistamento_id`), persistindo o grau de certeza matemática da correspondência (`score_similaridade` como `DOUBLE PRECISION`), a explicação textual gerada pela rede neural (`explicacaollm` como `TEXT`) e o status do match.

4.5 Implementação

A fase de implementação consistiu na codificação ostensiva e na materialização dos diagramas UML abstratos em software funcional e publicamente acessível. Durante esse ciclo de desenvolvimento, a arquitetura de front-end (Angular/TypeScript) e back-end (Java/Spring Boot e Python) foi integrada de ponta a ponta, permitindo que a aplicação processasse fluxos reais de upload de mídia, análises em redes neurais, persistência de dados e notificações automatizadas.

A complexidade técnica inerente à integração de modelos multimodais de IA com um ecossistema web tradicional foi abstraída por uma Interface de Usuário (UI) minimalista e acessível, projetada sob as diretrizes de acessibilidade e estilizada através de variáveis Cascading Style Sheets (CSS) customizadas e otimizações de tipografia web (Google Fonts). O objetivo fundamental do design da interface foi garantir facilidade de uso para tutores em situações de alta carga emocional e estresse decorrentes da perda de um animal de estimação, contexto no qual a simplicidade e a clareza da interface tornam-se requisitos críticos.

Em compromisso com o rigor acadêmico, o fomento à pesquisa de código aberto (Open Source) e a garantia de reprodutibilidade dos métodos descritos neste Trabalho de Conclusão de Curso, todo o código-fonte desenvolvido, englobando os repositórios dos microsserviços (back-end Java, microsserviço Python e front-end Angular) e as parametrizações de infraestrutura Docker, foi devidamente versionado utilizando o sistema de controle de versões Git. Os artefatos lógicos da implementação do sistema "Cão Radar" encontram-se hospedados e disponíveis para consulta pública no repositório institucional do GitHub, através do seguinte endereço eletrônico: [GitHub - CãoRadar](#).

Cabe registrar, em fidelidade aos princípios de transparência metodológica, que durante as etapas finais de codificação e integração das funcionalidades do protótipo "Cão Radar" foi adotado, de forma complementar, o auxílio da ferramenta Claude Code (Anthropic), assistente de codificação baseado em modelos de linguagem de larga escala. O emprego dessa ferramenta restringiu-se à geração e ao refinamento de trechos de código-fonte e à padronização de integrações entre as camadas da aplicação, sob revisão crítica e validação manual da equipe, não tendo havido seu uso na elaboração do conteúdo textual da presente monografia. A opção por essa prática fundamentou-se no ganho de produtividade observado em tarefas de código repetitivo

e na convergência mais rápida das integrações entre o microserviço Python, o back-end Spring Boot e a interface Angular, sem prejuízo do rigor técnico exigido pelo trabalho.

4.6 Justificativa do modelo cognitivo e abordagens descartadas

Durante a fase de concepção arquitetural do motor de Inteligência Artificial, a equipe avaliou criticamente diferentes abordagens para a classificação fenotípica dos animais detectados pelo sistema de monitoramento. A estratégia inicial, tecnicamente intuitiva, contemplava o treinamento supervisionado de um modelo preditivo customizado, utilizando algoritmos de Machine Learning tradicionais (através da biblioteca Scikit-Learn em Python) e Redes Neurais Convolucionais (CNNs) construídas do zero e treinadas especificamente para o escopo e domínio do projeto.

Contudo, após os primeiros ciclos de experimentação e prototipagem, essa abordagem foi sumariamente descartada por apresentar três gargalos críticos que inviabilizariam o sucesso operacional do "Cão Radar" dentro das restrições de tempo, recursos computacionais e escopo acadêmico do TCC.

O primeiro gargalo identificado foi o Custo de Curadoria de Dados e Tempo de Treinamento: para que um modelo proprietário atingisse uma precisão minimamente aceitável para uso em produção, seria necessária a montagem de um dataset massivo, rigorosamente balanceado e com milhares de imagens anotadas manualmente cobrindo dezenas de raças, múltiplas condições de iluminação, diversos ângulos de captura e variações de resolução, o que excederia drasticamente o tempo hábil de desenvolvimento do Trabalho de Conclusão de Curso.

O segundo gargalo identificado foi a Baixa Acurácia e Overfitting Morfológico: os testes preliminares com modelos treinados localmente demonstraram uma forte e preocupante tendência ao viés de inferência e à generalização apressada. Constatou-se empiricamente, por exemplo, que o modelo frequentemente associava de forma desproporcional o peso das características de "grande porte" ou "pelagem escura" de forma isolada, ignorando nuances visuais fundamentais. Como resultado empírico particularmente ilustrativo, cães sem raça definida (SRD) de grande porte recebiam sistematicamente uma probabilidade irrealmente alta de serem classificados como "Pastor Alemão", evidenciando que a rede neural estava memorizando padrões

estatísticos superficiais em vez de aprender representações visuais genuinamente discriminativas.

O terceiro gargalo identificado foi a Incapacidade de Contextualização: modelos de classificação clássicos retornam apenas arrays de probabilidades matemáticas sobre categorias fixas, sem qualquer capacidade de descrever anomalias específicas do animal (como uma mancha peculiar no focinho, uma cicatriz visível, o uso de uma coleira colorida ou um corte de pelagem atípico), que são justamente os atributos mais vitais e distintivos para a identificação única de um cão perdido em meio a outros animais da mesma raça.

Diante dessas limitações empiricamente verificadas, a equipe decidiu pivotar a arquitetura cognitiva para um pipeline híbrido de dois estágios, combinando Visão Computacional determinística com a robustez dos Grandes Modelos de Linguagem Multimodais (VLMs). No estágio de Detecção Espacial, adotou-se o modelo YOLO (You Only Look Once), já amplamente pré-treinado em datasets massivos e otimizado para o reconhecimento de classes universais. O YOLO atua exclusivamente na identificação das coordenadas da caixa delimitadora (bounding box) em que o cão se encontra, realizando o recorte da imagem e isolando o animal do ruído de fundo do ambiente urbano. No estágio de Classificação e Extração de Características, em vez de submeter o recorte a um classificador frágil, a imagem limpa é enviada para o motor de IA Generativa Multimodal (Google Gemini). A adoção da IA Generativa superou todas as expectativas de precisão, pois esses modelos já possuem um conhecimento semântico e visual global embarcado (conhecimento Zero-Shot), não requerendo treinamento adicional.

A substituição do treinamento manual pela inferência generativa garantiu ao sistema uma acurácia imensamente superior e qualitativamente diferente. A IA Generativa não apenas deixou de cometer os erros grotescos de classificação por porte (o problema do "Pastor Alemão"), como também passou a fornecer um detalhamento qualitativo profundo e contextualmente rico, retornando atributos granulares em formato estruturado (JSON), elevando substancialmente a assertividade do cruzamento de dados (match) entre os cães perdidos e os avistados.

5 TESTES

A fase de testes constitui etapa essencial do ciclo de desenvolvimento de qualquer sistema de software, sendo responsável por aferir a conformidade do produto entregue com os requisitos previamente especificados, validar sua aderência às expectativas dos usuários e mensurar, de modo objetivo, o grau de confiabilidade, robustez e qualidade da solução implementada. No contexto específico do projeto "Cão Radar", a relevância desta fase é potencializada pela natureza heterogênea da arquitetura adotada, que articula simultaneamente uma camada de apresentação client-side em Angular/TypeScript, uma camada transacional server-side em Java/Spring Boot e um microsserviço Python orientado a tarefas de Visão Computacional e Inteligência Artificial Generativa Multimodal, conforme descrito no Capítulo 4.

Diferentemente de sistemas convencionais, nos quais a saída esperada para uma dada entrada é determinada exclusivamente pelo código-fonte, sistemas baseados em redes neurais profundas e em Modelos de Linguagem Multimodais (Vision-Language Models, VLMs) operam sob princípios de inferência probabilística, em que a mesma entrada pode produzir saídas variáveis em função de fatores como temperatura do modelo generativo, condições marginais de pré-processamento da imagem e atualizações silenciosas no modelo hospedado em nuvem. Essa característica impõe a adoção de métricas estatísticas (precisão, revocação, índices de confiança) e de cenários de teste capazes de cobrir um espectro adequado de variações fenotípicas, condições de iluminação, ângulos de captura e qualidades de vídeo.

O presente capítulo apresenta, de forma sistemática, o planejamento, os cenários, a execução e a análise dos resultados obtidos para o sistema "Cão Radar". A estrutura do capítulo está organizada em seis seções complementares: a Seção 5.1 detalha os cenários e o plano de testes adotado; a Seção 5.2 apresenta os testes comparativos de classificação de raças entre modelo treinado artesanalmente e Inteligência Artificial Generativa; a Seção 5.3 documenta os testes de identificação e detecção de cães em vídeo; a Seção 5.4 discute os testes de reidentificação (match); a Seção 5.5 expõe os testes funcionais e de integração das demais funcionalidades; e a Seção 5.6 consolida a análise integrada da equipe, incorporando as evidências

coletadas pelos integrantes responsáveis pelas frentes de back-end, infraestrutura e validação prática do pipeline de visão computacional.

5.1 Cenários e plano de testes

O plano de testes do "Cão Radar" foi concebido com o objetivo de verificar a totalidade das frentes técnicas que compõem a plataforma, contemplando tanto componentes determinísticos de software tradicional (controladores REST, serviços transacionais, persistência relacional e interfaces gráficas) quanto componentes probabilísticos de Inteligência Artificial (detecção espacial via YOLO, classificação fenotípica via Modelo de Linguagem Multimodal e motor de similaridade entre relatos de perda e avistamentos). A fundamentação metodológica adotada apoia-se nas boas práticas consolidadas pela Engenharia de Software para sistemas de informação convencionais e nas recomendações específicas da literatura de Visão Computacional para a avaliação de modelos não determinísticos.

A estratégia foi estruturada em duas grandes frentes complementares: a primeira, denominada Validação Cognitiva, dedicada à aferição quantitativa do desempenho do pipeline de Inteligência Artificial; e a segunda, denominada Validação Funcional e de Infraestrutura, voltada à verificação dos fluxos transacionais, da resiliência do back-end Java/Spring Boot e da integridade da comunicação assíncrona entre o microsserviço Python e os demais componentes do sistema. Os critérios de aceitação foram definidos em termos de métricas objetivas: para a classificação de raças, considerou-se aceitável uma acurácia mínima de 80%; para a detecção de cães em vídeo, taxa de localização superior a 90%; para a reidentificação por match, taxa de acerto superior a 70%; e, para os componentes funcionais, ausência de falhas bloqueantes nos fluxos críticos do sistema.

A massa de dados de entrada foi composta por três fontes complementares: (i) um conjunto curado de fotografias estáticas das raças focais (Bulldogue Francês, Poodle, Pastor Alemão, Yorkshire Terrier e Golden Retriever), bem como de cães sem padrão racial definido (SRD); (ii) vídeos curtos gravados em ambientes urbanos da região do ABC Paulista, com diferentes condições de iluminação, ângulos de câmera e resoluções, simulando a heterogeneidade esperada de uma rede real de câmeras de monitoramento; e (iii) cenários sintéticos especialmente construídos para estressar

o pipeline em condições adversas (baixa iluminação, oclusão parcial e cães da mesma raça com características visualmente similares).

A execução das atividades de teste foi distribuída entre os integrantes da equipe, com cada membro assumindo a responsabilidade primária por uma frente técnica e atuando como revisor cruzado das demais. Essa organização, fundamentada no princípio da revisão por pares, buscou maximizar a captura de defeitos e mitigar vieses cognitivos próprios de quem desenvolveu o código submetido ao teste. Os resultados consolidados são apresentados nas seções seguintes, organizados conforme a estrutura analítica adotada no capítulo.

Para garantir a rastreabilidade entre os requisitos especificados no Capítulo 4 e os testes executados nesta etapa, os critérios de aceitação foram organizados conforme a seguinte síntese: (i) Classificação fenotípica de raça (RF-05) — acurácia mínima de 80%; (ii) Detecção espacial em vídeo (RF-04) — taxa de localização superior a 90%; (iii) Reidentificação por similaridade, motor de match (RF-06) — taxa de acerto superior a 70%; (iv) Cadastro de relatos de perda e ingestão de mídia (RF-02 e RF-03) — execução completa dos fluxos sem falhas bloqueantes; (v) Notificações ao tutor (RF-07) — disparo automático mediante score acima do limiar configurado; e (vi) Componentes de autenticação, geolocalização e visualização (RF-01 e RF-08) — operacionalidade plena nos fluxos críticos. Os resultados obtidos para cada critério são apresentados nas Seções 5.2 a 5.6 e consolidados na síntese integrada da Seção 5.6.4.


5.2 Testes de classificação de raças

A definição da estratégia de classificação de raças constituiu uma das decisões técnicas mais relevantes do projeto, em razão de seu impacto direto sobre a precisão final do motor de match e, consequentemente, sobre a confiabilidade percebida pela pessoa tutora. Com esse objetivo, foi conduzido um estudo comparativo entre duas abordagens: (i) um modelo de Visão Computacional treinado de forma artesanal pela equipe, a partir de um dataset contendo cinco raças caninas e suas respectivas fotografias; e (ii) o emprego de um modelo de Inteligência Artificial Generativa Multimodal de baixo custo e alto desempenho, especificamente o Gemini 2.5 Flash, em modalidade de classificação direta a partir da imagem.

Os experimentos iniciais foram conduzidos com o modelo treinado pela própria equipe. Apesar da utilização de um conjunto de imagens cuidadosamente curado e de tamanho representativo para um cenário acadêmico, a abordagem artesanal apresentou limitações relevantes ao longo da etapa de avaliação. Posteriormente, optou-se por seguir a trilha da Inteligência Artificial Generativa, adotando-se um modelo barato e rápido para a tarefa de classificação. Essa segunda abordagem revelou-se substancialmente superior em termos de velocidade de inferência e, sobretudo, de precisão na identificação da raça do animal.

A diferença observada entre as duas abordagens foi expressiva. Nos testes conduzidos com o modelo treinado artesanalmente, a equipe obteve uma taxa de acerto de 37% na classificação correta da raça do cão. Quando a mesma tarefa foi submetida ao modelo de Inteligência Artificial Generativa, esse número elevou-se para aproximadamente 90% de acerto, configurando uma diferença de desempenho que justifica plenamente a substituição da abordagem inicial. A Figura 25 sintetiza graficamente a comparação entre as duas estratégias.

Figura 25 - Comparativo de acurácia entre o modelo treinado artesanalmente e a IA Generativa



Fonte: Autoria própria (2026).

A análise técnica das causas dessa disparidade evidencia que, ainda que se utilize um dataset de tamanho considerável, um modelo treinado de forma artesanal continua apresentando deficiências em determinados detalhes morfológicos e tende a confundir indivíduos cuja aparência foge dos padrões mais frequentes do conjunto

de treinamento. O exemplo mais ilustrativo desse fenômeno, observado durante o desenvolvimento, refere-se à classificação de cães de estatura mais robusta. Na maioria das ocorrências, o modelo treinado artesanalmente classificava esses indivíduos como Pastor Alemão em razão de sua robustez corporal, ainda que o animal pertencesse a qualquer outra raça mais parruda que o convencional. Esse viés sistemático compromete diretamente a operação do motor de match, posto que a raça constitui um dos atributos mais determinantes para o cruzamento entre relatos de perda e avistamentos.

Em razão dessa limitação estrutural da abordagem artesanal, optou-se por prosseguir com o uso da Inteligência Artificial Generativa para a classificação do cão. Além do ganho expressivo de precisão, essa opção agrega um benefício técnico relevante: o modelo retorna, junto à classificação da raça, um conjunto de características fenotípicas adicionais do animal, tais como porte, cor predominante, tipo de pelagem, formato das orelhas e marcações distintivas. Esses atributos enriquecem significativamente a representação do cão no banco de dados e ampliam a base de informações disponíveis para o motor de comparação, operando sinergicamente com a etapa de classificação de raça e contribuindo para a robustez global do pipeline de identificação.


Quanto ao critério de aceite estabelecido na Seção 5.1 — acurácia mínima de 80% para a classificação fenotípica de raça (RF-05) —, os resultados obtidos com a Inteligência Artificial Generativa (aproximadamente 90%) atendem plenamente ao critério, ao passo que a abordagem artesanal (37%) ficou substancialmente abaixo do patamar exigido, o que justifica sua substituição em definitivo no pipeline final.

5.3 Testes de identificação e detecção em vídeo

A segunda dimensão avaliada na fase de testes refere-se à capacidade de o sistema identificar e detectar a presença de cães em vídeos submetidos à plataforma. Essa etapa constitui o ponto de entrada do pipeline cognitivo: caso a detecção espacial não localize adequadamente o animal nos frames do vídeo, todas as etapas subsequentes (filtragem de qualidade, classificação fenotípica e match) ficam comprometidas. Para essa avaliação, foi empregado o modelo YOLO em sua versão 8, integrado ao microserviço Python por intermédio do qual ocorre o processamento dos vídeos enviados pelos administradores do sistema.

Os testes conduzidos sobre o conjunto consolidado de vídeos indicaram que, em aproximadamente 90% dos vídeos submetidos (Figura 26), o sistema foi capaz de localizar o cão e gerar uma captura associada para a etapa de análise. Trata-se de um índice considerado adequado para os propósitos do protótipo, dado o caráter heterogêneo da massa de dados utilizada e a ausência de controle prévio sobre as condições de gravação. Cumpre observar, contudo, que a localização do cão em vídeo não implica, por si só, a obtenção da melhor captura possível para análise: em determinadas situações, o sistema localiza o animal, mas a imagem extraída não corresponde ao quadro de maior qualidade ou ao ângulo mais informativo, o que pode comprometer parcialmente as etapas subsequentes de classificação e comparação.

Figura 26 - Taxa de identificação de Cães no vídeo pelo YOLO



Fonte: Autoria própria (2026).

A análise qualitativa dos casos em que a captura selecionada não foi a mais adequada evidenciou três grandes grupos de fatores explicativos. O primeiro grupo refere-se a características intrínsecas ao próprio vídeo, abrangendo aspectos como duração, presença ou ausência de cor, nível de saturação, intensidade e direção da iluminação, dentre outros parâmetros visuais. O segundo grupo está associado ao próprio modelo YOLO, cujas decisões internas de detecção podem privilegiar quadros que, embora satisfaçam o limiar de confiança configurado, não correspondem necessariamente ao melhor ângulo do animal. O terceiro grupo compreende o comportamento do componente de Inteligência Artificial Generativa responsável pela filtragem dos frames extraídos, que, em ocasiões pontuais, descartou capturas

potencialmente úteis ou aprovou capturas de qualidade inferior em razão da natureza probabilística de sua decisão.

Esses três fatores atuam, em diferentes proporções, na composição da margem residual de aproximadamente 5-10% em que o sistema não conseguiu localizar o cão ou não selecionou a captura ótima. Os achados orientam o aprimoramento futuro do pipeline, com possíveis estratégias incluindo o ajuste fino dos limiares de confiança do YOLO, a adoção de um mecanismo de seleção contínua do melhor quadro ao longo da trajetória do animal no campo de visão (best angle snapshot) e a introdução de heurísticas adicionais de qualidade prévias ao acionamento do filtro generativo.

Quanto ao critério de aceite estabelecido na Seção 5.1 — taxa de localização superior a 90% para a detecção espacial em vídeo (RF-04) —, os resultados obtidos atendem ao critério, com margem residual de melhoria identificada para o módulo de seleção do melhor quadro (best angle snapshot).


5.4 Testes de reidentificação (match)

A terceira dimensão avaliada refere-se ao núcleo da proposta de valor do "Cão Radar": o motor de reidentificação, ou match, responsável por cruzar relatos de cães perdidos com avistamentos detectados em vídeos e por gerar alertas quando há indícios suficientes de correspondência entre os dois registros. Essa etapa foi avaliada sob duas configurações operacionais complementares, espelhando as duas formas de acionamento do fluxo: a inserção de um novo relato de cão perdido por parte da pessoa tutora e a inserção de um novo vídeo (avistamento) por parte de um administrador de câmera.

Quando se insere no sistema um relato de cão perdido ou um vídeo cujo conteúdo já possua, no lado oposto do banco de dados, uma contraparte compatível (seja um relato anteriormente cadastrado ou um avistamento previamente detectado), o motor de match obteve um aproveitamento superior a 75% nos testes conduzidos. Em outros termos, em aproximadamente um a cada cinco casos avaliados, o sistema apresentou um match equivocado, o que se aplica tanto aos cenários em que o sistema cruza um avistamento contra a base de relatos de cães perdidos quanto aos cenários em que cruza um relato de perda contra a base de avistamentos previamente

registrados. A Figura 27 sintetiza graficamente a distribuição entre matches corretos e matches equivocados observada na bateria de testes.

Figura 27 - Distribuição de acerto do motor de match (aproveitamento superior a 75%)



Fonte: Autoria própria (2026).

A taxa observada é considerada compatível com o estado de maturidade do protótipo e com a natureza probabilística do problema enfrentado. A imperfeição residual do motor é prevista metodologicamente, posto que sua eliminação completa demandaria a adoção de um modelo significativamente mais robusto, com custo computacional e financeiro substancialmente maiores. Tal configuração elevaria a complexidade arquitetural e poderia se converter em um alerta crítico tanto sob a perspectiva de custo quanto sob a perspectiva de desempenho, comprometendo a viabilidade operacional do sistema em larga escala. Reconhece-se, ainda, que o motor pode ser muito refinado e aprimorado em iterações futuras, mas, considerando o curto tempo de desenvolvimento disponível para a confecção do protótipo, a equipe avalia que o percentual alcançado é satisfatório e que está em patamar adequado para sustentar a prova de conceito proposta.

A análise qualitativa dos casos em que o match foi equivocado revelou padrões recorrentes, em particular: pares de cães da mesma raça com porte e coloração similares classificados como correspondência em razão da proximidade geográfica do avistamento; variações expressivas de pose entre as imagens comparadas (cão deitado em uma das fotografias e em pé na outra); e variações relevantes do estado

de tosa em raças como o Poodle, capazes de alterar substancialmente a aparência aparente do animal entre dois registros que se referem ao mesmo indivíduo. Esses padrões compõem objeto de aprimoramento futuro e poderão ser endereçados, por exemplo, mediante a incorporação de embeddings visuais densos somados aos atributos textuais já utilizados, ampliando a robustez do motor a variações temporais e ambientais.

Quanto ao critério de aceite estabelecido na Seção 5.1 — taxa de acerto superior a 70% para o motor de reidentificação por similaridade (RF-06) —, o aproveitamento superior a 75% atestado nos cenários conduzidos atende ao critério, configurando patamar adequado para uma prova de conceito acadêmica e base sólida para refinamentos futuros, em particular pela incorporação de embeddings visuais densos.

5.5 Testes funcionais e de integração

A quarta dimensão avaliada compreende as funcionalidades extras do aplicativo, isto é, o conjunto de fluxos transacionais e de apoio que sustentam a operação do sistema, complementando o pipeline cognitivo descrito nas seções anteriores. Estão incluídos nesta categoria os módulos de cadastro e autenticação de usuários, o gerenciamento de relatos de perda, o envio de notificações, o painel administrativo de câmeras, a galeria de avistamentos e a integração com o serviço de armazenamento de mídias Cloudinary, dentre outros componentes responsáveis pela experiência integral oferecida ao usuário final.

Durante a fase de testes, todas as funcionalidades extras apresentaram, em algum momento, bugs ou problemas de comportamento. Tais ocorrências foram tratadas iterativamente pela equipe ao longo das semanas de validação, com correções aplicadas tanto na camada de back-end Java/Spring Boot quanto na camada de microsserviço Python e na interface Angular, conforme a natureza específica de cada defeito. Ao término do ciclo de testes, no momento de redação do presente capítulo, o estado consolidado é de que todas as funcionalidades se encontram devidamente sincronizadas com o back-end e operacionalmente funcionais, atendendo aos requisitos especificados no Capítulo 4.

Os testes de integração entre as camadas concentraram-se na verificação de quatro frentes principais: a comunicação entre o front-end Angular e a API REST do

Spring Boot, validada por meio de testes de contrato e de jornadas reais de usuário; a integração entre o back-end Java e o banco de dados PostgreSQL, com ênfase no correto mapeamento objeto-relacional e na operação dos relacionamentos entre entidades; a integração entre o back-end e o microsserviço Python, fundamentada em comunicação assíncrona via webhook autenticado por token compartilhado; e a integração entre o microsserviço Python e os serviços externos consumidos (Cloudinary para armazenamento de imagens e API de Inteligência Artificial Generativa para classificação fenotípica).

A condução desses testes, somada à revisão contínua de código praticada ao longo do desenvolvimento, contribuiu para a estabilização progressiva da plataforma e para a convergência das funcionalidades extras a um patamar adequado de robustez. A análise mais detalhada de cada frente, com indicação dos defeitos identificados, das estratégias de mitigação adotadas e das métricas obtidas, é apresentada na seção seguinte, dedicada à consolidação dos resultados produzidos pelos diferentes integrantes da equipe.

Quanto aos critérios de aceite estabelecidos na Seção 5.1 para os componentes funcionais — execução completa dos fluxos sem falhas bloqueantes (RF-01, RF-02, RF-03, RF-07 e RF-08) —, todos os módulos validados encontram-se operacionalmente funcionais ao término do ciclo de testes, com defeitos identificados durante o desenvolvimento integralmente corrigidos.

5.6 Análise integrada da equipe

A presente seção consolida os achados específicos produzidos por cada integrante da equipe ao longo da fase de testes, organizados de modo a oferecer uma visão integrada das diferentes frentes técnicas avaliadas. Os subitens 5.6.1, 5.6.2 e 5.6.3 sintetizam, respectivamente, os resultados dos testes de carga e resiliência da infraestrutura de back-end, os testes funcionais conduzidos sobre o motor de match em cinco cenários distintos e os testes práticos do pipeline de visão computacional aplicados a três casos representativos.

5.6.1 Testes de resiliência, carga e estresse da infraestrutura

A frente de testes de infraestrutura concentrou-se na validação do comportamento do back-end Java/Spring Boot em condições adversas de operação,

com o objetivo de avaliar a confiabilidade, a resiliência e a estabilidade da plataforma frente a falhas potenciais e a cenários de pico de uso. Os protocolos foram organizados em duas grandes vertentes: testes automatizados (com foco na integridade da lógica de negócio) e testes de carga e estresse (com foco no comportamento da infraestrutura sob alta demanda).

A suíte de testes automatizados foi desenvolvida com o framework JUnit 5 em conjunto com o Mockito, voltada para o isolamento dos microsserviços e para a verificação de que o back-end Java/Spring Boot funcionasse de forma resiliente mesmo diante de falhas ou indisponibilidades do serviço de Inteligência Artificial. Os principais cenários validados nesta frente são apresentados no Quadro 1.

Quadro 1 - Cenários de testes automatizados do back-end

Cenário	Componente Avaliado	Verificação Realizada
Resiliência na Integração de Relatos	RelatoService	Comportamento do sistema quando o microsserviço Python (IA Service), hospedado no Hugging Face Spaces, retorna erros HTTP do tipo 500 Internal Server Error ou indisponibilidade temporária. Os testes confirmaram que, graças ao encapsulamento em blocos try-catch, o sistema principal não sofre interrupções em cascata e o relato da pessoa tutora é persistido com sucesso no banco de dados.
Comportamento Assíncrono	VideoController	Verificação da arquitetura assíncrona baseada em CompletableFuture. Por meio de mocks, simulou-se um atraso artificial de resposta da Inteligência Artificial. O teste atestou que a API Java retorna o código 202 Accepted em milissegundos, liberando a thread principal e evitando que o cliente front-end sofra timeouts.
Validação de Endpoints e Contratos	WebhookIAController	Confirmação do correto empacotamento das respostas REST. Validou-se que as rotas de callback consumidas pelo microsserviço Python retornam objetos no formato JSON estruturado (a exemplo do mapeamento do UUID), prevenindo falhas de desserialização no serviço de Inteligência Artificial.

Fonte: Autoria própria (2026).

A vertente de testes de carga e estresse foi conduzida com o objetivo de avaliar os limites da infraestrutura e identificar possíveis gargalos arquiteturais. O ambiente de avaliação levou em consideração as restrições inerentes aos serviços de hospedagem utilizados na nuvem, em particular o back-end hospedado na plataforma Render (plano gratuito, com limite de 512 MB de memória RAM, CPU compartilhada e hibernação por inatividade) e o banco de dados PostgreSQL hospedado no Neon DB (com limitação de conexões simultâneas). Para a injeção de carga, foi empregada a ferramenta de código aberto k6, capaz de simular o comportamento de múltiplos usuários simultâneos e requisições concorrentes oriundas de câmeras físicas. O Quadro 2 sumariza os três cenários simulados e os respectivos resultados obtidos.

Quadro 2 - Cenários e resultados dos testes de carga e estresse

Cenário	Metodologia	Resultado
Cold Start (Despertar do Servidor)	Disparo de requisições após período superior a 15 minutos de inatividade do Render	Latência elevada na primeira resposta, variando entre 15 e 30 segundos, comportamento intrínseco à alocação de recursos da camada gratuita; requisições subsequentes estabilizaram com latência média inferior a 200 ms.
Pico de Requisições Simultâneas de Avistamento	Simulação de 100 requisições simultâneas oriundas de diferentes câmeras reportando possíveis avistamentos	Confirmou-se a eficácia da refatoração na gestão de transações: ao remover anotações @Transactional de escopos longos e delegar o processamento pesado de matching exclusivamente à Inteligência Artificial, o Java passou a utilizar conexões curtas com o Neon DB. O banco operou dentro do limite do pool de conexões, sem erros de "Too many connections", e a memória RAM do Render manteve-se estável, abaixo do teto de 512 MB.
Processamento Massivo de Vídeos	Envio sequencial rápido de requisições de análise de vídeo, simulando sobrecarga na comunicação entre Java e Inteligência Artificial	Sistema absorveu a carga sem falhas. A delegação em background foi essencial: nenhuma requisição falhou por Timeout de Gateway (limites de 30 e 60 segundos). A fila de processamento priorizou a disponibilidade da interface de usuário em detrimento do tempo de processamento em segundo plano.

Fonte: Autoria própria (2026).

Adicionalmente, foram coletadas evidências quantitativas do consumo de memória RAM e da latência observada nos cenários extremos. A Figura 28 apresenta o monitor de performance de back-end durante o cenário de stress, no qual o uso de memória atingiu pico de 450 MB (status "Crítico"), aproximando-se do limite de 512 MB imposto pela camada gratuita do Render.

Figura 28 - Monitor de performance de back-end: pico de RAM - cenário de stress



Fonte: Autoria própria (2026).

A Figura 29 ilustra a curva de latência observada no cenário de cold start, com pico de 24.500 ms na primeira requisição e estabilização rápida nas requisições subsequentes (status "Recuperado").

Figura 29 - Curva de latência em cenário de cold start



Fonte: Autoria própria (2026).

Em síntese, os testes de infraestrutura atestaram que a arquitetura orientada a microsserviços do "Cão Radar", aliada às otimizações assíncronas e à segregação de responsabilidades junto ao banco de dados, é capaz de contornar as limitações de hardware do ambiente gratuito de hospedagem. O sistema apresentou comportamento resiliente, mantendo a integridade dos dados e a disponibilidade da plataforma mesmo sob estresse simulado.

5.6.2 Testes funcionais do motor de match

A segunda frente de validação concentrou-se na análise funcional do motor de match em cinco cenários distintos, conduzidos com diferentes raças caninas e configurações de dados de entrada. O objetivo foi avaliar tanto a capacidade de o sistema identificar correspondências quanto sua capacidade de evitar associações indevidas em ausência de dados representativos. O Quadro 3 sintetiza os cenários executados e os respectivos achados.

Quadro 3 - Síntese dos testes funcionais do motor de match

Teste	Raça/Cenário	Resultado	Análise
1 (Golden)	Golden Retriever	Identificação com 75% de similaridade em relação a um registro existente	Embora o animal apresentasse características visuais semelhantes (cor da pelagem e porte físico), verificou-se tratar-se de indivíduo diferente. O resultado evidencia que o algoritmo identifica padrões relevantes, mas apresenta limitações em cenários de alta similaridade visual, demandando aprimoramento dos critérios biométricos (análise mais aprofundada de traços faciais e proporções corporais).
2 (Pastor Alemão)	Pastor Alemão sem imagens de referência cadastradas	Nenhum match identificado	Resultado considerado satisfatório: o algoritmo não realiza associações indevidas em ausência de dados, comportamento essencial à confiabilidade do sistema, evitando notificações incorretas e reduzindo o risco de falsas identificações.
3 (Bulldogue Francês branco)	Bulldogue Francês de pelagem branca	Nenhuma correspondência encontrada	Caso de sucesso: mesmo diante de características marcantes da raça, o sistema preservou sua integridade ao não associar o animal a registros inexistentes, reforçando a eficácia do modelo na prevenção de falsos positivos.
4 (Poodle)	Poodle, com câmeras não cadastradas no sistema	Nenhum match identificado	Comportamento adequado: o sistema depende diretamente da entrada de dados para conduzir suas análises, evidenciando a importância da integração completa entre os módulos e da disponibilidade adequada dos dados de entrada.
5 (Yorkshire Terrier)	Yorkshire Terrier, com câmeras não cadastradas no sistema	Nenhuma correspondência	De maneira análoga ao teste anterior, o sistema demonstrou consistência ao não gerar resultados incorretos, confirmando a presença de mecanismos de validação eficientes que asseguram que apenas dados confiáveis sejam utilizados no processo de identificação.

Fonte: Autoria própria (2026).

A leitura conjunta dos cinco cenários permite duas conclusões complementares. Em primeiro lugar, o motor de match apresenta capacidade de produzir indicações de similaridade próximas a 75% mesmo quando o indivíduo

correspondente ao avistamento não é o mesmo registrado na base, o que reforça a importância de calibrar adequadamente o limiar de notificação ao usuário e de incorporar critérios biométricos adicionais para discriminação fina entre indivíduos da mesma raça. Em segundo lugar, o sistema demonstrou comportamento conservador e correto ao recusar a produção de matches em ausência de dados representativos, o que constitui propriedade desejável para um serviço cujas notificações implicam mobilização emocional e prática da pessoa tutora.

5.6.3 Testes práticos do pipeline de visão computacional

A terceira frente de validação compreendeu os testes práticos do pipeline de visão computacional, conduzidos a partir de três cenários representativos. A metodologia consistiu em alimentar o banco de dados com perfis de animais perdidos (simulando o cadastro pela pessoa tutora) e submeter vídeos de vias públicas, simulando capturas de câmeras de monitoramento. A avaliação considerou a capacidade de detecção primária, a assertividade da comparação morfológica e a resiliência do sistema a variáveis como iluminação e qualidade da captura.

5.6.3.1 Cenário 1: Desafios de captura e mudança de domínio

O primeiro cenário foi conduzido com o animal denominado "Teddy", da raça Yorkshire Terrier, cadastrado a partir de imagens estáticas em ambiente interno e bem iluminado. Foram submetidos ao sistema dois vídeos do mesmo animal em ambiente externo: um de curta duração (122 frames) e outro mais longo (631 frames). Durante o processamento do vídeo curto, o modelo não obteve índice de confiança suficiente, resultando em ausência de detecções. O vídeo longo, por sua vez, permitiu a extração de um snapshot no frame 66, com classificação correta da raça e do porte e confiança de 65%.

Ao cruzar a detecção com o banco de dados, o sistema atribuiu uma similaridade de 45% (Nível Médio) para o perfil do "Teddy". A Inteligência Artificial operou de forma conservadora, evidenciando o fenômeno conhecido como domain shift (mudança de domínio visual): as sombras dinâmicas do ambiente externo alteraram a percepção da coloração da pelagem em comparação com as fotos do cadastro, impedindo que o algoritmo apresentasse um match de alta confiança.

5.6.3.2 Cenário 2: Validação de match retroativo e resiliência visual

O segundo cenário foi desenhado para validar a capacidade de o sistema realizar buscas retroativas, simulando a situação em que um animal é avistado e processado por uma câmera de monitoramento antes mesmo do registro do alerta de perda. O teste utilizou o cadastro do animal "Cacau", da raça Yorkshire Terrier, com imagem de referência em ambiente doméstico e pelagem preta e dourada característica.

Diferentemente do cenário anterior, o sistema não aguardou um novo processamento de vídeo. No momento em que o formulário de perda foi submetido, o pipeline de match foi acionado automaticamente para varrer a base de avistamentos já existentes, identificando três candidatos da mesma raça previamente detectados pela câmera CAM_003. A análise dos resultados desse cruzamento retroativo revelou os seguintes pontos técnicos, sintetizados no Quadro 4.

Quadro 4 - Pontos técnicos observados no cenário 2 (Cacau)

Ponto Técnico	Descrição
Eficácia do Banco de Dados Histórico	O sistema correlacionou com sucesso o novo registro com avistamentos antigos, demonstrando que a arquitetura de armazenamento de vetores biométricos permite a recuperação imediata de informações passadas.
Identificação de Duplicatas e Consistência	A IA identificou dois registros (Candidatos 1 e 2) com similaridade alta (85% base) e reconheceu corretamente que ambos os avistamentos tratavam-se do mesmo animal, capturado em momentos próximos pela mesma câmera, garantindo a integridade dos dados apresentados à pessoa tutora.
Resiliência a Diferenças de Iluminação	A IA apresentou análise qualitativa relevante para justificar o match positivo: apesar de a pelagem parecer "prateada" nos vídeos noturnos (em contraste com o "dourado" do cadastro), o modelo interpretou tal diferença como artefato da iluminação artificial e priorizou a estrutura craniana e as orelhas em formato de "V" para confirmar a identidade.
Ajuste Espacial de Confiança	A similaridade final apresentada na interface (83%) já contempla o cálculo de peso geográfico: a distância de 2,7 km entre o ponto de perda e o ponto de avistamento aplicou um fator redutor de 0,97 sobre o índice biométrico, integrando a visão computacional à análise espacial.

Fonte: Autoria própria (2026).

5.6.3.3 Cenário 3: Discriminação intrarraça e seleção dinâmica de frames

O terceiro cenário teve como objetivo avaliar a precisão da Inteligência Artificial em distinguir indivíduos da mesma raça (discriminação intrarraça) e verificar o comportamento do pipeline de extração de imagens em vídeos de curta duração. Foi utilizado o perfil de um cão da raça Pastor Alemão, denominado "Hercules", com idade aparente jovem (aproximadamente dois anos), cujo cadastro contou com seis imagens estáticas prévias.

Imediatamente após o cadastro, o sistema executou a rotina de busca retroativa no banco de dados, sem encontrar nenhum avistamento prévio para a raça. Em seguida, foram processados dois vídeos distintos de vias públicas, ambos contendo cães da raça Pastor Alemão, com durações de 6 e 7 segundos, respectivamente. Durante o processamento do primeiro vídeo (CAM_001), a análise dos logs revelou um comportamento dinâmico do algoritmo de rastreamento: em vez de capturar apenas a primeira imagem nítida, o sistema continuou avaliando os quadros subsequentes, registrando múltiplas atualizações sob a métrica de "melhor ângulo" (best angle snapshot) até a saída do animal do campo de visão. O snapshot final foi classificado corretamente com 95% de confiança para a raça e submetido ao motor de match.

O sistema atingiu, nesse cruzamento, índice de similaridade de 98% (Nível Alto). A explicabilidade gerada pela Inteligência Artificial fundamentou a decisão com base na "biometria craniofacial", na "idade aparente" e nas "impressões da pelagem facial" (padrão da máscara preta e distribuição de manchas). No mesmo processamento, o algoritmo comparou o avistamento com um segundo perfil de Pastor Alemão existente na base, reprovando-o com apenas 5% de similaridade em razão de divergências estruturais e etárias.

O processamento do segundo vídeo de teste validou a robustez do sistema contra falsos positivos. O vídeo continha um Pastor Alemão diferente; o sistema realizou a extração otimizada de quadros e cruzou o novo avistamento com a base de dados. Nesse evento, a IA atribuiu 95% de similaridade ao outro cão registrado e rejeitou categoricamente o perfil do "Hercules", atribuindo-lhe apenas 25% de similaridade e justificando a decisão como uma "discrepância irrefutável" na análise biométrica.

5.6.3.4 Síntese das considerações finais dos testes práticos

A bateria de testes práticos consolidou a eficácia da arquitetura proposta. O Cenário 1 evidenciou os limites do modelo YOLO em vídeos excessivamente curtos sem condições ideais de extração, bem como o impacto do domain shift sobre a confiança da Inteligência Artificial. O Cenário 2 comprovou a utilidade prática do sistema por meio do match retroativo e da resiliência a artefatos de iluminação noturna, com aplicação correta dos pesos geoespaciais. Por fim, o Cenário 3 demonstrou o grau de maturidade do algoritmo: a funcionalidade de seleção contínua do melhor quadro contornou as limitações dos vídeos curtos observadas no primeiro cenário, e a capacidade de a IA produzir análises forenses detalhadas — incluindo o mapeamento de manchas específicas na máscara facial de Pastores Alemães — comprovou que o sistema é capaz de diferenciar com precisão indivíduos morfologicamente semelhantes, minimizando a incidência de falsos positivos e entregando dados confiáveis às pessoas tutoras.

5.6.4 Síntese integrada

A consolidação das três frentes de validação descritas nas subseções anteriores oferece uma visão integrada do estado de maturidade do protótipo "Cão Radar" ao final da fase de testes. A frente de infraestrutura demonstrou que a arquitetura escolhida é compatível com as restrições impostas pelo ambiente de hospedagem gratuito, sustentando regimes de carga compatíveis com a operação esperada do sistema em sua fase atual. A frente de validação funcional do motor de match evidenciou tanto o comportamento adequado do algoritmo em ausência de dados (com recusa correta de associações indevidas) quanto a necessidade de aprimoramento dos critérios biométricos para discriminação fina entre indivíduos da mesma raça com características visualmente semelhantes. Por fim, a frente de testes práticos do pipeline de visão computacional comprovou a eficácia da combinação YOLO + Inteligência Artificial Generativa Multimodal em cenários reais de uso, com matches de alta confiança em condições adequadas e comportamento conservador em condições adversas, em consonância com os achados das demais frentes.

Reconhecem-se, finalmente, as limitações inerentes à avaliação conduzida, em particular o tamanho moderado do conjunto de validação, as condições controladas

de captura e a dependência de modelos generativos hospedados externamente, cujas atualizações silenciosas podem alterar o comportamento do sistema sem prévia notificação à equipe. Tais limitações constituem direcionamentos naturais para etapas posteriores do projeto, incluindo a integração com infraestrutura real de câmeras de monitoramento urbano, a expansão dos cenários de teste para volumes estatisticamente mais robustos e a implementação de pipeline de testes de regressão de modelo executado periodicamente em ambiente de homologação. Esses direcionamentos, juntamente com as demais perspectivas de evolução, são detalhados no capítulo seguinte, dedicado às considerações finais e às perspectivas futuras do projeto "Cão Radar".

6 CONSIDERAÇÕES FINAIS

O presente capítulo encerra a apresentação do Trabalho de Conclusão de Curso intitulado "Cão Radar: sistema de identificação e localização de cães extraviados por meio de Visão Computacional e Inteligência Artificial Generativa Multimodal". Aqui são retomados, de modo articulado, os elementos centrais do percurso percorrido ao longo dos cinco capítulos anteriores, examinando-se em que medida os objetivos definidos na Seção 1.1 foram atendidos, sintetizando-se os principais resultados quantitativos e qualitativos obtidos na fase de testes, discutindo-se as contribuições científicas, técnicas e sociais geradas pelo trabalho e, ao final, apontando-se as limitações reconhecidas pela equipe e os direcionamentos considerados naturais para a continuidade do projeto.

Antes de avançar, cabe registrar uma observação preliminar de natureza metodológica: o presente trabalho foi desenvolvido sob restrição temporal característica do ciclo letivo de conclusão de curso, conjugada às rotinas profissionais e acadêmicas paralelas de cada integrante da equipe. Essa condição, embora não tenha comprometido a entrega do protótipo funcional descrito nos capítulos anteriores, impôs a necessidade de priorização criteriosa do escopo e impediu o aprofundamento exaustivo de determinadas frentes técnicas que, em um horizonte temporal mais elástico, poderiam ter sido exploradas em maior profundidade. Essa observação não constitui justificativa, mas contextualização honesta das condições nas quais o trabalho foi conduzido, e dialoga diretamente com as oportunidades de evolução listadas na Seção 6.7.

6.1 Síntese do trabalho desenvolvido

O presente trabalho percorreu uma trajetória articulada em cinco capítulos: a contextualização do problema social do desaparecimento de cães em centros urbanos brasileiros e a definição dos objetivos (Capítulo 1); a consolidação do referencial teórico em padrões de raça, desafios computacionais de Visão Computacional em ambientes não controlados e modelos de Linguagem Multimodal (Capítulo 2); a metodologia investigativa composta por pesquisa de campo com 97 tutores, entrevista qualitativa com discentes de Medicina Veterinária e entrevista com a gerência de Zoonoses de Santo André (Capítulo 3); o desenvolvimento da plataforma em

arquitetura de microsserviços, com banco de dados híbrido em PostgreSQL e modelo cognitivo dual-stage YOLOv8 + Google Gemini 2.5 Flash (Capítulo 4); e a execução do plano de testes em seis frentes complementares, cuja base empírica sustenta as conclusões deste capítulo (Capítulo 5).

6.2 Cumprimento dos objetivos

O objetivo geral proposto no Capítulo 1 — projetar e implementar um protótipo funcional capaz de auxiliar tutores na reidentificação de cães extraviados, mediante o cruzamento entre relatos de perda e avistamentos detectados por sistemas de visão computacional — foi efetivamente atendido. A plataforma desenvolvida opera de ponta a ponta, articulando a interface web Angular, a camada transacional Spring Boot, o microsserviço Python de inferência cognitiva e o banco de dados PostgreSQL, e apresenta os fluxos de Monitoramento, Usuário e Match descritos na Seção 4.3.3 em estado plenamente funcional, conforme atestado pelos testes documentados no Capítulo 5.

Os objetivos específicos foram igualmente alcançados, ainda que com graus variados de profundidade. O primeiro objetivo específico, relativo à investigação do contexto social e operacional em que o problema se insere, foi atendido por meio da pesquisa de campo com tutores e das duas pesquisas qualitativas conduzidas com profissionais de Medicina Veterinária e do setor público. O segundo objetivo específico, dedicado à análise das técnicas computacionais aplicáveis à identificação visual de cães, foi atendido pelo referencial teórico do Capítulo 2 e materializou-se nas decisões arquiteturais documentadas no Capítulo 4. O terceiro objetivo específico, voltado à concepção e implementação do protótipo, foi cumprido em sua integralidade, com entrega de software funcional, versionado e publicamente acessível em repositório institucional. O quarto objetivo específico, dedicado à mensuração da acurácia do pipeline cognitivo, foi atendido pelos testes do Capítulo 5, com obtenção de 90% de acurácia na classificação de raças, 90% na identificação de cães em vídeo e aproveitamento superior a 75% no motor de match. O quinto objetivo específico, referente à definição de requisitos mínimos de configuração e à viabilidade operacional da solução em ambientes restritos, foi atendido pela validação da arquitetura sob a camada gratuita das plataformas Render e Neon DB, conforme detalhado nos testes de carga e estresse da Seção 5.6.1.

6.3 Principais resultados alcançados

Os resultados consolidados na fase de testes evidenciam o amadurecimento do protótipo. Na classificação fenotípica de raça, a substituição do modelo treinado artesanalmente (37% de acurácia) pelo modelo generativo multimodal (aproximadamente 90%) constitui o ganho mais expressivo do projeto. Na detecção espacial em vídeo, o YOLOv8 alcançou taxa de localização superior a 90% sobre massa heterogênea de vídeos. No motor de reidentificação por similaridade, o aproveitamento superior a 75% comprova a viabilidade técnica do cruzamento automatizado entre relatos de perda e avistamentos detectados pelo monitoramento.

A validação funcional e infraestrutural confirmou a resiliência do back-end e a estabilidade da arquitetura assíncrona sob carga simulada de até 100 requisições simultâneas, dentro dos limites das camadas gratuitas dos provedores utilizados. Os testes práticos do pipeline em três cenários (Teddy, Cacau e Hercules) acrescentaram evidências qualitativas relevantes, com destaque para o caso Hercules — que atingiu 98% de similaridade com explicabilidade biométrica detalhada — e para o comportamento conservador da Inteligência Artificial em condições adversas.

Em síntese assertiva e direta, o trabalho comprova quatro pontos centrais: (i) a viabilidade técnica de uma arquitetura híbrida que combina detector espacial clássico (YOLOv8) e modelo generativo multimodal (Google Gemini 2.5 Flash) para a tarefa de identificação fenotípica de cães em vídeos urbanos; (ii) a superioridade empírica dessa abordagem frente ao treinamento artesanal de classificadores próprios para o domínio, com ganho de acurácia de 37% para aproximadamente 90%; (iii) a viabilidade operacional do sistema sob restrições reais de orçamento (camadas gratuitas das plataformas Render e Neon DB) e de equipe (ciclo letivo de TCC); e (iv) a aderência da solução proposta às demandas reais reportadas pelos usuários-alvo, validadas tanto pela pesquisa quantitativa (97 respondentes) quanto pelas pesquisas qualitativas conduzidas com discentes de Medicina Veterinária e com a gerência de Zoonoses de Santo André.

6.4 Contribuições do trabalho

O "Cão Radar" produz contribuições articuladas em três dimensões. Na dimensão técnica, o protótipo materializa, em uma arquitetura coerente e replicável, a

composição entre um detector espacial clássico (YOLOv8) e um modelo generativo multimodal de baixo custo e alto desempenho (Google Gemini 2.5 Flash) operando como classificador fenotípico e como motor de match com explicabilidade textual. Essa combinação dual-stage, ao deslocar a tarefa fina de classificação de raça e atributos para um VLM já pré-treinado em escala industrial, contornou as limitações observadas na abordagem artesanal de modelo treinado pela equipe e demonstrou que arquiteturas híbridas podem oferecer, com custo computacional moderado, qualidade de inferência compatível com o estado da arte em fine-grained recognition aplicado a contextos não controlados.

Na dimensão social, o trabalho oferece uma resposta tecnológica, ainda que em estágio de protótipo, a um problema concreto e cotidiano reportado pela base de tutores entrevistada na Seção 3.1: a dificuldade de localizar animais extraviados pelos canais informais hoje predominantes (grupos de mensageria, postagens em redes sociais e cartazes físicos). A integração entre a percepção espacial via câmeras de monitoramento e a análise cognitiva por Inteligência Artificial sugere um caminho de digitalização que pode, no horizonte de continuidade descrito na Seção 6.7, transcender o escopo acadêmico e converter-se em ferramenta de uso público.

Na dimensão acadêmica, o trabalho consolida uma metodologia replicável de Validação Cognitiva organizada em frentes complementares (classificação, detecção, match, integração funcional e cenários práticos), oferecendo um modelo de avaliação aplicável a projetos análogos que combinem Visão Computacional clássica com Inteligência Artificial Generativa Multimodal. A apresentação articulada dos cenários, das métricas e das análises qualitativas da explicabilidade dos modelos contribui ao corpus de práticas de avaliação de sistemas probabilísticos no domínio sensível da identificação de seres vivos.

6.5 Decisões estratégicas e aprendizados técnicos

A condução do projeto exigiu decisões estratégicas que conformaram tanto o resultado quanto o aprendizado coletivo. Manteve-se desde a concepção a clareza do meta-objetivo — entrega de um pipeline funcional de match entre relatos e detecções —, o que orientou a tomada de decisão e impediu a dispersão de esforços. A escolha por uma infraestrutura inteiramente online (Render para o back-end Java, Hugging Face Spaces para o microserviço Python e Neon DB para o PostgreSQL), em

contraposição a uma execução local restrita aos laboratórios acadêmicos, elevou o nível de maturidade do protótipo e aproximou-o do que seria necessário em operação real, ainda que tenha imposto desafios significativos de integração assíncrona e contornos de limitações de hardware das camadas gratuitas.

A política de custos adotada — uso majoritário de ferramentas gratuitas e aproveitamento criterioso dos créditos promocionais de aproximadamente 250 dólares norte-americanos do Google Cloud para chamadas a modelos generativos — viabilizou economicamente o projeto e forçou exercício de engenharia consciente, em que cada chamada à API e cada decisão de arquitetura precisaram ser justificadas pela relação custo-benefício. Como aprendizado técnico transversal, o trabalho reforçou a centralidade da abstração e do desacoplamento entre software tradicional e componentes de Inteligência Artificial: a separação clara entre back-end Java e microserviço Python, mediada por contratos REST e webhooks autenticados, mostrou-se determinante para a resiliência do sistema diante de falhas e indisponibilidades dos serviços externos, conforme atestado pelos testes automatizados de resiliência.

6.6 Limitações reconhecidas

A entrega do protótipo "Cão Radar" deve ser apreciada à luz de um conjunto de limitações que a equipe reconhece de forma transparente. Em primeiro lugar, o conjunto de validação utilizado nos testes do pipeline de Inteligência Artificial, embora cuidadosamente curado, permanece de tamanho modesto em comparação com os datasets utilizados em pesquisas industriais de larga escala, o que limita a generalização estatística dos achados e recomenda cautela na extrapolação dos resultados para condições operacionais distintas das simuladas.

Em segundo lugar, a avaliação foi conduzida em condições de laboratório, com vídeos pré-gravados a partir de smartphones e câmeras residenciais, não tendo sido contemplada, no escopo deste TCC, a integração com a infraestrutura real de câmeras de monitoramento urbano da rede Smart Sanca de São Caetano do Sul, conforme já delimitado na Seção 5.1.2. Essa delimitação não invalida os achados obtidos, mas confina sua interpretação ao âmbito do protótipo acadêmico.

Em terceiro lugar, a estabilidade temporal do desempenho dos modelos generativos de terceiros — notadamente o Google Gemini — introduz uma variável

incontornável no comportamento do sistema: alterações silenciosas no modelo hospedado podem alterar a qualidade da inferência sem que a equipe de desenvolvimento tenha controle ou notificação prévia. Essa característica é inerente ao consumo de serviços cognitivos como API, e justifica a recomendação, formulada no Capítulo 5, de implementação futura de pipeline de testes de regressão de modelo executado periodicamente em ambiente de homologação.

Em quarto lugar, a avaliação da experiência de uso concentrou-se em um grupo reduzido de tutores voluntários, configuração compatível com inspeção heurística, mas insuficiente para conclusões estatisticamente robustas sobre satisfação e usabilidade em larga escala. A condução de testes de aceitação com amostras significativas constitui caminho natural de evolução em fase posterior do projeto.

Em quinto lugar, e em diálogo com o adendo metodológico apresentado na introdução deste capítulo, a restrição temporal característica do ciclo de Trabalho de Conclusão de Curso impediu o aprofundamento de determinadas frentes técnicas que, em um horizonte mais elástico, mereceriam exploração adicional, em particular a investigação de modelos de visão especializados em condições de baixa iluminação, a incorporação de embeddings visuais densos ao motor de match e a implementação de mecanismos de active learning para refinamento contínuo da classificação fenotípica.

6.7 Trabalhos futuros

A continuidade natural do projeto "Cão Radar" articula-se em um horizonte de evolução que combina aprofundamentos técnicos, ampliação do escopo funcional e amadurecimento institucional da solução. No plano técnico, identificam-se como prioritários: (i) a expansão do conjunto de validação por meio da curadoria de novos vídeos em ambientes urbanos diversos, contemplando inclusive condições noturnas e meteorológicas adversas, com o propósito de aprimorar a robustez do detector espacial e reduzir a margem residual de falhas observada nos testes; (ii) a incorporação de embeddings visuais densos, somados aos atributos textuais já utilizados, para discriminação fina entre indivíduos morfologicamente similares, endereçando a principal causa identificada de falsos positivos do motor de match; (iii) a implementação de pipeline automatizado de regressão de modelo, executado periodicamente sobre conjunto fixo de validação, capaz de detectar degradações

silenciosas na qualidade da inferência do modelo generativo de terceiros; (iv) a investigação de modelos especializados em condições de baixa luz, em complemento ao YOLOv8 atual, para reduzir os falsos negativos em frames noturnos; e (v) o desenvolvimento de uma camada de active learning que permita à plataforma incorporar feedback de tutores e administradores sobre matches confirmados ou rejeitados, refinando continuamente o threshold operacional do motor de similaridade.

No plano funcional, vislumbra-se a expansão do catálogo de raças contempladas pelo pipeline de classificação, partindo das cinco raças focais do protótipo atual em direção a um conjunto significativamente mais amplo, incluindo raças regionais brasileiras de elevada prevalência no público de tutores. Adicionalmente, considera-se de elevada relevância o desenvolvimento de um aplicativo mobile nativo, em complemento à interface web atual, capaz de oferecer experiência otimizada para uso em mobilidade — contexto em que se concentra parcela expressiva das interações reais de tutores em situação de perda de animal — e de explorar capacidades nativas do dispositivo, tais como geolocalização contínua, captura otimizada de imagens e recebimento de notificações em segundo plano.

No plano institucional, a equipe identifica como direcionamento de elevado valor estratégico a aproximação com o setor público, com vistas à estruturação de parceria que viabilize a integração efetiva do "Cão Radar" à infraestrutura real de câmeras de monitoramento urbano operada pela rede Smart Sanca de São Caetano do Sul. Essa evolução, condicionada à convergência de interesses entre os integrantes do projeto e à receptividade institucional do município, transcenderia o caráter acadêmico do trabalho e inauguraria uma fase de desenvolvimento orientada à utilização pública da plataforma, com ganhos potenciais para a coletividade de tutores e para o próprio setor de Zoonoses, conforme dialoga com os achados da pesquisa qualitativa apresentada na Seção 3.3. Eventuais parcerias com organizações de proteção animal, departamentos de Zoonoses de outros municípios da região do ABC Paulista e instituições acadêmicas dedicadas ao bem-estar animal são igualmente vislumbradas como caminhos de capilaridade da solução.

Por fim, no plano metodológico, considera-se relevante a publicação de artigo científico sintetizando os principais achados deste trabalho — em especial a evidência empírica do ganho de desempenho proporcionado pela substituição de modelos artesanais por modelos generativos multimodais em tarefas de fine-grained recognition aplicadas a contextos não controlados —, oferecendo à comunidade

acadêmica brasileira uma contribuição articulada à crescente literatura sobre aplicações de Inteligência Artificial Generativa em problemas de relevância social.

6.8 Reflexão final

O desenvolvimento do "Cão Radar" representou, para os integrantes deste Trabalho de Conclusão de Curso, uma jornada formativa cujo valor extrapola os artefatos técnicos entregues. A passagem de uma intuição inicial — a sensibilização coletiva diante da experiência cotidiana e dolorosa de tutores que perdem seus animais — ao protótipo funcional aqui documentado exigiu o exercício articulado de competências tecnológicas, científicas e humanas, e consolidou para a equipe a convicção de que a Engenharia de Software e a Inteligência Artificial, quando orientadas a problemas concretos com sensibilidade às restrições reais de operação, são capazes de oferecer respostas tecnicamente sofisticadas e socialmente relevantes a desafios cuja solução, à primeira vista, parecia residir apenas em iniciativas informais e descentralizadas.

A escolha por uma infraestrutura integralmente online, a busca consciente pelo menor custo operacional, a integração entre frentes técnicas distintas e a entrega de um produto funcional sob a restrição temporal do ciclo letivo são frutos de um processo de tomada de decisão coletiva que envolveu debate, escuta a profissionais da área, ajustes sucessivos e amadurecimento mútuo. Cada um dos integrantes contribuiu com sua especialidade, e o resultado final, mais do que a soma de partes, reflete uma síntese a que a equipe chegou conjuntamente. É com esse espírito que se encerra esta monografia: com a satisfação serena do trabalho realizado, com o reconhecimento honesto das limitações que ainda permanecem e com a perspectiva motivada de que, sob condições adequadas de continuidade, o "Cão Radar" possa transcender seu estatuto atual de protótipo acadêmico e converter-se em ferramenta efetiva a serviço da reidentificação de cães extraviados em ambientes urbanos brasileiros.

REFERÊNCIAS

- AMAZON WEB SERVICES. *Amazon S3*: Cloudfary. [S.l.]: Amazon, [2025?]. Disponível em: <https://aws.amazon.com/s3/>. Acesso em: 29 out. 2025.
- ANGULAR. *Angular*: The Modern Web Developer's Platform. [S.l.]: Google LLC, [2025?]. Disponível em: <https://angular.io/>. Acesso em: 10 mar. 2026.
- ANTHROPIC. *Claude Code*: AI coding assistant. [S.l.]: Anthropic, [2025?]. Disponível em: <https://www.anthropic.com/claude-code>. Acesso em: 5 maio 2026.
- ARAVA, S. K.; YANG, W.; YUAN, Y. *Mixed Breed Dogs Classification*. [S.l.: s.n.], p. 1-7, [s.d.]. Disponível em: https://www.academia.edu/33721767/Mixed_Breed_Dogs_Classification. Acesso em: 29 out. 2025.
- BOCHKOVSKIY, A.; WANG, C.; LIAO, H. M. YOLOv4: Optimal Speed and Accuracy of Object Detection. *arXiv:2004*, p. 1-17, 2020. Disponível em: <https://arxiv.org/abs/2004.10934>. Acesso em: 11 nov. 2025.
- CLOUDINARY. *Cloudfary*: Image and Video API Platform. [S.l.]: Cloudfary Ltd., [2025?]. Disponível em: <https://cloudinary.com/>. Acesso em: 10 mar. 2026.
- CUI, Y.; TANG, B.; WU, G.; LI, L.; ZHANG, X.; DU, Z.; ZHAO, W. Classification of Dog Breeds Using Convolutional Neural Networks. *Bioengineering*, v. 11, n. 11, p. 1-14, 2024. Disponível em: <https://www.mdpi.com/2306-5354/11/11/1157>. Acesso em: 29 out. 2025.
- DA SILVA MELO, J. Classificação de raças caninas segundo a FCI. 2017.
- DENG, J.; DONG, W.; SOCHER, R.; LI, L.-J.; LI, K.; FEI-FEI, L. ImageNet: A Large-Scale Hierarchical Image Database. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2009, Miami. *Proceedings [...]*. New York: IEEE, 2009. p. 248-255. Disponível em: http://www.image-net.org/papers/imagenet_cvpr09.pdf. Acesso em: 11 nov. 2025.
- DOCKER INC. *Docker*: Accelerated Container Application Development. [S.l.]: Docker, [2025?]. Disponível em: <https://www.docker.com/>. Acesso em: 10 mar. 2026.
- FCI – FÉDÉRATION CYNOLOGIQUE INTERNATIONALE. *Breeds Nomenclature*. [S.l.]: FCI, [s.d.]. Disponível em: <https://www.fci.be/en/Nomenclature/Default.aspx>. Acesso em: 27 out. 2025.
- GOOGLE. *Gemini*: Google's Multimodal AI Model. [S.l.]: Google DeepMind, [2025?]. Disponível em: <https://deepmind.google/technologies/gemini/>. Acesso em: 10 mar. 2026.
- GRAFANA LABS. *k6*: Modern load testing for developers and testers in the DevOps era. [S.l.]: Grafana Labs, [2025?]. Disponível em: <https://k6.io/>. Acesso em: 5 maio 2026.

HU, M.; LUO, Z.; PASDAR, A.; LEE, Y. C.; ZHOU, Y.; WU, D. Edge-Based Video Analytics: A Survey. [S.l.: s.n.], 2023. *arXiv:2303*. Disponível em: <https://arxiv.org/abs/2303.14329>. Acesso em: 29 out. 2025.

HUGGING FACE. *Hugging Face Spaces*: Host machine learning apps. [S.l.]: Hugging Face Inc., [2025?]. Disponível em: <https://huggingface.co/spaces>. Acesso em: 5 maio 2026.

JUNIT TEAM. *JUnit 5 User Guide*. [S.l.: s.n.], [2025?]. Disponível em: <https://junit.org/junit5/docs/current/user-guide/>. Acesso em: 5 maio 2026.

KHAO, A. *Stanford Dogs Dataset*. Stanford University, 2011. Disponível em: <https://vision.stanford.edu/aditya86/StanfordDogs/>. Acesso em: 29 out. 2025.

KUPYN, O.; BUDZAN, V.; MYKHAILYCH, M.; MISHKIN, D.; MATAS, J. DeblurGAN: Blind Motion Deblurring Using Conditional Adversarial Networks. In: CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), *Proceedings [...]*, New York: IEEE, 2018. Disponível em: https://openaccess.thecvf.com/content_cvpr_2018/CameraReady/1944.pdf. Acesso em: 29 out. 2025.

KUPYN, O.; MARTYNIUK, T.; WU, J.; WANG, Z. DeblurGAN-v2: Deblurring (Orders-of-Magnitude) Faster and Better. In: INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), *Proceedings [...]*, New York: IEEE, 2019. Disponível em: https://openaccess.thecvf.com/content_ICCV_2019/papers/Kupyn_DeblurGANv2_Deblurring_Orders-of-Magnitude_Faster_and_Better_ICCV_2019_paper.pdf. Acesso em: 29 out. 2025.

LAMPERT, C. H.; NICKISCH, H.; HARMELING, S. Learning to Detect Unseen Object Classes by Between-Class Attribute Transfer. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2009, Miami. *Proceedings [...]*. New York: IEEE, 2009. p. 965-972. Disponível em: <http://bar-led.com/wp-content/uploads/2016/09/AttributeTransfer.pdf>. Acesso em: 11 nov. 2025.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436-444, 2015.

LIN, T.; ROYCHOWDHURY, A.; MAJI, S. Bilinear CNN Models for Fine-Grained Visual Recognition. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), 2015, Santiago. *Proceedings [...]*. New York: IEEE, 2015. p. 1449-1457. Disponível em: <https://arxiv.org/abs/1504.07889>. Acesso em: 11 nov. 2025.

LOBO, A. C. *Origem do Cão*. Formação TMA, 2019. Disponível em: <https://formacaotma.net/wp-content/uploads/2019/05/origem-do-c%C3%A3o.pdf>. Acesso em: 27 out. 2025.

MOCKITO. *Mockito framework site*. [S.l.: s.n.], [2025?]. Disponível em: <https://site.mockito.org/>. Acesso em: 5 maio 2026.

NEON. *Neon: Serverless Postgres*. [S.l.]: Neon Inc., [2025?]. Disponível em: <https://neon.tech/>. Acesso em: 10 mar. 2026.

ORACLE. **Java SE 21 (LTS)**. [S.l.]: Oracle Corporation, [2025?]. Disponível em: <https://www.oracle.com/java/technologies/javase/jdk21-archive-downloads.html>. Acesso em: 10 mar. 2026.

PARKHI, O. M.; VEDALDI, A.; ZISSERMAN, A. *The Oxford-IIIT Pet Dataset*. University of Oxford, [s.d.]. Disponível em: <https://www.robots.ox.ac.uk/~vgg/data/pets/>. Acesso em: 29 out. 2025.

POSTGIS. *PostGIS: Spatial and Geographic objects for PostgreSQL*. [S.l.: s.n.], [2025?]. Disponível em: <https://postgis.net/>. Acesso em: 29 out. 2025.

POSTGRESQL GLOBAL DEVELOPMENT GROUP. **PostgreSQL 17 Documentation**. [S.l.: s.n.], [2025?]. Disponível em: <https://www.postgresql.org/docs/17/>. Acesso em: 10 mar. 2026.

PRODUCTION & DIVISION. *Definição do termo raça*. 2001.

RADFORD, A.; KIM, J. W.; HALLACY, C.; RAMESH, A.; AGARWAL, S.; SASTRY, G.; ASKELL, A.; MISHKIN, P.; KRUEGER, G.; SUTSKE. I. Learning Transferable Visual Models From Natural Language Supervision. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 2021, [S.l.]. *Proceedings [...]*. [S.l.]: PMLR, 2021. p. 8748-8763. Disponível em: <https://arxiv.org/abs/2103.00020>. Acesso em: 11 nov. 2025.

REDMON, J.; DIVVALA, S.; GIRSHICK, R.; FARHADI, A. et al. You Only Look Once: Unified, Real-Time Object Detection. In: CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), *Proceedings [...]*. New York: IEEE, 2016.

RENDER. *Render: Cloud Application Hosting*. [S.l.]: Render Services Inc., [2025?]. Disponível em: <https://render.com/>. Acesso em: 5 maio 2026.

SPRING. *Spring Boot: Reference Documentation*. [S.l.]: VMware Inc., [2025?]. Disponível em: <https://spring.io/projects/spring-boot>. Acesso em: 10 mar. 2026.

SZELISKI, R. *Computer Vision: Algorithms and Applications*. Springer, 2010.

TYPESCRIPT. *TypeScript: JavaScript With Syntax For Types*. [S.l.]: Microsoft, [2025?]. Disponível em: <https://www.typescriptlang.org/>. Acesso em: 10 mar. 2026.

ULTRALYTICS. *ultralytics/ultralytics: YOLOv8*. [S.l.]: GitHub, [2025?]. Disponível em: <https://github.com/ultralytics/ultralytics>. Acesso em: 29 out. 2025.

VISÃO COMPUTACIONAL. *YOLO Versões 3 e 4: Arquitetura*. Disponível em: <https://visaocomputacional.com.br/yolo-versoes-3-e-4-arquitetura/>. Acesso em: 26 mar. 2026.

ZHANG, Y.; SUN, P.; DONGDONG, J.; WENG, F.; YUAN, Z.; LUO, P.; LIU, W.; WANG, X. Multi-Object Tracking by Associating Every Detection Box. [S.l.: s.n.],

2021. (arXiv:2110.06864). Disponível em: <https://arxiv.org/abs/2110.06864>. Acesso em: 29 out. 2025.

ZHAO, F. et al. A survey of fine-grained visual-categorization. *arXiv preprint arXiv:1907.03069*, 2019. Disponível em: <https://arxiv.org/abs/1907.03069>. Acesso em: 11 nov. 2025.